单位代码：10010

学　　号：2022210574

北京化工大学

专业学位

硕士研究生学位论文

题　　目　基于 LDA 模型的自然灾害网络舆情情感分析研究

专　　业　工程管理

研 究 生　张玉冰

指导教师　吴军　教授

企业导师　李虎　高工

日　　期：　2025 年 5 月 25 日

中国知网　https://www.cnki.net

学位论文数据集

中图分类号	C93	学科分类号	630.50
论文编号	1001020250574	密　　级	公开
学位授予单位代码	10010	学位授予单位名称	北京化工大学
作者姓名	张玉冰	学　　号	2022210574
获学位专业名称	工程管理	获学位专业代码	125601
课题来源	自选	研究方向	网络舆情
论文题目	基于 LDA 模型的自然灾害网络舆情情感分析研究		
关 键 词	自然灾害，舆情分析，LDA 模型，情感分析		
论文答辩日期	2025.05.17	*论 文 类 型	应用研究

学位论文评阅及答辩委员会情况				
	姓名	职称	工作单位	学科专长
指导教师	吴军	教授	北京化工大学	管理科学与工程
评阅人 1	盲审 A			
评阅人 2	盲审 B			
评阅人 3	盲审 C			
答辩委员会主席	辛春林	教授	北京化工大学	管理科学与工程
答辩委员 1	任继勤	教授	北京化工大学	管理科学与工程
答辩委员 2	赵庆亮	副教授	北京化工大学	管理科学与工程
答辩委员 3	赵柱	研究员	新兴重工集团有限公司	工程管理
答辩委员 4	侯朝鹏	研究员	中国石化石油化工科学研究院	工程管理

注：一. 论文类型：1.基础研究　2.应用研究 3.开发研究 4.其它

二. 中图分类号在《中国图书资料分类法》查询。

三. 学科分类号在中华人民共和国国家标准（GB/T 13745-9）《学科分类与代码》中查询。

四. 论文编号由单位代码和年份及学号的后四位组成。

中国知网　https://www.cnki.net

基于 LDA 模型的自然灾害网络舆情情感分析研究

摘 要

当重大的自然灾害事件发生时，网民在互联网上讨论的观点反映了公众对自然灾害事件态度和关注程度，当讨论的热度增加到一定的程度时，就会引起网络舆情的爆发。由于网络舆情的爆发给社会带来负面影响，所以通过挖掘并分析网民讨论的文本内容的方式能有效的控制舆情，能够准确了解网民真正关注的内容，为救灾工作献出一份力量；也能够了解公众的情感倾向，根据公众倾向政府相关部门能及时控制并引导舆情的行动。

本文以 2023 年发布的重大灾害事件中的台风“杜苏芮”和“海葵”两个典型自然灾害事件进行分析，得到公众在这两起重大自然灾害事件中的情感倾向和关注的核心内容。首先，采用了 Python 爬虫技术对微博平台进行爬取相关的数据，根据爬取数据的发表时间和评论个数，绘制了网络舆情趋势图，根据图中的变化趋势判断网络舆情的各个阶段，在网络舆情阶段划分上，总共分为舆情潜伏期、舆情爆发期、舆情波动期和舆情衰退期。其次，对于网络舆情的情感划分是使用了 Python 中的 Snownlp 技术，通过对情感语料库的更新，对评论数据进行情感分析并划分为积极和消极两类。然后，对数据的去重、去停用词等预处理，在有效的数据基础上，通过主题困惑度和主题之间的距离确定了最优的主题个数。再次，使用 Latent Dirichlet Allocation（简称 LDA）主题模型对两个重大自然灾害事件中积极和消极文本分别进行主题分类，每个主题当中选取最有特征的关键词进行主题分析。通过主题内容的对比分析，在积极文本中我们可以发现主题内容大多关于灾情的救援行动的正面信息，而消极文本中公众更关注灾害损失、人员伤亡等负面信息。最后，对重大自然灾害的舆情提出应对方案和情感引导策略。

本文基于两个典型自然灾害事件进行网络舆情研究，对文本不同情感下的主题内容进行分析，提出了重大自然灾害舆情的应对方案和情感引导策略。研究结果不仅有效制止网络舆情的爆发和更好的对重大自然灾害网络舆论进行正确引导，还可以向政府、媒体和社会提供一些借鉴和参考。

关键词：自然灾害，舆情分析，LDA 模型，情感分析

中国知网 https://www.cnki.net

RESEARCH ON SENTIMENT ANALYSIS OF ONLINE PUBLIC OPINION ON NATURAL DISASTERS BASED ON LDA MODEL

ABSTRACT

When major natural disasters occur, the viewpoints discussed by netizens on the Internet reflect the public's attitude and concern towards the natural disaster events. When the heat of the discussion increases to a certain extent, it will cause an explosion of online public opinion. Due to the negative impact of the outbreak of online public opinion on society, it can be effectively controlled by mining and analyzing the text content of netizens' discussions, which can accurately understand the content that netizens truly care about and contribute to disaster relief efforts; it can also understand the public's emotional tendencies, and based on the public's tendencies, government departments can take timely actions to control and guide public opinion.

This paper analyzes two typical natural disaster events, Typhoon Doksuri and Haikui, among the major disaster events released in 2023, and obtains the core content of the public's emotional tendencies and concerns in these two major natural disaster events. Firstly, the Python crawler technology was used to crawl the relevant data of the microblogging platform, and according to the publication time and the number of comments on the crawled data, the network public opinion trend map was drawn, and the various stages of network public opinion were judged according to the change trend in the figure. Secondly, the sentiment division of online public opinion is based on the Snownlp technology in Python, and the sentiment analysis of the comment data is carried out through the update of the sentiment corpus and divided into two categories: positive and negative. Then, the data was deduplicated and stopped, and the optimal number of topics was determined through the topic confusion and the distance between topics on the basis of effective data. Thirdly, the LDA topic model was used to classify the positive and negative texts in the two major natural disaster events

中国知网 https://www.cnki.net

respectively, and the most distinctive keywords were selected for topic analysis in each topic. Through the comparative analysis of the subject content, we can find that most of the positive information about the rescue operation of the disaster situation in the positive text, while the public pays more attention to the negative information such as disaster losses and casualties in the negative text. Finally, the response plan and emotional guidance strategy for the public opinion of major natural disasters are proposed.

Based on two typical natural disaster events, this paper conducts research on network public opinion, analyzes the theme content under different emotions of the text, and puts forward the response plan and emotional guidance strategy of public opinion of major natural disasters. The research results not only effectively stop the outbreak of online public opinion and better guide the online public opinion of major natural disasters, but also provide some reference for the government, media and society.

KEY WORDS: Natural disasters; Public opinion analysis; LDA model;

Sentiment analysis

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....1
1.2 国内外研究现状.....2
1.2.1 舆情分析研究.....2
1.2.2 信息收集研究.....3
1.2.3 主题分类研究.....4
1.2.4 情感分析研究.....5
1.2.5 可视化分析研究.....7
1.2.6 文献述评.....7
1.3 研究主要内容.....8
1.3.1 数据来源.....8
1.3.2 研究案例.....9
1.4 研究方法与思路框架.....9
1.4.1 研究方法.....9
1.4.2 技术路线.....10
第 2 章 相关理论与方法.....11
2.1 网络爬虫技术理论.....11
2.2 情感分析技术理论.....12
2.3 LDA 主题分类理论.....13
2.4 数据预处理理论.....14
2.4.1 数据去重.....14
2.4.2 数据去停用词.....14
2.4.3 正则表达式提取中文文本.....15
2.4.4 jieba 分词.....15
2.5 本章小结.....15
第 3 章 网络舆情阶段性演化分析.....17
3.1 数据文本的选取.....17
3.2 台风杜苏芮网络舆情阶段划分.....19
3.3 台风海葵网络舆情阶段划分.....22
3.4 本章小结.....23
第 4 章 情感语料库的构建以及情感分析.....25
4.1 网络情感语料库的构建.....25

中国知网 https://www.cnki.net

4.1.1 Snownlp 情感分析技术 25
4.1.2 构建台风灾害的情感语料库.....25
4.2 情感分析结果.....27
4.2.1 台风杜苏芮网络舆情的情感分析结果 27
4.2.2 台风海葵网络舆情的情感分析结果.....29
4.3 本章小结.....32
第 5 章 结合情感分类的主题提取及分析 33
5.1 LDA 主题模型分析 33
5.1.1 LDA 主题模型的构建 33
5.1.2 LDA 主题模型评估标准 34
5.2 主题提取结果.....39
5.2.1 不同情感下台风杜苏芮的主题分析.....39
5.2.2 不同情感下台风海葵的主题分析.....43
5.3 本章小结.....47
第 6 章 重大自然灾害舆情的应对方案和引导策略 49
6.1 面对重大自然灾害舆情的应对方案 49
6.1.1 基于大数据技术提高识别不同主题舆情精准度 49
6.1.2 采用实时直播分析不同主题内容并制定方案 49
6.2 面对重大自然灾害舆情的引导策略 50
6.2.1 发布权威消息实现多渠道正确引导情感 50
6.2.2 联动社区支援实现凝聚力正向引导情感 50
6.3 本章小结.....51
第 7 章 总结与展望 53
7.1 总结.....53
7.2 展望.....54
参考文献.....55

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景与意义

1.1.1 研究背景

面对突如其来的的自然灾害，不仅对人类和社会造成严重的伤害和损失，也会对环境造成严重的破坏，在互联网还没发达的时候，唐山大地震这一重大灾情的消息传播大多是从电视新闻播报。而在科技发展的今天，互联网技术愈加成熟，已经渗透到我们生活当中，也给我们生活带来了巨大的影响。互联网产生了多种多样的载体，有微博，抖音，B 站，豆瓣，知乎等平台，在信息时代信息传播的速度非常快，再加上我们每个人都有权力在网络平台上发表自己的意见，就会导致网络舆情的产生，目前微博是网络舆情的最高载体之一，网络舆论有好处也有弊处，网络的信息发达和探讨让我们得知信息更快，更了解世界各地发生的事情，同时也是由于信息的传播飞快，如果网络舆论不加以监控和控制，就会让网络舆论更加走到高点。为了响应和实现《“十四五”国家综合防灾减灾规划》的目标——达到灾害防治能力现代化，习主席曾说“互联网是网络舆情的重要区域，而且网络舆论工作已经归为宣传思想工作的关键环节”，由此可见国家对网络舆情产生影响的高度重视。对舆情监控随时掌控网络信息和舆情倾向，能立刻对其做出响应。那如何在网络舆情当中观察到人民对此事件是处于什么态度以及如何进行网络舆情控制呢？因此本文参考应急管理部发布的 2023 年重大自然灾害中的台风“杜苏芮”和台风“海葵”的灾情进行案例分析，在面对自然灾害的网络舆情时，通过 Snownlp 和 LDA 模型进行分析研究，最后进行可视化分析来掌握网民的情感、态度、观点、意见，对官方、政府能够引导舆论的走向起到一个重要的依据。如果舆论产生，政府的积极参与引导能够有效的减少负影响的蔓延。

1.1.2 研究意义

在面对网络信息发达的社会和不确定的灾情的发生，对网络舆情的爆发通过分析民众的情感进而监控舆论的走向引导，有以下研究意义：

理论意义：①在网络信息时代，人们基本使用网络来表达自己的观点并含有隐藏的情感，本文对于 LDA 主题理论进行梳理和研究，采用 LDA 主题模型结合对文本情感的方法进行主题建模，有助于在灾情网络舆情中 LDA 主题模型的应用，推动 LDA 主题模型在灾情当中的研究领域，为后续相关工作打好基础。②最近几年，

中国知网 https://www.cnki.net

学者群体对分析网络舆情的兴趣越来越浓厚。在借鉴前人的研究基础上深化了关于网络舆情的研究，但是本文使用案例具体分析灾害舆情的情感可视化分析，使用情感模型对两重大自然灾害事件进行分析，有效的验证模型的适用性，在一定程度上弥补了前人对此问题领域的研究不足，丰富了在灾害网络舆情研究方向，在救灾情况下各大网民的需求，也给政府和国家提供了一定的参考价值。

实际意义：①网民的情感和意见有利于政府做灾情救灾的工作，一般自然灾害发生后越来越多的人民在网络平台关注灾情的情况，发布的求助信息是工作人员探索不到的灾情信息，网络舆情在助力地震灾害减灾救灾工作方面有巨大潜力。②有利于官方媒体、政府对舆情的掌控和引导，随着互联网的迅猛发展，互联网载体越来越多，每个平台的用户也发表自己的意见和评论，如果不对网络舆论进行管制和引导，就有可能引起网络风波，尤其是对于自然灾害事件，对人民生命安全有重大影响的事件，所以对此领域进行舆情分析，进而对网络舆情管理和引导有重要意义。

1.2 国内外研究现状

由于网络应用的迅速普及，常常爆发一些自然灾害的新闻，例如：河南洪水，地震，台风等，这些不可控的自然灾害引起了网民们的恐慌，肆意飞起的视频和文案进行各种网络平台的转载，导致了网络舆情的发生。如果舆情不及时管控，那么带来的结果严重影响着人们的情绪和网络治安，对于网络舆论正确的引导，引起了政府和媒体的重视。对此，通过阅读大量的文献以及整理，从以下四个方面进行综合概述：

1.2.1 舆情分析研究

网络舆情就是全世界人民在互联网的不同平台上对某个事件发表的各种看法、情绪和意见，并通过互动和传播形成的一种舆论氛围[1]。因为网络上的用户来自各地，由于大家接受不同的文化所以也有不同的见解，具有偏差性；针对这个网络舆情带来的认知偏差，李明德，邝岩(2023)[2]从传播学的角度出发，技术环境和主题认知结构两个层面解析了网络舆情认知偏差的原因，并提出了相应的纠正策略。在互联网快速发展的时代，新媒体应运而生，它和传统媒体相比，更加满足当今公民的需求，也体现了交互性，即时性和共享性，新媒体环境下网络舆情具备的这些特征显得网络舆情的引导显得尤为重要，冯超(2021)[3]对新媒体环境下的网络舆情特点展开了分析以及对现有的瓶颈提出更好的方案。艾敬怡，耿亮和安彧(2023)[4]等人对于网络舆情预测情况以及是否会发生反转，构建了基于 RVM 的网络舆情反转模型，能够及时发现反转舆情并及时对网络舆情作出正确的引导和控制。在社交网络发达的时代，网络舆情传播具有传播速度快、范围大、主体多元化、传播导向分化等特点，对于以上的网络舆情特点,梁瑛楠和张丽颖(2021)[5]从新媒体，网民和政

中国知网 https://www.cnki.net

府的角度提出了治理网络舆情的应对措施。还有胡锦玉(2019)[6]也对新媒体环境下的网络舆情的特点进行研究和提出相应的应对策略。舆情的种类分很多种，此次研究的是自然灾害网络舆情，从历史发展以来，自然灾害的发生主要有两个原因：一是自然本身的变化，比如气候、地质等自然条件的变化；二是人类活动对自然环境的影响。自然灾害是指那些对人类的生命、财产或生活环境造成破坏的自然现象，比如地震、暴雨、洪水等。本文研究的自然灾害网络舆情在自媒体环境下，更容易产生网络舆情，这种自然灾害事件不仅影响着人民的生命安全和生活，还影响着经济损失，一旦灾害事件发生，信息就会迅速传播，对于减灾，自然灾害网络舆情的治理是非常重要的。张谱，张豪和孔锋(2023)[7]等人进行了自然灾害舆情的研究，阐述了暴雨洪涝灾害舆情特征，并从时间序列角度上进行了情感分析，能够方便看出灾害舆情变化趋势情况。唐忠强(2018)[8]针对 10 年的舆论数据进行分析新媒体下网络舆情对公共政策产生的影响，研究结果体现了国家政策的建立和网络舆情传播的联系。张伟平(2019)[9]指出网络舆情对政策产生了积极和消极的影响，为了良好的网络环境，推动一系列政策的制定，发挥积极影响的同时减少负面影响。在挖掘灾情情势时，关注到灾害信息传播非常重要，刘晓岚(2022)[10]对防灾科技学院建构的一个较为完整的灾害信息传播理论谱系进行研究，也对应急管理部和防灾救灾提供了帮助。郭怡雷(2018)[11]也对邢台 719 洪灾事件进行研究，提出在舆情当中的问题以及提出合适的引导的策略。

1.2.2 信息收集研究

一般情况下，舆情信息的获取渠道主要从官方媒体，网站，论坛，博客和公众号等平台获取，互联网的平台又多，数据也杂，舆论信息内容的采集是非常重要的，目标选的准确，就会事半功倍，吴珺(2009)[12]对互联网的获取信息进行了阐述，首先，我们把舆情的来源归纳为 7 个方面，分别是经济工作：这是舆情的核心，也是大家最关心的。重点工作：比如政府或社会正在推进的重要任务，容易引发网民的讨论。重大事件：比如自然灾害、重大事故等，并且会吸引大量网民关注。突发事件：突然发生的事情，容易引起大家的强烈反应。重要改革措施：如果改革措施和大家的期望有差距，容易引发争议。重大政策调整：新政策出台，尤其是涉及民生的，容易成为热点。群众切身利益：和老百姓生活直接相关的事情，往往是焦点。媒体炒作：有时候媒体过度报道也会引发新的舆情。其次对采集信息的来源进行八大类，分别为政府新闻网站：官方发布的信息。大型商业网站：比如新浪、腾讯等，信息更新快，大家也比较信任。新闻媒体网站：比如新华社、人民日报等权威媒体。代表性地方网站：代表某个地区的新闻和信息。BBS 及网络社区：比如贴吧、论坛，大家自由讨论的地方。时事论坛：专门讨论热点事件的地方。Blog（网络日记）：个人写的文章，可能表达一些独特观点。特殊导航网页：一些专门收集热点新闻的

中国知网 https://www.cnki.net

网站。总的来说，大型商业网站因为信息更新快、可信度高，是舆情信息的重要来源。本文对灾情的舆情分析既是对重大事件的分析也是和老百姓相关的焦点，王全兰(2012)[13]提出网络舆情采集分为一般采集和重点采集。张颖，林洋和张澜等(2020)[14]人对灾情信息快速获取采用的方式是一般采集，采用了八爪鱼采集器结合灾情分类模型字典进行信息获取，但是一般采集不设主题，信息获取量大，数据的精准度不高，而重点采集则是对产生舆论的来源进行采集，不限于网页、网站、博客或是某个热点话题。常用的数据采集方法有很多，例如目前研究学者王金峰，彭禹和王明(2019)[15]等人采取了基于 Scrapy 框架的改善和 Requests、Selenium 等工具进行网络爬虫，此方法可以实现很多用户来爬虫，获得指定爬取的内容信息，提高了爬取信息的效率和稳定性。杜晓旭和贾小云(2019)[16]通过基于 python 微博爬虫的基础上，设计一种新的 python 网络爬虫程序，更加精准获取信息并且具有较高的实用性和有效性。Rungsawang and Angkawattanawit(2005)[17]通过构建三种知识库起始 url、主题关键词和 url 预测提出了特定主题的爬虫方法，能收集到更多相关的网页数据。综上所述，对于灾情网络舆情的数据收集，基于大量的文献的基础上，将采用人工采集的方式从大型商业网站中的微博平台进行网络爬虫设计，爬取的数据具有针对性和准确性。

1.2.3 主题分类研究

LDA 于 2003 年由 Blei(2003)等人提出[18]，是基于概率图的三层贝叶斯模型，能够从一堆杂乱无章的文档当中自动分类为几个主题，这个模型的结构更清楚更完整，而且能用高效的算法快速处理大量数据，所以用的人很多，并促使主题模型成为 Twitter、微博等网络文本领域的研究热点。Jelodar et al.(2019)[19]通过调研 LDA 相关的文献研究模型的架构和应用，LDA 主题采样方式一般分为三种：吉布斯采样(Gibbs)，期望最大值算法和变分贝叶斯推理，强调在主题分析应用中引入 LDA 主题模型非常有价值，并且应用范围广泛。首先在舆情分析方面，蔡一村，李家新和黄小冬(2024)[20]获取各网络平台的涉台数据，对文本数据进行预处理后，通过 LDA 主题模型进行主题分类，了解公众对涉台的态度和关注情况。宋雅蓉，王译啡(2023)[21]通过一种基于 LDA 主题挖掘模型和情感分析的方法对网上教学舆情分析研究，对网络舆情的监管和引导具有很大的研究意义。陈齐超，林广发(2021)[22]等人通过对“米克拉”灾情分析，采用 LDA 主题模型分为灾损信息类、 防御信息类、预警信息类和无关信息类，对不同主题分别进行分析，对台风的减灾有一定的辅助作用。Luo(2019)[23]利用 LDA 主题模型对网络舆情进行主题分布，与卷积神经网络 CNN 结合对文本舆情分析，有效地提高了文本情感分类的准确性。

中国知网 https://www.cnki.net

其次 LDA 主题模型也可以结合情感分析，对此曾子明，陈思语(2023)[24]通过利用 LDA 模型、Bert-BiLSTM-Attention 模型构建研究框架，探究不同周期的舆情主题差异及情感演化，对控制和引导舆情有一定的参考意义。杜景玮(2020)[25]通过构建 LDA 与 TF-IDF 为框架的特征词筛选模型 TI-bLDAs 模型，目的是过滤掉情感极性无关词以及冗余词汇，并且在不同情感下验证有效性，对情感分析应用研究提供了参考意义。Huang et al.(2020)[26]在 LDA 主题模型中嵌入情感层，设计了一种新的主题情感分析模型，对主题情感演化分析有较好的效率和可解释性。孙玲玲(2021)[27]通过 LDA 主题模型进行用户关注主题挖掘，发现用户关注主题呈现类型多、范围广的特点，找到用户的关注重点，再与 BiLSTM-Attention 模型相结合，挖掘用户对商品的情感趋向，并为商家改善产品提供了一定的理论依据。杨嘉怡，李晓英和何首武(2022)[28]基于 Snownlp 对手机评论文本情感分类并通过 LDA 模型进行主题分析消费者的情感关注，对商家提供了一定的参考价值。

要想在文本分类中 LDA 主题模型分类效果更好，就需要选择合适的主题个数，一般选取合适的主题个数有两个指标：主题一致性得分和主题困惑度[18]。Rosner et al.(2014)[29]提出了主题一致性的公式。 Huang et al.(2017)[30]采用的主题困惑度选取最优的主题个数。Li et al.(2024)[31]选择 LDA 主题模型的主题个数是通过主题之间的距离来判断，主题之间的距离通过余弦相似度计算，余弦相似度越低代表主题之间重叠的少，主题分类效果更好。在 LDA 主题模型改进和优化方面，倪维斌，姜垚松和罗玮等(2018)[32]人使用 hierarchical latent Dirichlet Allocation（hLDA）层次主题模型挖掘患者投诉数据的主题，归纳出一个分类框架，并对患者投诉的主题分布进行可视化分析，对评估医疗服务质量有一定的贡献。Ye et al.(2018)[33]采用改进的 LDA 主题模型和支持向量机 SVM 对主观文本进行情感分析，使用了 TF-IDF 算法挖掘主题，对改进的 LDA 主题模型用于多分类的问题比传统的有效。

1.2.4 情感分析研究

1995 年情感计算的概念由 Picard 首次提出，并于 1997 年正式出版《Affective Computing（情感计算）》，情感分析也可看作是挖掘公众的观点，是研究人们对产品、事件等具体事物所表达的个人看法及主观情绪[34]。随着网络媒体的发达和使用，更多的人喜欢在网络平台上抒发自己的意见，滋生了越来越多的文本性数据，一般从数据的获取到文本情感分析过程中，数据基本来源于网民的各大平台的发言评论。目前国内有一些学者对文本情感分析作出了研究，国内学者有对在线评论进行情感分析，李杨，徐泽水和王新鑫(2023)[35]对网上的评论内容隐藏的的情感进行分析，采用的方法主要有四大类：基于词典的方法、基于机器学习的方法、基于深度情感分类学习的方法和混合类型的情感分析方法，在基于词典的方法上，赵妍妍，秦兵

中国知网 https://www.cnki.net

和石秋慧(2023)[36]等人设计了一种专门针对微博的海量的情感词典，分类效果有了不少的提高；在建构情感词典过程中，有非自动构建和自动构建两种方法，情感词典当中对微博的情感词语覆盖不高，所以为了增加情感词典的适用性。Xu et al.(2019)[37]构建了扩展词典，包括基本词典、多义情感词和特定领域当中的情感词汇，对酒店、服装、水果、数码、洗发水等领域都具有良好的效果。但是王科和夏睿(2016)[38]对于情感词典进行了分类指出情感词典的不足，为了使情感分类更准确，引入了机器学习的情感分析。对于基于机器学习的情感分析，蔡增玉，韩洋和张建伟(2024)[39]等人通过 Python 中的 Snownlp 文本分析库，Snownlp 情感分析是基于朴素贝叶斯原理实现的，将数据进行人工标记，然后进行训练模型，得出文本的情感倾向值，积极情感值在 0.5 和 1 之间，消极情感值在 0 到 0.5 之间。邱冬阳，绘娴(2023)[40]通过引入 Snownlp 情感分析对购物的评论进行情感分析，情感平均分值直接反映了网民的满意程度。Qu et al.(2024)[41]针对微博上的广州城市的信息进行爬虫，通过将这些信息进行分类了解不同主题下的情感倾向，采用了 Snownlp 情感分析方法，通过标记的数据进行训练模型，最终得到文本的情感分值，进而了解人们对广州的态度和感受。Zhang and Wu (2022)[42]对猫眼平台下的电影评论的信息采用了 Snownlp 方法计算文本情感得分，了解用户对不同电影的感受以便提供给用户观看电影的选择。Sugiyarto et al.(2021)[43]引入了卷积神经网络的模糊情感分析方法，通过机器学习进行情感分析，能够得到更好更流畅的情感分析结果。基于深度学习的情感分析，金书丞，王嘉梅(2025)[44]提出了基于 BERT-MABL 模型的情感分析方法，在产品、酒店和电影领域进行了评估，由于加入了 BERT 模型和注意力机制，解决了联系上下文语义的困难和词汇情感权重等问题。周凯和李晖(2022)[45]等通过在 BERT 语言模型上结合 DPCNN 神经网络分类器，提升了模型的运行效率和计算性能，增强了模型的泛化能力，优化后的模型能够更有效地适应情感分析任务的需求。温廷新，陈依琳(2022)[46]基于深度学习思维对不均衡评论文本进行情感分析研究，研究了一种结合 LWC-BilSTM 模型，主要用于分析长短不一的文本，LWC-BilSTM 模型可提升类别不同文本长度不同的深度学习性能，提高了对不均衡评论数据的情感分析效率。Wei et al.(2020)[47]提出了用于隐式情感分析的模型——BiLSTM 模型，解决一些难以分辨但常常忽略的情感词汇。混合情感分析是一种把前面三种情感分析方法进行整合的一种分析方法，它往往是把机器学习、深度学习的算法与词典资源的精确性相结合，曾莉，杨添宝和周慧(2022)[48]构建的基于 LDA 与 Attention 机制 BilSTM 的混合模型能够反映舆情中的热点话题与情感时序变化，揭示事件爆发的主要原因，帮助了有关部门识别舆情，引导舆情。文本情感分析往往分为三大类：其一是依赖情感词典的方式，其二是采用机器学习方法，其三则是使用特殊模型来进行分析[49]。SnowNLP 是采用了朴素贝叶斯算法对情感进行分析的模型。文本内容

中国知网 https://www.cnki.net

经过模型进行情感分类，情感倾向值按照消极到积极映射[0，1]区间，此研究基于Snownlp 方法进行文本情感分析。

1.2.5 可视化分析研究

网络舆情一般分为隐匿期，爆发期，衰退期，有部分学者对时间上进行统计分析，例如刘华玲，王希睿和孙爱华(2021)[50]对于新冠疫情的舆情阶段进行时间上的关建节点，国内关注的热点和国外关注的热点进行可视化分析，为完善大型公共卫生事件的舆情应对机制提供科学支持。国内外学者也对数据可视化作出一定的研究，对于可视化工具多种多样，麦丞程，陈波和周嘉坤(2016)[51]等人介绍了国内现有的可视化工具，一般可分为用于软件应用的微博可视化工具，网页应用的微博可视化工具和智能移动终端的微博可视化工具。吴帆(2018)[52]对热点事件的数据进行 web 浏览器可视化，采用的技术是结合了 ECarts 框架，实现了文本情感分析结果，用户信息等多种可视化图形展示；而李亚芳，王新刚和梁庆云(2020)[53]对于新疆伽师 6.4 地震的舆情调用了 Python 中的 word cloud（词云展示库）、PIL（图像处理库）、matplotlib（图像展示库）等功能模块，可实现数据的可视化展示，对于辅助政府应急救援决策具有实际影响；赵剑，董文华和史丽娟(2021)[54]等人对于突发事件的舆情，采用了 wordcloud 和 matplotlib 对清洗后的数据进行高频词统计，生成词云图，进行情感分析的可视化。刘丽群(2022)[55]使用 React 框架和 Echarts 技术实现了舆情分析结果可视化。Ono et al.(2007)[56]介绍了在 Jupyter Noterbook 中实现可视化的三种方法，分别是 Matplotlib 回调、导入可视化工具包和自定义 Html 嵌入。Nordmann et al.(2022)[57]讲述了 R 的可视化的基本原理和教学步骤。以上是基于软件应用的微博可视化工具，但是基于人工编程会费时费力，对此宋成章，黄晓东和李棚(2014)等人[58]是为了比人工编程省时省力，能够快速的进行数据可视化，从而利用了 Processing 工具对的数据进行挖掘分析和可视化。王心瑶，郝艳华和吴群红(2018)[59]等人利用一些云软件帮助实现词频直观化，使词频分析结果呈现效果更直观、更清晰。可视化展示能够直接呈现数据的变化，Cui et al.(2021)[60]提出了一种新的可视化方法 VineMap，使能够让用户以分层的形式理解民意，并且通过评估证明 Vinemap 可视化方法的多功能性。Wu et al.(2014)[61]引入了 OpinionFlow 可视化分析系统，增强了信息扩散的模型，通过模型和新的可视化技术结合，能够检测意见传播模式并收集。基于大量文献的基础上，本文选用较多使用的人工编程调用第三方库的方式进行可视化分析。

1.2.6 文献述评

通过对舆情分析、信息收集、主题分类、情感分析以及可视化进行国外内文献

中国知网 https://www.cnki.net

的梳理和总结，发现网络舆情情感分析逐渐成为学术界的热点领域。这些研究成果在舆情情感分析研究过程中奠定了良好的理论基础。首先，在舆情分析方面，在新媒体环境下对舆情的传播、舆情的特点以及治理的引导策略进行了研究，可以有效的通过舆情趋势来预测舆情阶段，针对每个不同时期提出相应的解决方案。但目前对自然灾害台风的舆情的研究缺少多事件对比分析、数据的多模态整合。其次，在信息收集方面，收集的来源一般都集中在用户多的社交平台上，例如：微博、抖音、B 站等，收集的方法一般分为人工采集、自动采集，采用自动采集的方法可以达到高效又准确。但是优化算法是一直思考的问题。再次，在主题分类的研究中，采用 LDA 主题模型对舆情数据进行不同主题的分类，能够更加准确了解采集的内容和主题，通过对 LDA 主题模型的研究发现 LDA 主题模型已经广泛应用在主题分类领域。但在面对复杂的主题需要结合深度学习进行学习。然后，在情感分析方面，一般分为情感词典、机器学习和深度学习三类，通过情感分析的方法发现文本的潜在情感倾向，有利于捕捉公众的态度和舆情趋势，但分析的领域不同，情感词典需要做相应的补充。最后，在可视化分析中多采用基于 Python、R 语言的图形工具和云软件，通过这些图表来直观展示数据，可以协助研究者了解局势。

结合上述的研究现状，本文提出了相应的改进。舆情分析方面增加了对自然灾害台风事件的舆情分析，结合多案例进行实证分析；情感分析方面补充了情感词汇，进行情感分析模型的训练，对文本数据进行情感倾向的划分。通过上述的改进，本文旨在为舆情分析领域提供更科学、更实用的研究方法，同时为相关决策提供数据支撑。

1.3 研究主要内容

1.3.1 数据来源

由于互联网的载体多种多样，B 站，抖音，微信，微博都是用户基数庞大的社交平台，本文选取微博的原因，第一是它拥有大量用户关系，并且用户可以通过多种设备登录，例如 PC、手机等。第二它的内容的表现形式不限于文字、图片、视频等，达到信息的共享性，即时性。第三它的传播方式是裂变式的形式，促进了用户之间的互动，更让他们觉得与世界紧紧相连，随时获取世界的信息。根据 2024 年微博用户消费趋势报告显示，截至 2024 年 9 月，微博月用户达到了 5.87 亿，日活用户达到 2.57 亿，用户当中的年龄几乎 90 后占比最高，其次是 00 后。所以基于用户多，发表意见多，选取微博平台作为研究数据的来源。

中国知网 https://www.cnki.net

1.3.2 研究案例

应急管理部公布了 2023 年全国十大自然灾害名单，其中包括 1 月 17 日西藏林芝派墨公路遭遇的雪崩、6 月底至 7 月初重庆遭受的暴雨洪涝及地质灾害、2023 年第 5 号台风“杜苏芮”的肆虐、7 月底至 8 月初京津冀地区爆发的暴雨洪涝灾害、8 月初东北地区面临的暴雨洪涝挑战、陕西西安长安区“8·11”山洪泥石流惨剧、四川金阳“8·21”山洪灾害的侵袭、2023 年第 11 号台风“海葵”的登陆、9 月中旬江苏盐城等地遭遇的风雹灾害，以及甘肃积石山发生的 6.2 级地震。其中 2023 年 7 月 28 日上午，第 5 号台风“杜苏芮”在福建省晋江市沿海强势登陆。由于受多重因素影响，这场台风竟在华北等内陆地区引发了罕见的极端强降雨，导致洪涝灾害肆虐，损失惨重。鉴于台风“杜苏芮”与台风“海葵”在属性上的诸多相似之处，且在微博上引发了广泛的关注与热议，本文特此选取这两个典型台风自然灾害事件，进行深入探究与分析。

1.4 研究方法与思路框架

1.4.1 研究方法

本文研究内容是基于 LDA 主题模型对自然灾害网络舆情的情感分析研究，研究过程中运用了计算机爬虫技术、情感分析和 LDA 主题模型的方法，具体的研究方法涵盖以下几个方面：

在文献研究方面，首先下载并阅读了对不同平台数据采集、LDA 主题模型、情感分析有关的国内外文献，整理这些文献中的技术路线与理论方法，其次对涉及到的理论方法进行学习理解，最后结合本文的研究灾害事件案例，从文献研究上选取了合适的理论方法并设计出符合本文研究的技术路线。

在案例分析方面，我们选取了应急管理部发布的 2023 年第 5 号台风“杜苏芮”和第 11 号台风“海葵”作为研究对象，进行了全面深入的分析。在数据获取方面，我们采用了基于 Python 的网络爬虫技术，通过“杜苏芮”、“门头沟暴雨”、“涿州暴雨”和“台风海葵”等关键词在微博平台上进行了数据的抓取。

在情感分析方面，主要使用的 Snownlp 情感分析技术进行情感分析。第一是因为 Snownlp 情感分析技术是以朴素贝叶斯模型为基础，在大量的文本数据中，可以将文本情感划分为消极和积极两个大类，情感分值在 0 到 1 之间。第二是它具有多种功能，包括不限于中文分词、词性标注以及情感倾向判断。

在 LDA 主题模型方面，经过对数据的去停用词、去重等不必要的信息以及对

中国知网 https://www.cnki.net

文本情感倾向性分析划分的积极文本和消极文本之后，就采用了 LDA 主题模型进行文本内容的分类。在训练 LDA 主题模型中，通过调整主题个数、迭代次数和超参数α、β等参数，结合了主题困惑度和主题气泡图，确定了 LDA 主题模型。

1.4.2 技术路线

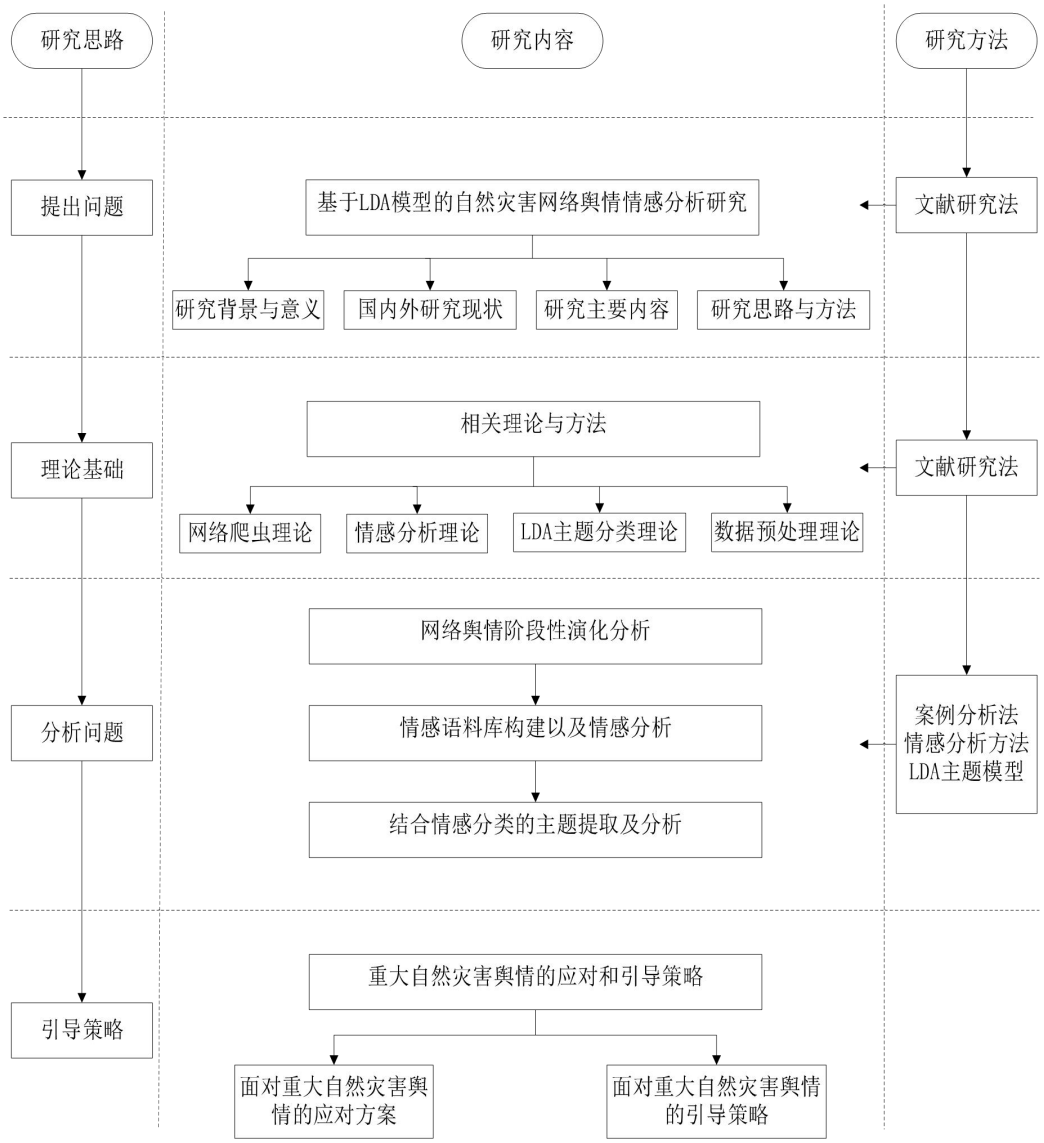

图 1-1 技术路线图

Fig.1-1 Technology Roadmap

中国知网 https://www.cnki.net

第 2 章 相关理论与方法

2.1 网络爬虫技术理论

网络爬取技术使我们能够从互联网上获取大量的信息，包括新闻、文章、图像、视频、社交媒体帖子等。政府和企业可以使用数据爬取技术来监测社交媒体上的舆情，了解公众对他们的看法，及时做出反应，数据爬取技术在信息获取和分析方面发挥着至关重要的作用。本研究所有的数据都是利用以 python 爬虫技术实现，对于网页的部分有 HTML、CSS、JavaScript。HTML 的用途是通知浏览器去编排网页的标记语言。它并非是编程语言，是具有描述性功能的标记语言，主要是展示网页内容的结构和显示方式，如字体颜色、大小等。HTML 文档由一系列元素组成，这些元素通过一些关键词来表示。网页的显示是网页的内容而决定，网页的内容是由 HTML 的尖括号“<”和“>”包围起来。除了网页的内容，还有内容的格式，CSS 主要作用是控制网页的布局、字体、颜色、间距等视觉效果，使网页更加美观。HTML 与 CSS 的结合是静态的网页，如果引入 javascript 就能实现动态界面。JavaScript 是一种动态语言，与静态的区别是在运行时可以改变其结构和行为，主要用途是创建网页的动态交互、数据处理和页面特效。

网络爬虫大概的任务是把网站中的指定的网页获取到本地， 并对网页的特定内容实施复制备份。爬虫可以分为三个过程： 获取网页 URL 的源码、提取网页的信息、下载存储所对应的网页数据。Python 中有很多库，如 Requests 库是一个基于 Python 编写的 HTTP 库，它基于 urllib3 模块，Requests 库提供了多种 HTTP 请求方法，包括 GET、POST、PUT、DELETE、HEAD 和 PATCH 等。其中，GET 和 POST 是最常用的两种方法。使用 Requests 库进行 HTTP 请求的一般步骤：引入 Requests 库、采用库中内置的 get、post 等方式发起 HTTP 请求、接收响应、随后依据实况来判断是否要将数据保存。

对爬虫程序设计首先选择微博平台进行微博博文和微博评论数据爬取，其次设置浏览器 url、Cookie 和 User-Agent 模拟用户访问浏览器，爬取数据的关键词有杜苏芮、门头沟暴雨、涿州暴雨、台风海葵等。爬取的时间根据“杜苏芮、台风海葵”的发生时间前后来设置。最后通过对网页元素的定位将数据爬取下来并保存，整个过程中涉及到很多相关的库比如 requests、pandas、lxml.etree、urllib.parse、time 和 os 等，其中 time 模块是时间相关的函数，os 模块提供了许多与操作系统交互的函数，用于执行文件、目录等操作系统相关的操作。

中国知网 https://www.cnki.net

2.2 情感分析技术理论

情感分析技术是自然语言处理研究的领域，从文本当中识别、提取、分类、归纳以及解释文本中所表达的情感或情绪，从文本中观察到个人情感、态度、评价或心情[34]。在情感分析的过程中，系统或算法通过分析文本内容并且捕捉并量化文本所表现的情感倾向。情感倾向一般有积极、消极以及中立。目前情感分析运用的方法基本分为基于情感词典、机器学习和深度学习[35]。第一种是依赖于预先建立的情感词汇集，这个集合为每一个情感词汇都设定了对应的情感倾向性分值。在整个分析流程中，首要任务是从大量的文本内容中抽取出含有情感的所有词汇，并且考虑到句子的特定句型计算得出最终的情感总分。然后基于这个总和分数来断定文本的情感倾向。第二种是基于机器学习的情感分析，通过训练标注好的数据来构建模型，来面对新的文本进行情感分类。第三种是基于深度学习的情感分析，利用深度学习技术从文本数据中提取情感信息，做出文本数据的消极到积极的区分。

在研究过程中，采用了 Python 的工具库 Snownlp 用来对文本数据进行情感倾向性分析。它的原理是朴素贝叶斯分类算法，该算法基于一个核心假设：文本中的特征词是相互独立的，即一个特征对特定类别的影响不受其他特征的影响。其核心公式为：

$$P(Y=c_k \mid X=x)=\frac{P(Y=c_k)\cdot P(X=x \mid Y=c_k)}{P(X=x)} \cdots\cdots\cdots\cdots\cdots\cdots \text{式（2-1）}$$

式中的 $P(Y=c_k \mid X=x)$ 是样本 $X=x$ 的前提下，$Y=C_k$ 发生的概率即后验概率；$P(Y=c_k)$ 是类别 c_k 的先验概率，即在训练数据集中类别 c_k 出现的频率；$P(X=x \mid Y=c_k)$ 是在类别 c_k 下，样本 $X=x$ 出现的条件概率；$P(X=x)$ 是样本 $X=x$ 出现的先验概率，通常在实际计算中作为常数项被省略，因为它不影响类别的比较。其中的条件概率 $P(X=x \mid Y=c_k)$ 是每个特征条件概率的乘积：

$$P(X=x \mid Y=c_k)=\prod_{j=1}^{n} P(X^{(j)}=x^{(j)} \mid Y=c_k) \cdots\cdots\cdots\cdots \text{式（2-2）}$$

式中的 n 是特征的数量，$X^{(j)}$ 表示第 j 个特征，$x^{(j)}$ 是该特征在样本 x 中的取值。因此，朴素贝叶斯公式可以最终表示为：

$$P(Y=c_k \mid X=x) \propto P(Y=c_k)\cdot \prod^{n} P(X^{(j)}=x^{(j)} \mid Y=c_k) \cdots \text{式（2-3）}$$

中国知网 https://www.cnki.net

2.3 LDA 主题分类理论

LDA 主题模型的主要用途是通过分析文章中的词语，来推测文章中可能包含哪些主题。LDA 模型不注重文章中词语的顺序，而是把文章看作一堆词语的集合，然后通过这些词语来分析主题。LDA 主题模型是由 Blei 等人在 2003 年提出的一种用来分析文档主题的模型[18]，它主要包含三个层次：文档、主题和词语。简单来说，就是通过分析文档中的词语，找出文档涉及的主题。以下是 LDA 模型算法的输入和输出，如表 2-1：

表 2-1 LDA 模型参数

Table 2-1 LDA Model Parameters

算法输入	需要分析的文章集 主题个数 K，超参数α、β
算法输出	文档中每个词的主题分类结果 每篇文章的主题概率分布 θ 每个主题下的词概率分布 Φ 词语 id 映射表 各个主题下词概率从高到底排序的主题特征词

由于获取的数据经过数据预处理之后，类似得到一篇文章，在这篇文章当中找到合适的主题以及找到主题下的特征词。LDA 生成文档的原理图如图 2-1 所示：

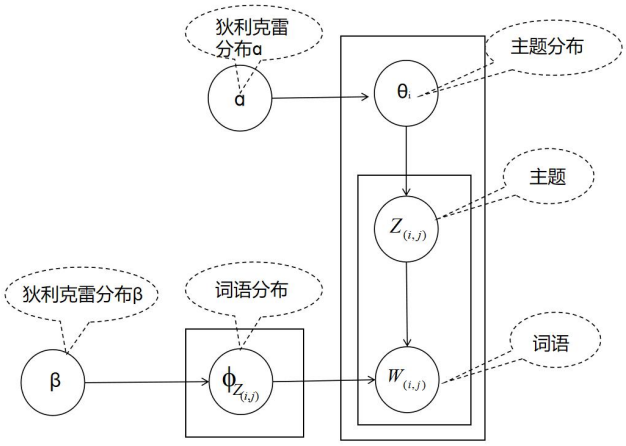

图 2-1 LDA 主题模型原理

Fig. 2-1 The Principle of LDA Topic Model

中国知网 https://www.cnki.net

由上图可知一共有两个狄利克雷分布，第一个狄利克雷分布α是通过对应的主题和文章联系起来，第二个狄利克雷分布β是通过对应的单词和主题联系起来。

在 LDA 中的两个狄利克雷分布分别是：文档对应的主题分布和主题对应的词汇分布。文档对应的主题分布由第一个狄利克雷分布参数α决定，α是一个向量，每个维度代表一个主题。主题对应的词汇分布由第二个狄利克雷分布参数β决定，β也是一个向量，每个维度代表一个词汇。狄利克雷分布的参数α和β是 LDA 模型的超参数，分别影响生成的主题分布和词汇分布。狄利克雷分布往往用在建模多项式分布的参数，它是一种多维概率分布，每个维度代表着一个类型或主题。

LDA 假设文档中的每个词汇都是从文档的主题分布中采样一个主题，然后从对应主题的词汇分布中采样一个词汇。此过程可以用上图的多项式分布θ_i和$\Phi z_{(i,j)}$来建模，其中每个主题的词汇分布表示为多项式分布的参数。多项式分布的参数由主题-词汇分布（狄利克雷分布中的β参数）控制，它表示了在每个主题中每个词汇出现的概率。所以生成文档的概率公式如下：

$$P(W,Z,\theta,\phi,\alpha,\beta)=\prod_{j=1}^{M}P(\theta_j;\alpha)\prod_{i=1}^{K}P(\phi_i;\beta)\prod_{t=1}^{N}P(Z_{j,t}\mid\theta_j)P(W_{j,t}\mid\phi_{z_{j,t}})\quad\cdots\text{式（2-4）}$$

2.4 数据预处理理论

2.4.1 数据去重

不同用户评论的文本内容各不相同，但是在实际的数据采集过程中，用户在不同的话题下重复发表相同或高度相似的评论，以及他们的评论中包含了多个相关的话题标签，这就可能导致我们在不同话题下采集到的评论数据存在重复现象。数据重复不仅增加了数据处理的复杂性，还对后续的数据分析产生影响。对数据进行去重操作非常必要。因为第一去重可以确保数据的准确性更高，避免因为重复数据而导致的分析偏差。第二过多重复的数据可能在训练模型中出现过拟合现象，面对新数据预测时预测结果往往不准确，所以过拟合现象降低了模型的准确性。数据清洗阶段利用 Python 当中的 drop_duplicates 函数对评论数据进行去重处理。经过删除数据集中重复行的操作，评论数据数据集会对训练模型的结果更加准确，同时也为接下来的数据分析和模型训练奠定了良好的数据基础。

2.4.2 数据去停用词

一句话的组成不仅有动词、名词、代词和语气助词等，评论的内容也含有一些没有含义的词汇——停用词，如“的”“是”“在”“有”等。虽然这些词汇是句

中国知网 https://www.cnki.net

子的组成部分，但是在数据分析层面属于无意义的词汇，所以在数据预处理阶段中，把这些停用词去除掉，可以提升数据分析质量。本次研究采纳了哈工大的停用词表作为基础，结合了本文话题的文本内容，对基础词表进行了针对性的增加、删除和修改，在提高数据准确性的同时，也为后面的分析数据打下了良好的数据基础。

2.4.3 正则表达式提取中文文本

在采集微博数据时，经常带有各种微博特有的特殊字符，如@、#等以及表情符号。微博评论中常包含回复或转发时附带的用户名，以及不必要的空格和空行。这些数据元素对于后续的数据建模和数据分析来说，通常被视为无效信息，对数据分析只有干扰。

在对微博评论内容进行数据预处理来提取中文文本时，通常采用的 Python 的 re 模块，这个模块的功能主要是识别无效的信息和各种特殊字符并剔除，在表达式编写方面要遵循正则表达式的匹配规则，正确的表达式对采集的数据进行精准的剔除和提取。这一方法不仅能够让数据集更加准确，也为后续的研究奠定了可靠的数据基础。

2.4.4 jieba 分词

识别一个句子的核心，需要将句子进行分词，分词的效果直接影响着文本分析的准确性。分词主要是保证句子的原有意思不变，按照一定的规则进行分词处理。为了提升文本分析的准确性，本文主要爬取的数据是中文文本，中文文本中的词语相互关联，停顿用标点符号进行隔开。为了更好地理解和分析数据，本文采用的是 jieba 分词，通过使用 jieba 分词提供的 jieba.cut 函数，实现中文文本的分词处理。分词处理可以帮助理解文本的信息，还为为后续的数据分析提供可靠的数据基础。

2.5 本章小结

本章节主要介绍了本文研究过程当中用到的一些相关的理论的方法。首先在数据获取上是采用的爬虫的技术，2.1 主要介绍了网页的元素介绍、爬虫的基本流程和设计爬虫程序等内容；其次在情感分析上采用的是 Snownlp 技术，2.2 主要介绍了目前情感分析运用的方法，重点介绍了本文使用的 Snownlp 技术的基本原理。然后在主题分类使用的是 LDA 主题模型，2.3 主要介绍了 LDA 主题模型的原理、算法的输入输出。最后是 2.4 主要介绍了在数据预处理过程中的数据去重、去停用词、正则提取和 jieba 分词等操作，达到后续研究数据层面的准确性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 3 章 网络舆情阶段性演化分析

3.1 数据文本的选取

本文采集数据的自然灾害事件聚焦于与台风“杜苏芮”和“台风海葵”紧密相关的两个自然灾害事件。首先本文主要采集了“杜苏芮”、“门头沟暴雨”和“涿州暴雨”等关键词的微博博文及其对应的评论。成功获取了 33977 条相关数据，其中通过“杜苏芮”关键词爬取到的评论数量为 25974 条，通过“门头沟暴雨”关键词采集到的评论为 4404 条，而“涿州暴雨”关键词下的评论则达到了 3599 条。考虑到杜苏芮时间的发生周期，数据采集的时间从 2023 年 7 月至 12 月，通过对初步获取的数据进行了时间范围筛选，确保数据的时效性和相关性，最终得到了 33553 条有效数据。

在“台风海葵”事件中，我们通过“台风海葵”关键词在微博上进行针对性爬取。成功获取了 20379 条微博数据，其中微博博文达到了 9656 条，微博评论采集了 10723 条。在数据采集的内容中包括了评论者的昵称、网址、评论日期和评论内容。这两万多条的数据既反映了民众对此次台风海葵的关注，也获得了丰富的公众意见。我们把收集到的数据都保存为 csv 文件，以便后续分析。这些数据不仅能帮助我们更深入地了解公众对自然灾害事件中观点和需求，而且也可以及时找到舆论的焦点。爬取内容的格式示例如下表 3-1，表头展示了爬取内容的属性，表格内容则是信息内容。

中国知网 https://www.cnki.net

表 3-1 爬虫数据示例

Table 3-1 crawler data examples

screen_name	profile_image_url	location	created_time	text
颖忆兮_	https://tvax3.sinaimg.cn/crop.0.0.1080.1080.50/006yNgsNly8hgbj67mq40j30u00u0ta3.jpg?KID=imgbed,tva&Expires=1692627497&ssig=aV%2Fa2mpWOP	天津 津南区	2023 年 8 月 20 日	按照我们的说法就是下冒烟了，天津刚刚也这样
微博视频	https://tvax2.sinaimg.cn/crop.0.0.749.749.50/005EY2yCly8h8va834rdij60kt0kt0tb02.jpg?KID=imgbed,tva&Expires=1692627497&ssig=%2FTZbUwe5AZ	北京	2023 年 8 月 20 日	您好，恭喜您的视频荣登视频飙升榜，社会领域第 13 名，榜单小时级更新请尽快查看哦~快来查看分享你的上榜视频吧~榜单戳》http://t.cn/A6OPXNSS
易假酒的喵三岁	https://tvax1.sinaimg.cn/crop.0.0.664.664.50/006zwZqSly8h9604zvm30j30ig0igaax.jpg?KID=imgbed,tva&Expires=1692627497&ssig=zU0N6lxSmL	海外 俄罗斯	2023 年 8 月 20 日	北京的 bee 注意天气

中国知网 https://www.cnki.net

3.2 台风杜苏芮网络舆情阶段划分

Python 当中有很多绘图工具，将绘图工具导入并调用就可以创建各种图形，也经常用于数据可视化。Matplotlib 就是其中一个绘图库，类似于 Matlab 的画图效果，也常与其他的数组库 Numpy、数据处理库 Pandas 结合用于数据分析。Matplotlib 画图工具可以将线的形状、颜色、直线/虚线进行自由组合绘制出不同的图形，比如折线图、散点图、柱状图等。图像的的构成包含三个层次，一是能够表示数的单个数轴 x 轴或 y 轴，通常数轴上包含了刻度的标注。二是 x 轴和 y 轴共同组合成坐标系，包含了 x 轴和 y 轴的标注、图形标题、参考线等。三是整个图形的展示，可以包含多个坐标系，可以调整坐标系在图中的位置。画图的基本流程是导入画图包、设置画图风格、自定义常用的参数（如字体颜色大小，图形的大小）。

由于自然灾害事件每到一个时间段网民关注程度不一样，为了能够直观的展现整个周期公众的关注程度，使用了上述 Python 中的 Matplotlib 方法绘制了网络舆情趋势图，如图 3-1。以横轴为时间，竖轴为评论的数量，评论的数量越多代表着公众对台风海葵的关注越大。该图中详细展示了网络舆情的产生到结束的变化过程。最初是台风还未登陆，公众还没过多关注，所以评论数量比较少。但是台风瞬间登陆并且带来的影响巨大，公众以及媒体都对此次自然灾害事件非常关注，灾后政府相关部门及时采取救援措施解救被困群众，公众关注的内容才得以解决，微博对此次事件的热度才有所减退。但是台风还没完全退下，所以公众的讨论一直在波动，直到台风事件完全过去，评论数量才趋于平稳。

根据网络舆情图，可知“杜苏芮”、“门头沟暴雨”及“涿州暴雨”等相关话题在网络上的讨论热度持续了整整 123 天。在 7 月 1 日至 7 月 17 日之间，网络评论数量相对较少，讨论热度偏低，反映了“杜苏芮”还没给公众带来明显的负面影响。尽管媒体可能开始了初步报道，新闻和气象台也发出了防护预警等信息，但报道的数量和覆盖面相对有限。根据网络舆情的特点，将这一阶段归为网络舆情的潜伏期。

然而，到了 7 月 18 日，网络评论数量突然激增，舆情事件或话题迅速成为公众关注的焦点。媒体报道的数量也随之大幅增加，社交媒体上的讨论热度空前高涨。公众对舆情事件或话题的看法开始汇聚，媒体也展开了更为深入的报道和分析。其中 7 月 22 日以及 7 月 28 日至 29 日，微博评论数量达到了多峰形态的顶峰。这主要是因为 2023 年第 5 号台风“杜苏芮”预计在 27 日进入南海东北地区，并且 28 日早上到上午在福建中部地区到广东东部一带沿海登陆。受其残余云系外围环流的影响，7 月 31 日局部地区出现了中等雷阵雨，给人民群众带来了极大的影响，从而激发了

中国知网 https://www.cnki.net

公众在网络上的热烈讨论，舆情事件或话题的舆论场正式形成。因此，7 月 18 日至 8 月 7 日被视为网络舆情的形成期阶段。

从 8 月 8 日开始至 8 月 31 日，网络舆情评论数呈现出波浪曲线的态势。公众的情绪开始调整，部分观点逐渐收敛，社交媒体上的讨论热度也略有下降，公众的情绪、观点和立场趋于稳定。与此同时，媒体报道的数量也有所减少，但仍保持了一定的关注度。这一阶段，我们称之为舆情的波动期。

进入 9 月 1 日之后，舆情评论数量逐渐减少，直至 10 月 31 日，网络舆情步入了衰退期。尽管下降过程并非直线式，但总体来看，增长与减少之间的差距已不再显著，舆情事件或话题的影响逐渐消退，社交媒体上几乎不再有相关讨论。

综上所述，本次舆情的演变过程可清晰地划分为以下四个时期，如表 3-2 所示：

表 3-2 杜苏芮网络舆情划分阶段

Table 3-2 Division stages of Dussuri's network public opinion

舆情阶段	时间周期
舆情潜伏期	2023 年 7 月 1 日到 2023 年 7 月 17 日
舆情形成期	2023 年 7 月 18 到 2023 年 8 月 7 日
舆情波动期	2023 年 8 月 8 日到 2023 年 8 月 31 日
舆情衰退期	2023 年 9 月 1 日到 2023 年 10 月 31 日

中国知网 https://www.cnki.net

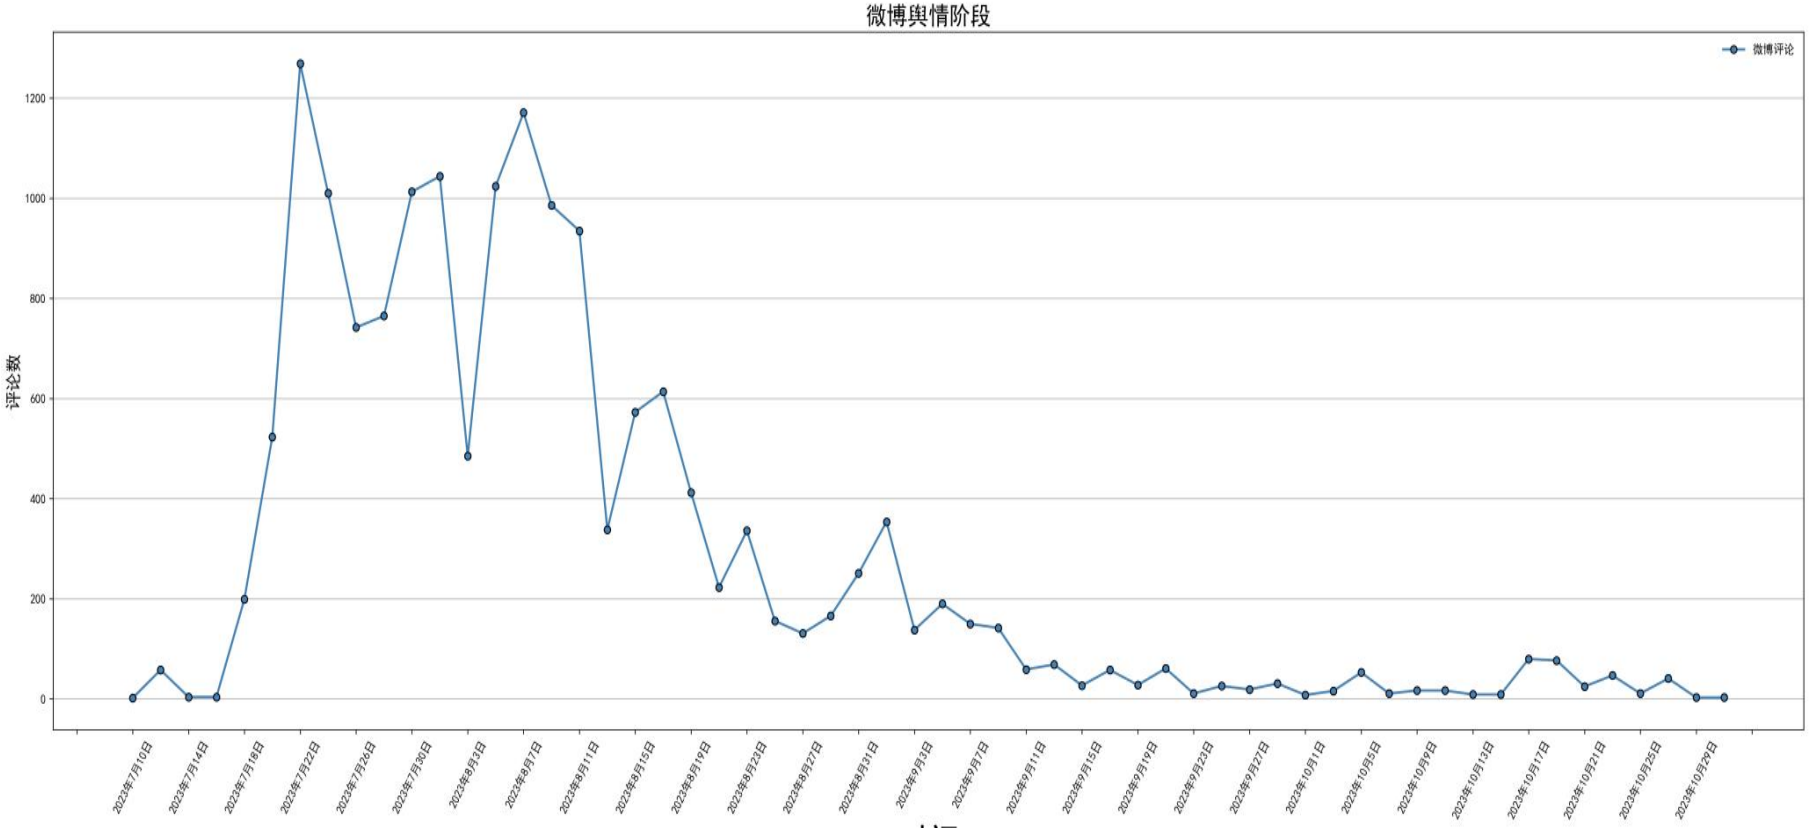

图 3-1 杜苏芮网络舆情趋势图

Fig.3-1 Network public opinion trend chart of Du Suri

中国知网 https://www.cnki.net

3.3 台风海葵网络舆情阶段划分

根据应急管理部正式发布的2023年度十大自然灾害报告中的台风海葵事件，本文从微博这一社交平台爬取了与“台风海葵”相关话题的博文和评论数据。在获取了这些原始数据后，我们依据台风海葵的实际发生和发展周期，进行了详细的筛选与整理，确保所采纳的数据真实有效，能够准确反映公众的关注动态。基于筛选后的有效数据，绘制了一张时间趋势图，以直观展现台风海葵网络舆情的演变过程，如下图3-2所示。这张趋势图中，横轴是以时间为单位，从2023年7月到11月；而竖轴则表示微博评论的数量，数量的高低直观的反映了公众对此次灾害事件话题关度的严重程度。

根据台风海葵的网络舆情趋势图，“台风海葵”话题在微博上的讨论共计123天。在7月26日至8月23日这一阶段的文本内容，大多数是媒体发出的微博博文和气象台发布的相关防护预警信息，平时公众也没有太多关注这些媒体，这一阶段视为网络舆情的潜伏期，暗示着舆网络舆情即将发生。台风海葵公众了解的信息量相对缺乏，网络话题可能刚在网络平台上出现，讨论热度也维持在较低水平，没有引起大众的大量的关注。这无疑在说明“台风海葵”在这一阶段没有对公众产生严重的的直接影响。

在8月24日这一天，网络评论数量猛然激增，将一个舆情事件或热门话题迅速推向了公众视野的核心。随之而来的是媒体报道数量的急剧攀升，社交媒体上的讨论热度更是达到了前所未有的高度。公众对于这一舆情事件或话题的看法开始迅速汇聚，形成了一股强大的舆论力量。媒体也不甘落后，纷纷展开了更为详尽深入的报道与分析。最重要的是8月29日与9月12日这两天，微博评论数量攀升至顶峰，形成了两个鲜明的舆论高峰。以2023年第11号台风“海葵”为例，9月3日下午，它以强台风级别强势登陆中国台湾省台东市沿海，对中国台湾、福建、广东等地造成了极其严重的影响，多地遭遇了破纪录的极端暴雨。这一自然灾害无疑激发了公众在网络上的热烈讨论，舆情事件或话题的舆论场就此正式形成。因此，从8月24日至9月12日这一时段，被视为网络舆情的形成期阶段。

9月12日到13日之间，评论数量出现了明显的降低。9月13日至10月8日在下降中伴有上升波动的趋势，这一阶段称为舆情的波动期。微博上的热点话题的讨论也有所减退，公众情绪已经进入自我调节的环节，一些有热度的观点也在政府媒体下得以解决，整体的情绪状态、观点表达和立场取向趋向于一个更为平稳的状态。同时媒体报道的频率虽有所减少，但一直保持着一定的社会关注度。

从10月9日至11月25日，舆情评论数量逐渐递减并趋于平稳，标志着网络舆情正式步入了衰退期。舆情事件或话题的影响力已完全消散，公众关注度跌落至谷底，相关讨论近乎销声匿迹。

综上所述，本次舆情的演变过程可清晰地划分为以下四个时期，如下表3-3

中国知网 https://www.cnki.net

所示：

表 3-3 台风海葵网络舆情阶段划分

Table 3-3 the typhoon sea anemones stage of network public opinion

舆情阶段	时间周期
舆情潜伏期	2023 年 7 月 1 日到 2023 年 7 月 17 日
舆情形成期	2023 年 8 月 24 到 2023 年 9 月 12 日
舆情波动期	2023 年 9 月 13 日到 2023 年 10 月 8 日
舆情衰退期	2023 年 10 月 9 日到 2023 年 11 月 25 日

3.4 本章小结

本章节主要是对台风网络舆情阶段进行划分。首先交代了数据集的来源以及爬取数据的格式；其次是介绍了绘制网络舆情趋势图的工具，主要介绍了 Matplotlib 工具包的使用方法和画图的基本流程；然后对台风杜苏芮、台风海葵的网络舆情图进行分析，可以观察到整个事件的发生周期，根据网民的评论数量推断网络舆情各个阶段，共分为四个阶段：网络舆情潜伏期、形成期、波动期和衰退期。

中国知网 https://www.cnki.net

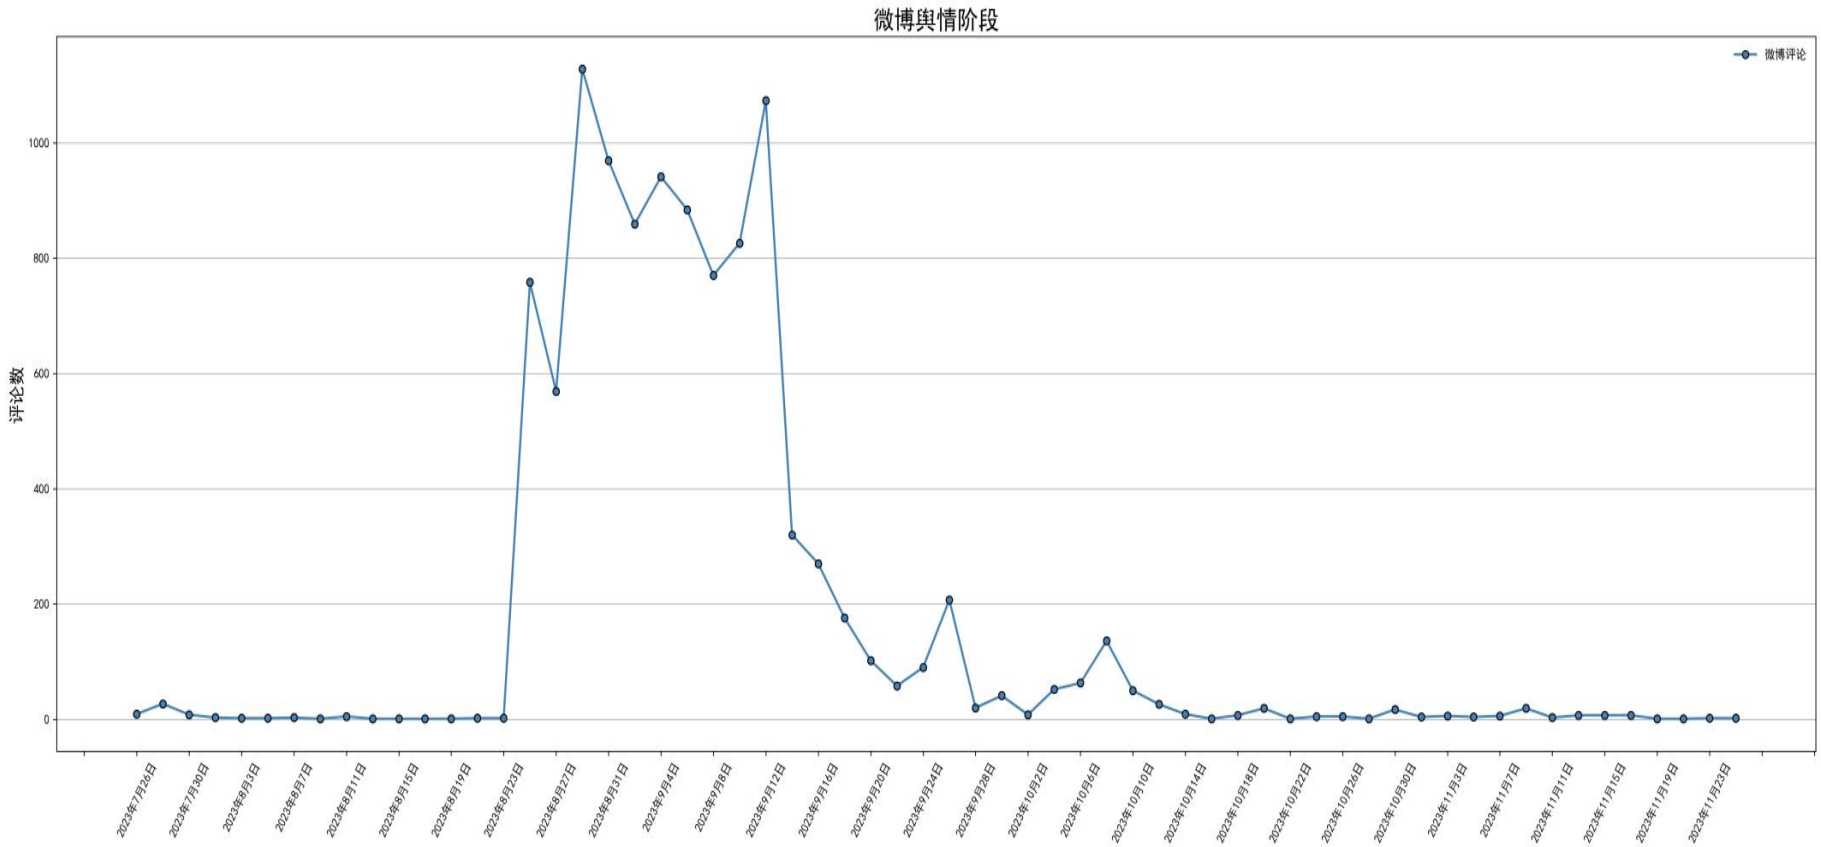

图 3-2 台风海葵网络舆情趋势图

Fig.3-2 Typhoon Haikui network public opinion trend chart

中国知网 https://www.cnki.net

第 4 章 情感语料库的构建以及情感分析

4.1 网络情感语料库的构建

4.1.1 Snownlp 情感分析技术

Snownlp 是一个基于 Python 的自然语言处理库，具有中文分词、词性标注、情感分析、文本分类等功能。它提供了预训练的情感分析模型，用户也可以使用自己的数据进行训练。Snownlp 的情感分析功能基于朴素贝叶斯分类器，通过训练数据学习文本特征与情感类别之间的关系，计算文本的情感概率。情感分析的结果是一个概率值，表示文本属于积极或消极情感的可能性，分值在[0，1]之间，趋于 1 表示积极情感，趋于 0 表示消极情感。Snownlp 可以应用于电商评论的情感分析，也可以根据自己研究的数据进行训练模型适用于研究领域，但其效果可能会受到训练数据领域适应性的影响。

4.1.2 构建台风灾害的情感语料库

虽然 Python 中的 Snownlp 具备多种功能，专门用于中文文本情感分析，文本情感值在 0 到 1 之间，以 0.5 为界，数值越趋近于 0，表明文本情感归为消极；而越接近 1，则情感归为积极。但是 Snownlp 库中自带的 pos.txt 和 neg.txt 语料库主要基于电商评论构建，因此在处理购物商品类领域的文本时，其情感分析表现效果很好。然而当将这一工具应用于本研究中的微博舆情样本时，发现微博自然灾害舆情文本与电商类的文本差别较大。为了提高对自然灾害网络舆情文本的情感分析的准确率，本文对 Snownlp 的情感语料库进行必要的补充，如图 4-1 所示。

中国知网 https://www.cnki.net

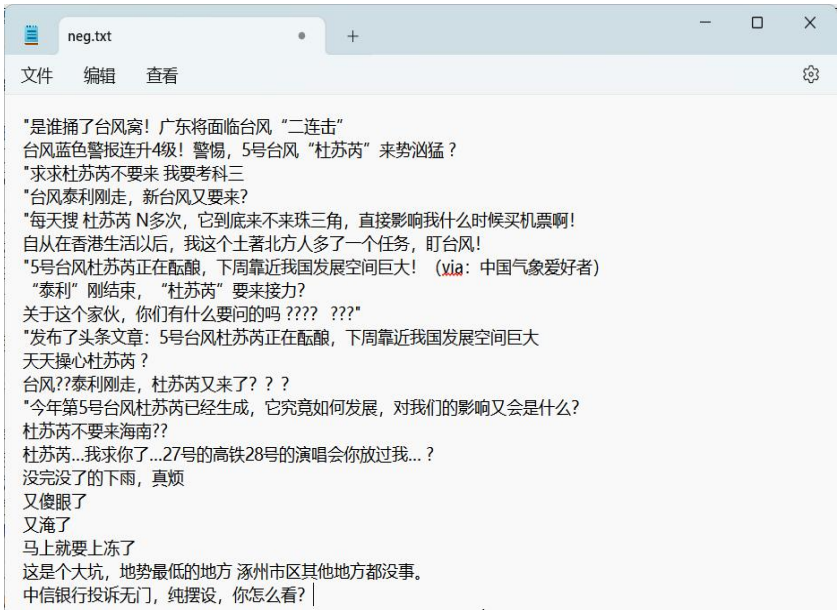

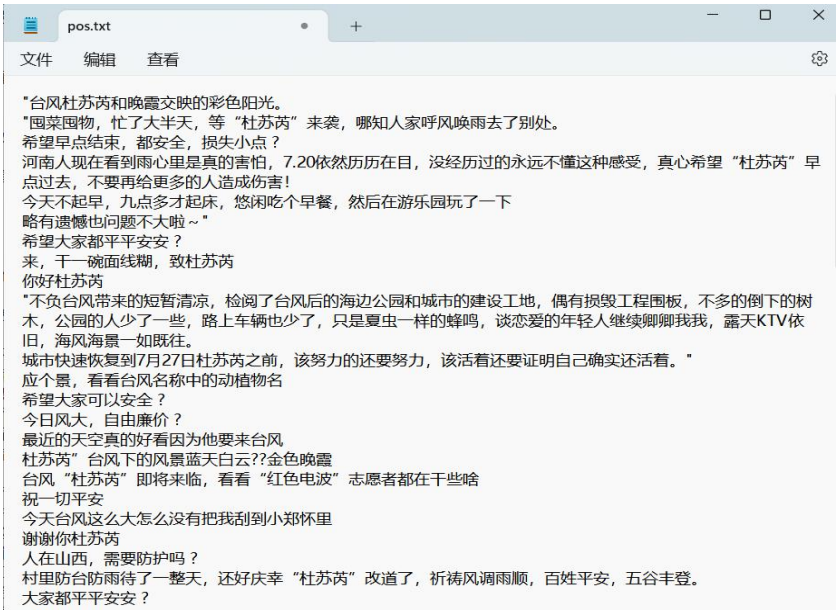

图 4-1 台风情感语料库的构建

Fig.4-1 Construction of typhoon emotion corpus

在实际操作中，根据本文的研究数据需要重新训练模型，首先需要对部分数据进行情感标记，积极情感的文本标记为“1”，消极情感的文本负向标记为“0”。经过这些文本数据的训练会生成新的 marshal 模型，需要到 python 环境中的 site-package 库里把 Snownlp 的 sentiment 原始的 mershal.3 模型文件替换掉。

中国知网 https://www.cnki.net

4.2 情感分析结果

4.2.1 台风杜苏芮网络舆情的情感分析结果

（1）整体情感属性布局

根据台风杜苏芮整体的情感趋向，详细分为了两类，积极和消极占比如图 4-2 所示。积极情感的文本内容共有 34322 条数据，比例占据非常大。消极情感的文本内容共计 10857 条数据，比例占据较少。单从数据层面来看，积极文本数据是消极文本数据的将近 3 倍。

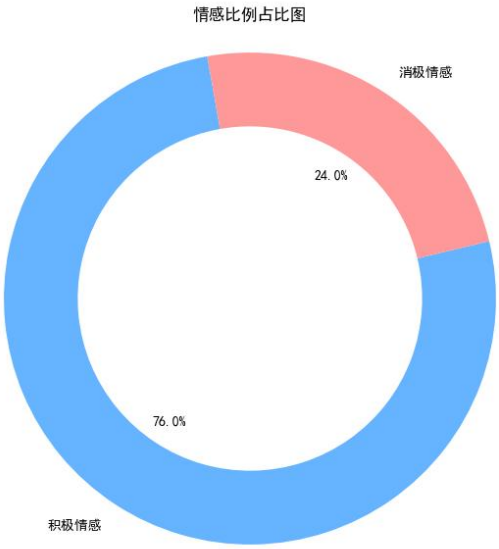

图 4-2 情感占比图

Fig. 4-2 Emotion proportion chart

（2）台风杜苏芮网络舆情的积极词云图分析

根据本文研究的 Snownlp 模型，精准地计算出每一条微博评论所蕴含的情感分值。根据情感值范围：情感值在 0.5-1 之间的归为积极文本，并据此绘制出积极词云图（见图 4-3）。

中国知网 https://www.cnki.net

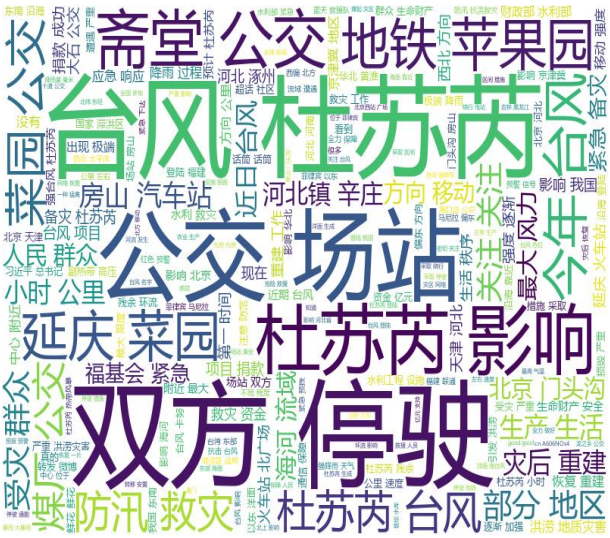

图 4-3 台风杜苏芮积极词云图

Fig.4-3 Typhoon Dusuri positive word cloud image

词云图作为一种高效的数据可视化工具，能够依据词汇的密集程度和分布特点，直观且精确地展现两类文本的主题焦点和情感倾向。在积极文本的词云图中，主题词“杜苏芮”处于显眼的地位，直观的表明了文本的核心议题——“杜苏芮”事件所带来的影响。同时，我们还可以看到“救灾”、“重建”、“防汛”、“公交”、“地铁”等词汇占据了显著位置，这些词汇不仅出现频率高，而且相互关联，一起呈现了灾害发生后政府和社会的积极救灾行动和保障交通顺利运行，同时在积极文本中表现出了公众对政府和社会灾后重建的期待和一直抱有对灾后重建的乐观心态。比如“防汛、救灾、杜苏芮”等词汇直接反映了政府对台风杜苏芮的救灾行动，相关部门和地区为了保障人民的生产财产安全，正在积极行动来减少自然灾害带来的负面影响。“公交、地铁、苹果园”等词汇表示的是地理位置站点，可能由于暴雨天气，对公共交通设施造成了一定的破坏，影响了人民的正常出行，但是政府相关部门积极的采取有关措施减少出行的不便，修复交通设施。从积极文本的词云图中的关键词几乎可以完整的体现出灾害的发生、灾害对社会和群众的影响和及时参加救灾活动中。

（3）台风杜苏芮网络舆情的消极词云图分析

借助了适合本文研究的 Snownlp 模型，精准地计算出每一条微博评论所蕴含的情感分值。根据情感值范围：情感值在 0-0.5 之间的归为消极文本，并据此绘制出消极词云图（见图 4-4）。

中国知网 https://www.cnki.net

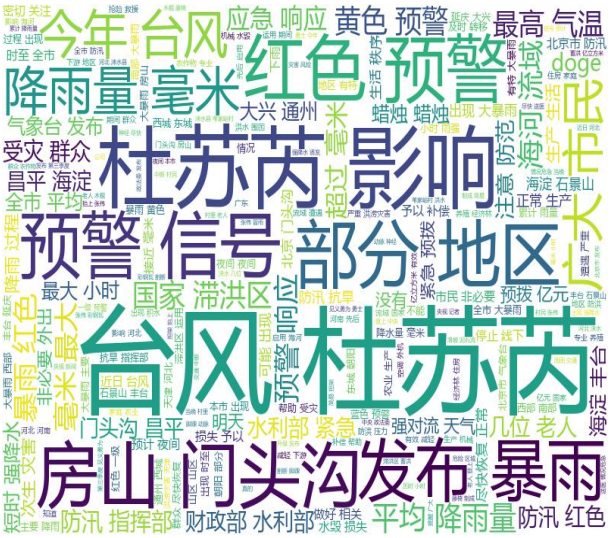

图 4-4 台风杜苏芮消极词云图

Fig.4-4 Negative word cloud image of Typhoon Dusuri

在消极文本的词云图中，“台风、杜苏芮、影响”直接点明了消极文本的主题，几乎围绕着杜苏芮事件带来的影响而展开，同时也充斥着负面的情感。“房山、门头沟、暴雨”等词汇反映了暴雨的受灾地区处于北京房山、门头沟地区，也间接反映了这两个地区极易受灾，需要重点关注。“预警、信号”等词汇表示对灾害的发生发出警示，代表即将会有风险，提醒着公众时刻保持高度的警觉。“降雨量、毫米”表示暴雨的强度，通过降雨量来判断降雨等级。“防汛、红色”等词汇似乎反映着灾害防汛的等级，红色代表着特别严重。“昌平、海淀、门头沟”等北京地名的出现，更加确定了北京这些区域受到暴雨的冲击。

通过积极文本词云图和消极文本词云图的分析，可以发现积极文本词云图关注救灾行动，虽然也体现了暴雨带来的影响，但讨论最多的是政府相关部门的救灾救援行动，因此情感也趋于积极正向。而消极文本更加强调灾害暴雨带来的负面影响，对于这些负面影响公众体现出一种消极负向的情感情绪。这两张词云图的主题关键词都是杜苏芮事件，但是公众关注的内容不同而展现的情感有不同。分析结果不仅可以了解公众关注的核心内容，还可以了解公众的情感趋势。

4.2.2 台风海葵网络舆情的情感分析结果

（1）整体情感属性布局

利用 Python 中的绘图工具 Matplotlib 将台风海葵的情感趋向分为两类，如图 4-5 所示。筛选有效数据中积极情感的有 14649 条，消极情感的有 5725 条。积极情感几

中国知网 https://www.cnki.net

乎是消极情感的 2.5 倍。

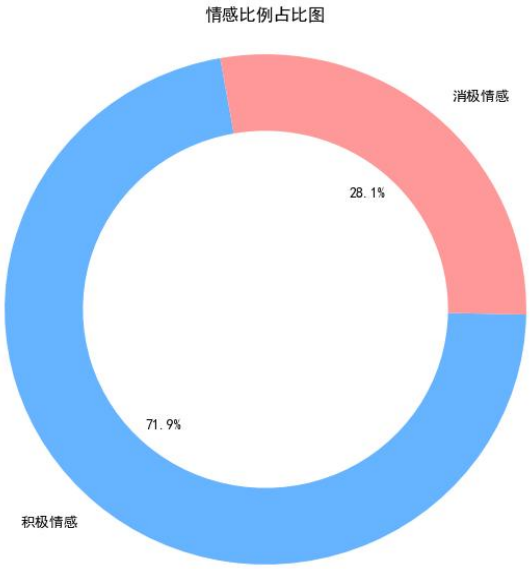

图 4-5 情感占比图

Fig.4-5 Emotion proportion chart

（2）台风杜苏芮网络舆情的积极词云图分析

在情感划分上，借助 Snownlp 模型，准确地计算出每一条微博评论所蕴含的情感分值。根据情感值范围，将文本分为两类：情感值在 0.5-1 之间的归为积极文本，并据此绘制出积极词云图（见图 4-6）。

图 4-6 台风海葵积极词云图

Fig.4-6 Positive word cloud of Typhoon Haikui

中国知网 https://www.cnki.net

积极词云图中最明显的词汇是“台风海葵”与“影响”，这两个词汇反映了微博话题讨论的核心——自然灾害台风海葵这一事件带来的影响。从“通信”、“网络”、“保障”等关键词中，暗示了在自然灾害面前通信发生了故障，相关部门立即采取行动，争取在在短时间内保障通信网络正常运行，维护人民的日常通信，体现了国家对民生需求的及时响应。“季风”“西北太平洋”“残涡”“沿海登陆”等专业词汇映射了台风海葵的形成的情况和经过途径，对了解台风海葵的去向有巨大的帮助。“突破历史极值”和“大暴雨”等关键词形象描述了台风海葵的极端强度和会造成巨大的影响，强调了此次自然灾害的严重性。“关注”多次出现，强调了政府、社会对自然灾害的普遍关切，还体现了公众对此次灾害事件的广泛关注。“受损”“保障工作”“转移群众”等关键词，形象地反映了在面对灾害发生产生的损坏，政府、社会立刻开启应急响应机制，对受损设施修复全力开展和转移群众并安置工作。

词云图中除了上述的关键词，更能体现积极的因素有“迅速行动”“应急响应”“快速恢复”等救灾关键词，体现了政府有关部门高效而有序的救灾行动，他们具有坚定不移的决心和卓越的能力，以最快的速度恢复生活的平静与秩序。在救灾过程中，还有“联通”“移动”等通信企业积极履行社会责任，保障日常通信顺利运行，为救灾工作提供了坚实的网络信息支撑。从社会到企业，再到每一位群众，都展现出了团结协作、全力应对灾害的宝贵精神。

（3）台风杜苏芮网络舆情的消极词云图分析

借助 Snownlp 模型，精准地计算出每一条微博评论所蕴含的情感分值。根据情感值范围情感值在 0~0.5 之间的归为消极文本，并据此绘制出消极词云图（见图 4-7）。

图 4-7 台风海葵消极词云图

Fig.4-7 Negative word cloud of Typhoon Haikui

中国知网 https://www.cnki.net

从消极词云图中，最明显的关键字眼是“台风海葵”“台风苏拉”与“台风达维”，这三个台风的同时出现，不仅极大地提升了公众的关注度，使事件的发展形势更加关注，同时也深刻地揭示了台风灾害风险的严峻性。

“蜡烛”这个词汇的多次出现，暗示着人们的生活遭受到停电的现象，使用蜡烛照明，反映了自然灾害对日常生活秩序的严重干扰，给民众带来了诸多不便。而“沿海靠近”就像告诉我们台风正在向沿海地区逼近，向公众发出紧急预警，受灾的风险等级再次升级。“附近、中心、最大风力”等词汇的出现，表示台风的惊人的强度，还有可能对附近周边的树木、设施造成巨大的破坏，甚至会危及到人民的生命安全。同时“海水、回灌、山体、滑坡”等词汇表示由台风产生的次生灾害具有多样性，例如，海水回流引发的低地区域泛滥成灾，以及山体塌方对自然环境的重大损害。“残余环流、残涡”这些专业术语是对台风衰退后剩余能量的专业描述，残余的能量极有可能对附近地区产生持续的困扰和威胁。几乎所有词汇都与台风相关并且由台风可能引发的负面效应也被展开，浓厚的忧虑氛围被整个消极词云图所充满着。一方面，自然灾害的频率通过多个台风词汇的叠加在图中被凸显出来，暗示着台风活动的频繁性；另一方面，日常生活的不便、环境的破坏和设计到生命安全的威胁，都是台风带来的影响，显示出其影响范围的广泛性。

在积极词云图中的分析可知，公众对自然灾害台风“海葵”带来负面影响非常关注，而且政府相关部门能够依据公众关注的内容及时采取应对措施并解决问题，比如保障灾害中的通信正常运行、有效的转移受灾群众和社会企业的共同团结合作共同应对自然灾害。但在消极词云图的分析可知，大多围绕着台风海葵给社会、人民带来的影响，比如人员伤亡、设备损坏、台风残余影响、环境破坏等。同时也能够让公众意识到自然灾害的严重性，在遇到自然灾害前，需要关注官方媒体报道的灾情情况，提前做好准备。

4.3 本章小结

本章节的主要工作是对台风杜苏芮和海葵的文本数据进行情感分类：积极和消极。首先介绍了 Snownlp 技术和使用范围局限；其次在 Snownlp 自带的情感语料库补充了本文研究领域的情感语料词汇，通过人工标记的数据进行训练，达到适合本文研究的模型效果；然后主要介绍了台风杜苏芮和海葵的情感分析结果，主要包括了整体的情感倾向布局，绘制了积极和消极的词云图，从词云图当中分析积极和消极文本下公众所关注的内容，最后进行积极文本和消极文本的关注内容的对比。

中国知网 https://www.cnki.net

第 5 章 结合情感分类的主题提取及分析

5.1 LDA 主题模型分析

5.1.1 LDA 主题模型的构建

LDA 是一种无监督学习的文本主题分类方法，不仅可以从多个文档集合中提取潜在的主题，还能生成文档-主题分布和主题-词语分布。LDA 主题模型的构建通常基于 Gensim 和 Sklearn 模块，其中 Gensim 更适合大规模数据，而 Sklearn 易于与其他机器学习工具结合而实用性强。本文的研究数据属于中小规模数据集，选择 Sklearn 模块构建 LDA 模型已经满足需求。在构建 LDA 模型之前，我们对文本数据进行了预处理。首先使用正则表达式去除不相干的符号和词汇，然后使用 Sklearn 的 CountVectorizer 方法对文本数据进行特征提取，同时还设置了提取特征词语数量 3000、去英文停用词等参数提高模型效果，最终生成的文档-词语矩阵。在处理后的文档-词语矩阵的基础上，使用 Sklearn 的 LatentDirichletAllocation 类构建 LDA 模型，在训练 LDA 模型时，通过调整模型的主要参数，如以下列表 5-1，本文在训练模型时对其中一部分参数进行设置，比如 max_iter 设置了 50，learning_method 设置 batch 等。

表 5-1 LDA 模型训练参数

Table 5-1 LDA model training parameters

参数	含义
n_topics	设置的主题个数
doc_topic_prior	控制文档-主题的参数α
topic_word_prior	控制主题-词语的参数β
learning_method	LDA 主题模型的算法，有 batch 和 online，一般数据小用于训练选 batch
learning_decay	前提选择 online 使用该参数，取值范围在 0. 5 到 1 之间，默认 0. 7
learning_offset	前提选择 online 使用该参数，取值比 1 大
max_iter	最大迭代次数

中国知网 https://www.cnki.net

参数	含义
total_samples	前提选择 online 使用该参数，在使用 partial_fit 函数时需要，分步训练时每一批文档样本的数量
batch_size	前提选择 online 使用该参数，每次算法迭代时使用的文档样本的数量。

5.1.2 LDA 主题模型评估标准

针对文本的主题进行挖掘分析，需要判断主题个数划分的效果好坏。首先评估 LDA 主题模型的常用方法是计算各个主题的困惑度。主题困惑度是经过训练之后，主题模型对文本的主题划分的效果，对于某个文档可能属于主题 A 也可能属于主题 B，这种不能确定性就是困惑度，不确定性越低代表主题划分效果越好，相当于主题困惑度越低越好，但是过低的主题困惑度会造成主题过拟合的现象。

困惑度的计算公式如下：

$$\text{perplexity}\ (D) = \exp\left(-\frac{\sum \log p\ (w)}{\sum_{d-1}^{M} N_d}\right) \quad \cdots\cdots\cdots\cdots\cdots\cdots \text{式（5-1）}$$

其中，分母是测试集中所有单词之和。p(w)指的是测试集中每个单词出现的概率，计算公式如下：

$$p(w) = p(z \mid d) * p(w \mid z) \quad \cdots\cdots\cdots\cdots\cdots\cdots \text{式（5-2）}$$

$p(z \mid d)$ 表示的是一个文档中每个主题出现的概率，就是程序中的.theta 文件，$p(w \mid z)$ 表示的是词典中的每一个单词在某个主题下出现的概率，就是程序中的.phi 文件。

其次也可以通过计算主题之间的距离实现主题可视化，可以观察到主题之间的距离和主题关键词。根据距离可以判断主题之间的联系，距离比较近甚至可能有重叠部分的主题，代表着主题之间的关联性强，具有相似性；距离比较远的主题，表示主题之间的语义差别大，主题之间相互独立。除此之外可以观察到主题当中 Top-30 的关键词，更加直观的理解主题的核心内容，也能根据主题的关键词判断数据处理方面的效果，若主题中的关键词几乎是无意义的词汇，代表数据处理层面没达到要求。最后判断主题模型的效果基本是根据合理结合这些指标来进行主题模型的评估。

（1）不同情感下的台风杜苏芮的主题模型

在积极文本下，主题个数在 1~10 的范围当中，对主题困惑度逐一进行计算，如图 5-1 所示。在主题困惑度图中，主题个数从 1 到 5 的主题困惑度数值逐渐下降，主题个数为 5 的主题分类效果最好。为了更加确定主题个数的确定，还结合了

中国知网 https://www.cnki.net

pyLDAvis 包对主题数量间距离进行了计算，如图 5-2 所示。从主题气泡图这一图当中可以观察到主题个数为 5 时，主题内容无重叠，再次确定了主题个数选择 5 最优。

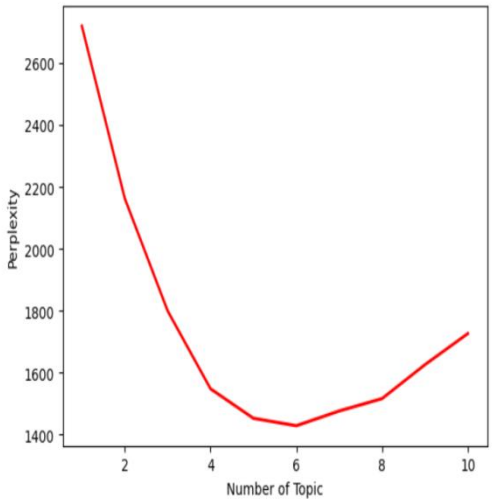

图 5-1 主题困惑度

Fig.5-1 Topic confusion

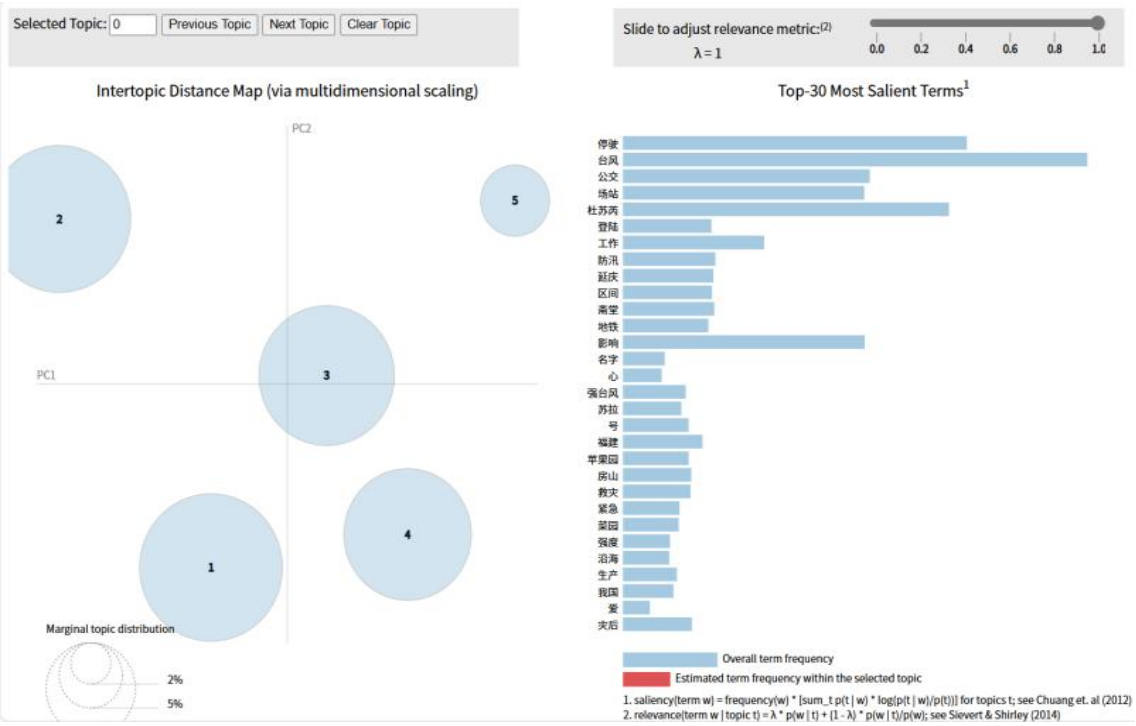

图 5-2 主题气泡图

Fig.5-2 Theme bubble diagram

针对消极文本进行主题挖掘时，也需要从主题困惑度和主题气泡图进行结合考虑，以下展示的是关于主题困惑度、主题气泡图的具体图表，如图 5-3，图 5-4。这

中国知网 https://www.cnki.net

些图所展示的内容能够对我们选择合适的主题数量有非常大的帮助，保障文本主题划分的准确性。从主题困惑度图中观察到主题个数从 1 到主题个数 5，主题困惑度的值越来越低，但是主题个数 5 以后主题困惑度的值稳步上升。结合主题气泡图，主题个数为 4 时，主题之间几乎没有重叠，所以选择主题个数为 4 时主题划分效果最好。

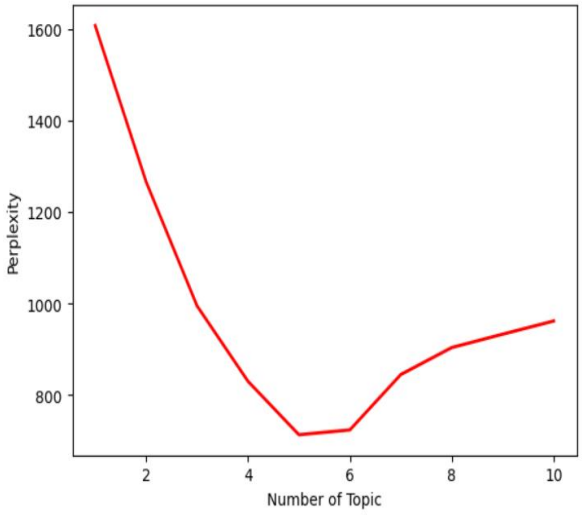

图 5-3 主题困惑度

Fig. 5-3 Topic confusion level

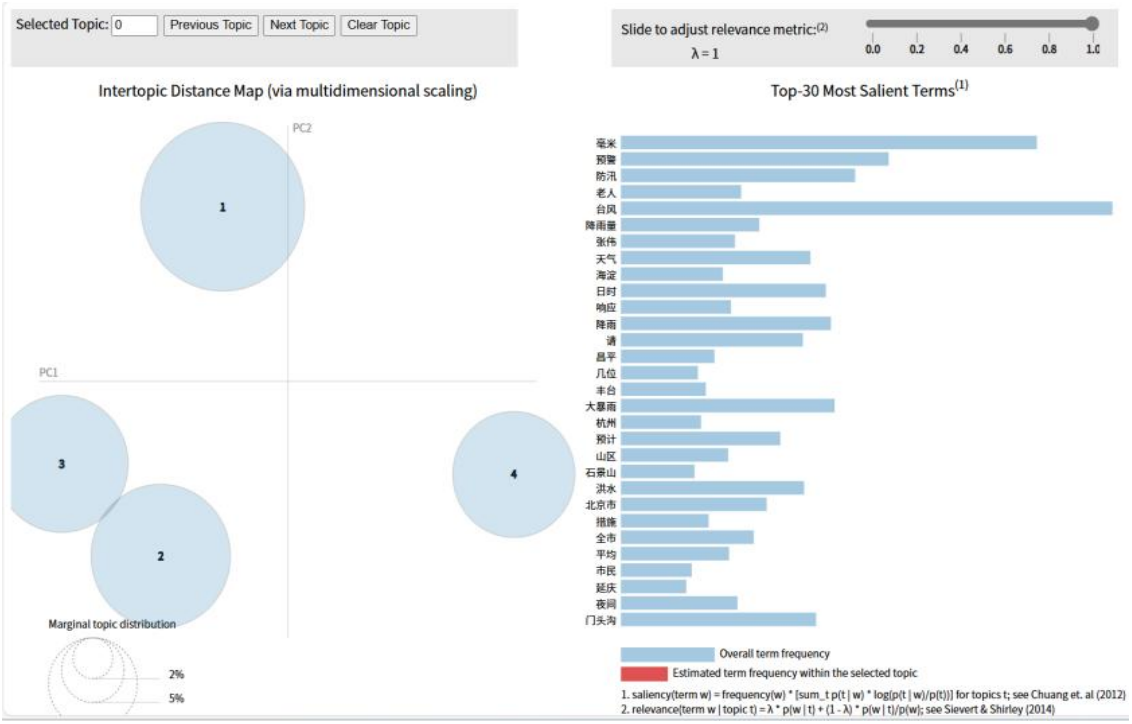

图 5-4 主题气泡图

Fig.5-4 Theme bubble diagram

（2）不同情感下的台风海葵的评估模型

中国知网 https://www.cnki.net

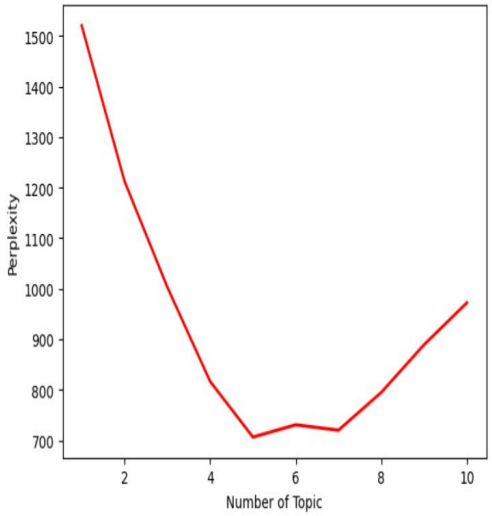

图 5-5 主题困惑度

Fig.5-5 Topic confusion level

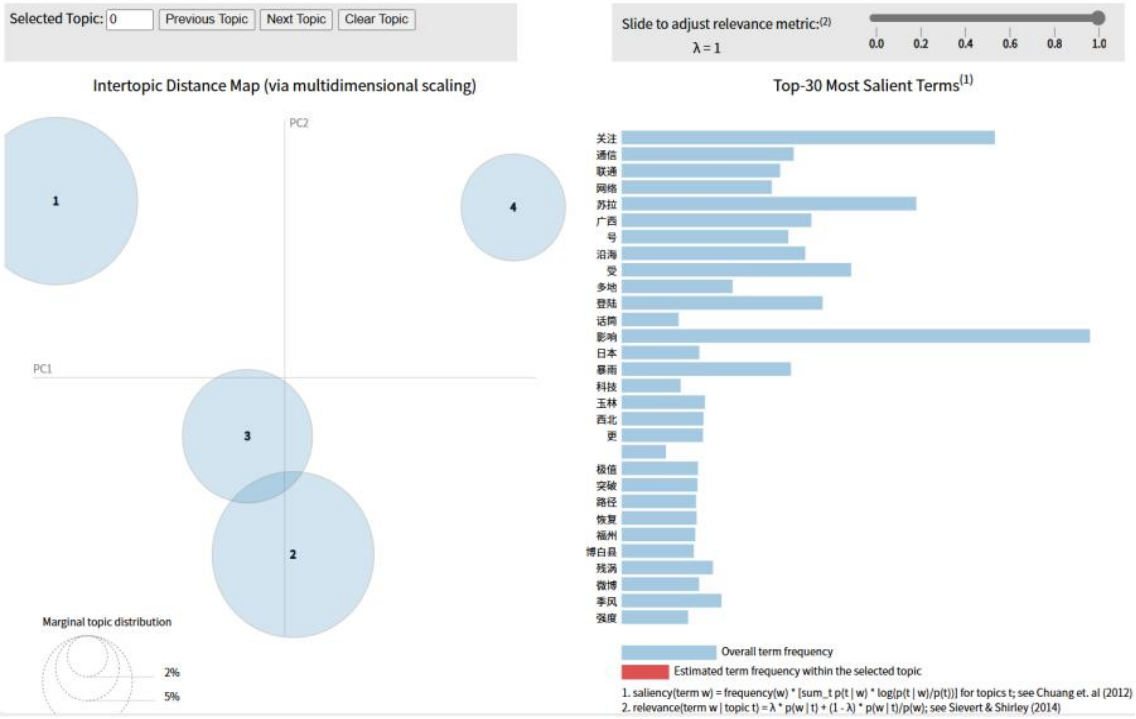

图 5-6 主题气泡图

Fig.5-6 Theme bubble diagram

情感分析已经把文本划分为积极和消极两类，从积极文本当中进行主题挖掘，主要先从主题困惑度和一致性得分的指标来考虑，如图 5-5。从主题困惑度的变化趋势来看，主题个数从 1 到 5，主题困惑度呈现下降的趋势，随着主题个数的增加，主题困惑度越来越低，代表主题划分的效果越好。但主题个数从 5 升到 6 时，困惑

中国知网 https://www.cnki.net

度稍有上升，主题个数从 6 到 7 困惑度又开始呈现下降的走势，主题个数从 7 之后一直呈现上升的趋势。根据主题困惑度的含义和变化趋势来看，主题个数选择主题 5 到 7 之间可能最为合适。为了选择效果更好的主题个数，我们还绘制了主题气泡图，如图 5-6。主题个数为 4 时主题部分重叠的最少，综合主题困惑度和一致性得分，最终选定主题个数为 4。

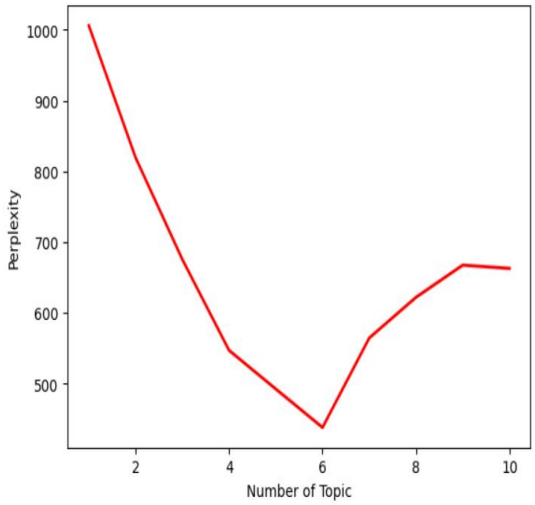

图 5-7 主题困惑度

Fig.5-7 Topic confusion level

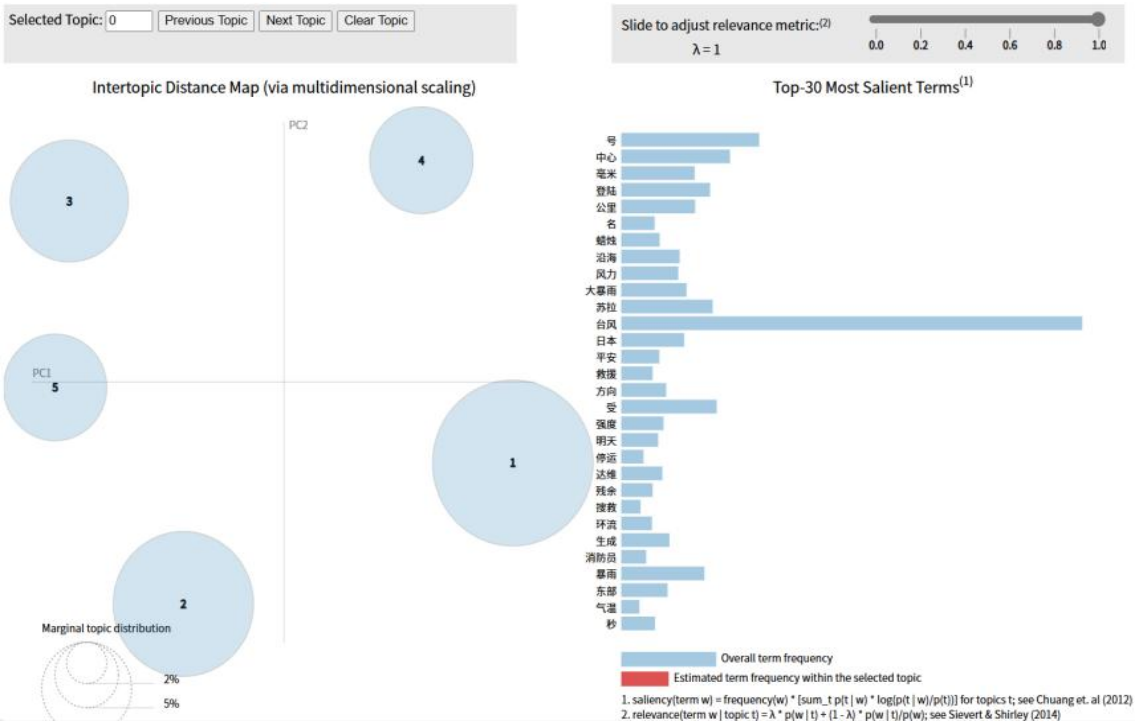

图 5-8 主题气泡图

Fig.5-8 Theme bubble diagram

接着是对消极文本进行主题挖掘，对主题个数的确定先依据主题困惑度指标，

中国知网 https://www.cnki.net

如图 5-7。从图中可以看到主题困惑度从主题个数 1 到主题个数 4，主题困惑度一直处于下降的趋势，但是从主题个数 4 到 6，下降速度有所减缓。在主题个数 6 以上，主题困惑度值持续上升。根据主题划分效果与主题困惑度指标的含义，主题困惑度越低代表主题分类效果越好，但是过低会造成过拟合现象，所以主题个数选择在 4 到 6 之间最为合适。在主题个数 4 到 6 之间的文本进行进一步观察。通过主题气泡图，如图 5-8。我们可以直观地看到，在这三个主题中，主题个数 5 的散点分布最为集中且没有重叠，这表明主题个数 5 下的文本内容最为清晰、聚焦且一致。

5.2 主题提取结果

5.2.1 不同情感下台风杜苏芮的主题分析

（1）积极情感下的主题分析

主题个数已确定为5，接下来在选取各主题的关键词时，变量n_top_words设置为10，表示每个主题最关键的前10个词汇。tf_vectorizer.get_feature_names_out()方法获取词频特征名称，然后调用打印函数，将LDA模型、tf_feature_names和n_top_words作为参数传入，将会得到每个主题下的前10个最具代表性的词汇，这些词汇对了解每个主题的关键内容至关重要，如下表5-2：

表 5-2 积极情感下的主题分类结果

Table 5-2 Subject classification results under positive emotion

主题分类									
主题一：									
工作	群众	防汛	救援	影响	应急	救灾	物资	暴雨	社区
主题二：									
影响	暴雨	强度	预计	预警	方向	降雨	小时	路径	预报
主题三:									
公交	场站	区间	斋堂	地铁	苹果园	菜园	房山	煤厂	措施
主题四:									
影响	生产	农业	设施	水利部	流域	救灾	滞洪区	资金	话筒
主题五:									
暴雨	门头沟	项目	备灾	影响	力量	孩子	视频	村民	救援

中国知网 https://www.cnki.net

主题一当中的主题词似乎与救灾工作有关，其中“暴雨、影响、社区”一词反映的是台风暴雨的天气带给社区的群众巨大的影响，“救援、救灾、防汛”等词汇反映在这极端的暴雨天气，采取一些有效的措施开始救援行动，保障减少暴雨对社区群众的影响。“应急、物资”等词汇更加强调了救灾的物资要确保充足，保障群众的日常生活和生命安全。灾后的救灾工作直接影响着社会的稳定，要做好灾后的救援就需要群众、政府以及相关社区部门紧密联系，保障信息共享和救援行动迅速响应。这一主题一系列的救援行动也让公众的情绪趋向积极的一面，也强调了灾后的救灾行动的重要性以及面对灾害团队协同合作共同抵抗灾害的责任。

主题二的关键词反映的含义似乎与暴雨的强度、路径以及带来的影响有关。“影响、暴雨”直接说明了暴雨天气给群众、环境带来了一些影响。“强度、预警、预计、降雨、小时、方向、路径”等词汇反映了气象部门经过专业的分析，对暴雨的强度、降雨时长、暴雨移动方向以及路径做了精准的预测，这些预测数据对防灾行动非常重要，尤其是对比较容易受灾地区的人民，提前掌握灾害的情况能够及时采取部署防控措施来减少暴雨带来的损失，减少焦虑的心情，也能为政府相关部门制定救灾方案提供一些参考。

主题三的关键词多次出现地点的词汇，似乎与交通设施有关。比如“地铁、公交、苹果园、房山”似乎是北京地区的站点，可能这些地区受到了暴雨天气的影响，影响了公交、地铁的正常交通。“措施”一词代表着在这样的极端天气，政府相关部门及时采取相关措施保障交通的正常运行。“煤厂”一词可能受暴雨天气的影响，可能导致煤厂的损失、增加煤厂的安全生产事故的发生。这些关键词汇联系在一起组合成一个主题，反映了受灾地区重点是北京，由于暴雨天气影响了公交地铁的正常运行，影响公众的正常出行，甚至对煤厂的生产效率和安全造成一定的影响，并对此采取相关的措施保障交通正常出行，减少暴雨天气对公众的影响。

主题四的关键词似乎与农业、水利救灾相关活动有关，由于暴雨天气，农业生产效率受到了影响，直接导致了农民财产的损失，所以有效的防汛措施至关重要。“水利部”的工作主要包括资源调配、防汛抗旱等几个方面，在台风暴雨灾害前，能够进行有效的流域管理达到用水保障。救灾“资金”也是整个救灾过程中的保障，利用媒体这一“话筒”呼吁社会向灾区伸出援助之手，帮助灾区农民的农产品的治理。

主题五的关键词比较分散，首先“暴雨、门头沟”直接点明了暴雨的受灾地区位于北京门头沟。“项目、备灾”似乎是应对暴雨灾害而开展的备灾项目，成为救灾行动的重要力量，并且通过“视频”的分析，对灾情有一定的掌握并能够采取相关措施救援灾区的孩子和村民。这一主题还是关注受灾地区的救援活动。

综上所述，这五个主题的关键词分别包含了关于台风暴雨灾害带来的影响、对灾情数据的预测和掌握、灾后的救援响应等，面对灾害造成的损失，政府、社会及

中国知网 https://www.cnki.net

时采取相关措施救灾减灾，注重救灾的救援行动，网民的情绪也在灾情当中越来越积极，也强调了社会各界的协同合作的重要性。

（2）消极情感下的主题分析

每一个主题都有代表主题内容的关键词汇，这些词汇对于我们深入了解每个主题的内容非常重要。经过算法技术选取每个主题的最具代表性前 10 个的词汇。以下表格 5-3 是每个主题的前 10 个关键词。

表 5-3 消极情感下的主题分类结果

Table 5-3 Results of topic classification under negative emotion

主题分类									
主题一：									
预警	降雨	防汛	暴雨	降雨量	房山	全市	小时	门头沟	预计
主题二：									
影响	气温	高温	老人	小时	预计	局部	预报	局地	暴雨
主题三：									
工作	暴雨	车辆	蜡烛	损失	积水	群众	影响	救援	道路
主题四：									
影响	应急	门头沟	工作	防汛	房山	旅客	物资	基站	公司

上述是从消极文本中提炼出的四个主题，以下是对这四个主题的详细分析：

主题一的关键词似乎是对于台风引起的暴雨事件进行防汛工作。比如“预警、降雨量、防汛、暴雨”等词汇都是报道台风暴雨事件的预报和防范，降雨量的多少直接影响公众的日常出行。而“房山、门头沟”等地名反映了台风暴雨重灾地区，这些地区山体多，极易发生滑坡受到暴雨灾害的影响。“全市”和“小时”可能反映了台风暴雨覆盖全市，持续达到了几个小时以上，总体暴雨强度还是比较大的。主题一主要揭示了自然灾害预警系统的关键作用，公众才能有所防备应对极端天气时挑战。

主题二的关键词似乎是在高温的天气当中预计有暴雨，比较关注老年人群体。“影响、气温、高温、老人”等词汇提示需要关注高温天气对老年人群的健康影响。“预计、局部、预报、暴雨”等词提示公众在某些地区将会有暴雨发生，可能会对高温天气有所降温，但同时提醒公众需要关注天气预报的播报并能够及时做好准备。“小时”这一词汇强调了暴雨的持续性久，可能会造成雨量过大影响人民的日常出行和交通状况。虽然台风暴雨减轻高温带来的负面影响，但是雨量过大还是会对人

中国知网 https://www.cnki.net

民的生活造成严重的影响，尤其是老年人的出行。

主题三的核心主要是暴雨灾害带来的直接后果及救援措施。比如“暴雨、车辆、蜡烛、损失、积水”等词汇描绘了暴雨灾害造成了停电，人们只能使用蜡烛照明，暴雨的雨量过大导致了积水，影响车辆的运行，导致人民的生命财产安全损失，灾害现场一片混乱。但“群众、救援、道路”等词汇揭示了在灾害面前群众和政府、社会都伸出了援助之手，减少暴雨灾害对人们生活的影响。不仅展示了台风灾害带来的负面影响，也体现了在灾难面前政府相关部门、人与人之间的帮助。

主题四的关联词串联起来似乎更加关注灾后的救援恢复事宜。“应急、门头沟、房山、防汛”应该是在门头沟、房山等地区快速启动应急方案并积极的进行防汛工作，也表明了房山和门头沟是暴雨灾害容易受到影响的地区。“旅客、物资、基站、公司”反映了灾害的基站恢复、物资筹备、旅客的转移、公司的运营的需求。主题四体现了在自然灾害面前，不仅需要关注重点灾区进行及时救援，还需要全面的灾后恢复计划，以保障社会生活的尽快恢复，一系列的恢复工作让公众更加理解灾害带来的破坏力。

主题一和主题二更偏向于台风暴雨灾害所带来的影响，而主题三和主题四的核心大多是灾后的救援工作。这四个主题包括了带给人们日常生活的不便、及时启动应急方案和灾后各方面的恢复等内容。这些主题不仅展现了台风灾害的恶劣影响，也展示了政府、社会在灾害面前的充分准备与积极应对。如果在自然灾害过程中能够优化灾害预警系统，那么将来的自然灾害的预防和灾害重建工作会更好。

（3）分析结论

积极文本主题分类与消极文本的主题分类之间有共性也有异性。共性方面第一是两者的核心都是围绕台风“杜苏芮”展开，积极文本的五个主题与消极文本的四个主题的关键词重复的有“影响、杜苏芮、暴雨、门头沟、应急、救援、物资等词汇。前四个词汇代表着都是关于台风引起的暴雨强度，重点地区门头沟可能比较严重。后三个词汇都是与救灾救援活动有关。在不同方面，积极文本的主题中的情感更倾向于政府有关部门的积极应对和公众对自然灾害的正面态度，而消极文本的主题中的情感更关注于灾害救援的人员伤亡、被困群众的窘迫。比如积极文本主题中的“预计、预报”传达出在灾害面前政府有关部门及时通知公众灾情情况，引起大家的关注。而消极主题中的词汇“损失、积水”反映了台风自然灾害可能造成了人民生命财产安全的损失、周边道路的积水情况影响日常交通等等。总体来说，积极文本主题挖掘的结果更倾向于公众对灾害的乐观态度和政府、相关机构的及时救援；而消极文本主题挖掘更关注于灾害带来的负面影响，揭示了目前灾害会发生的一些问题和将来面对的挑战。

中国知网 https://www.cnki.net

5.2.2 不同情感下台风海葵的主题分析

（1）积极情感下的主题分析

主题个数确定为 4 后，为了抓住每个主题的内容，所以从每个主题当中选取前 10 个最有代表性的关键词，可以从这些关键词反映出每个主题的核心。以下表格 5-4 就是我们所选取的关键词汇总：

表 5-4 积极情感下的主题分类结果

Table 5-4 Subject classification results under positive emotion

主题分类									
主题 1:									
暴雨	海葵	影响	预警	话筒	环流	降雨	小时	局部	雨量
主题 2:									
海葵	影响	路径	方向	预计	强度	风力	一带	共舞	海面
主题 3:									
影响	海葵	联通	网络	风雨	极值	突破	季风	残涡	消防员
主题 4:									
海葵	影响	工作	救援	应急	群众	防汛	记者	消防	注意安全

表格当中一共展示了四个主题，每个主题都有 10 个关键词，通过分析这些关键词，可以掌握每个主题的关键内容，研究不同主题之间的不同，了解其评论内容和情感。在这四个主题之间，都有“海葵、影响”关键词，由此可知围绕着海葵带来的影响而展开。

在主题一当中“预警”一词象征着灾害事件发生的提前告知，不仅在警示着灾害带来的潜在危险，更能够让人们提前采取预防措施。在面对自然灾害时，人们不是手足无措和被动地承受，而是采用一些科学的方法和先进的技术手段积极地应对，提前预知并准备应对自然灾难的发生。“雨量”与“小时”这两个关键词，具有单位属性，在灾害发生前后衡量了台风“海葵”带来的暴雨强度和持续时间范围。这些词汇不仅告诉我们暴雨雨量的多少，也能通过时间单位“小时”的降雨强度划分，这样才能清楚理解此次灾害引起的暴雨带来的影响。正是因为对灾害的细致描述，所以提前做好预防准备工作非常重要。公众能够根据对灾情的报道和结合自己的实际情况，制作有针对性地防灾计划，采取对应的应对措施，比如通过提前转移灾害地区的人员和物资，加固维护容易受风雨破坏的建筑物等，从而最大程度地减少灾害带来的损失后果。

中国知网 https://www.cnki.net

在主题二当中的“预计”一词常被视作人们在面对自然灾害时所需准备时间的评估，同时也为人们提供了一个时间上的预警和准备依据。在预警系统当中，这一词汇不仅展现了灾害预警的重要性和准确性，更确保了社会在防灾减灾方面能够迅速采取行动。不仅促使相关部门能够预先做出规划，调动救援人员力量和物资，也向公众提交了一个清晰的说明，减弱了因不确定性而产生的恐惧和混乱场面。“强度”“风力”等词汇则是精准描述了自然灾害台风的现象。当台风“强度”增强，“风力”加剧时，人们就能意识到台风带来影响的危险性，为了保障自己的人身财产安全，会主动的听从政府和救援队伍的指令。“共舞”一词似乎生动的描绘了多个台风在同一时间段内相互影响、共同活动的场景。这不仅提升了预测台风移动路径和风力强度的难度，也进一步凸显了面对自然灾害时，全世界的气象监测和预警系统需要共同应对灾害做好作战的重要性。总的来说这些关键词不仅评估了台风风力和带来暴雨的破坏力，更让人们对自然灾害拥有直观的认知，随时有可能出现在自己身边，提醒公众注意安全并采取对应的防护措施。

主题三当中“海葵、影响”一词又强调了此次自然灾害事件的影响之大。“网络、联通”揭示了此次自然灾害事件对网络通信的运行造成一定的破坏，影响了人民日常生活的通信服务乃至失去了受灾群众的联系。“风雨、极值、突破”等词汇直观展示了台风带来的暴雨强度，甚至可能突破了极限值，给人类的生活和周边环境带来了严峻的考验。“季风、漩涡”词汇不仅描述了台风海葵发生背景和极端的季风天气。但是“消防员”的出现给了人类的希望，政府相关部门的协助才能够让无情的灾害中感受到一丝温暖的人情，面对这么严峻的天气，政府、社会都在积极的解救灾害中的人们，也有一线记者报道灾情情况，社会各界都来伸出援助之手，集中筹备物资带去灾区，更有投身于灾难中解救被困群众，不怕困难，确保人员的生命安全。总的来说，主题三当中的关键词反映了自然灾害台风海葵给人们、社会、环境的影响，在面对这些负面影响时，国家政府相关部门、社会各界作为了应急救援的重要力量，更在灾难面前彰显了社会团结、齐心协力的精神。

主题四中的关键词也包括了“海葵、影响”这两个词汇，也是围绕着台风海葵带来的影响而展开，其中“救援、工作”这两个词汇体现了在自然灾害面前，政府相关部门对受灾群众的关注以及都在积极的采取救援活动，保障人类的生命安全。“应急、群众”代表着对受困的群众采取快速的应急方案，迅速解救出受困人群，同时也告诫我们在面对自然灾害时，要提前做好防护准备和及时快速响应。“防汛、消防”似乎记录着在暴风雨天气消防员在紧急救援的场景。“记者”作为报道灾情的前线人员，通过真实、客观的灾区前线的消息，报道灾区的最新情况，更响应了来自四面八方的积极救援，加速了救援物资的筹备。“注意安全”这短短四个字，凸显了在灾害应对中人们对安全的担忧。在进行灾后救援和重建过程中，确保人员安全是首要原则，能够有效的降低预防灾害伤害、人员伤亡。

中国知网 https://www.cnki.net

积极词汇一共分为四个主题，主题一与主题二几乎都围绕着台风的生成背景和台风的强度以及台风带来的影响，而主题三和主题四都是围绕着面对台风带来的影响，政府相关部门的积极应对和社会的救援行动有效的缓解灾害带来的负面影响。这些词汇生动展现了人们在自然灾害面前所采取的积极举措与正面态度，也为后续的积极应对奠定了重要基础，这些词汇在某种程度上被视为积极词汇体系中的组成部分。

（2）消极情感下的主题分析

通过综合分析主题困惑度和主题气泡图，我们最终确定了主题个数为 5。然后从这 5 个主题中输出前 10 个最具代表性的词汇，具体如下表 5-5 所示：

表 5-5 消极情感下的主题分类结果

Table 5-5 Results of topic classification under negative emotion

主题分类									
主题 1：									
海葵	影响	共舞	海水	核污染	工作	应急	公司	设备	供电
主题 2：									
影响	海葵	暴雨	雨量	季风	局地	残涡	小时	山体	列车
主题 3：									
海葵	方向	预计	风力	小时	海面	强度	阵风	蜡烛	速度
主题 4：									
海葵	影响	预警	降雨	暴雨	路径	环流	海域	应急	信号
主题 5：									
救援	消防员	海葵	群众	影响	消防	民警	开学	鳄鱼	派出所

在主题一中，“海葵”这一台风名称点明了整个自然灾害事件的核心要点，几乎围绕着台风海葵带来的危害和影响而展开。当“影响”与“共舞”出现时，似乎不仅只有一种灾害事件，更像是和其他灾害事件之间错综复杂、相互交织的关系。最关键的“海水”和“核污染”这两个词汇既揭示了由于台风的猛烈冲击，可能对核电站及周边环境的潜在危害，导致核电站的海水冷却系统受损，可能会引发环境危机。同时“应急”“供电”与“工作”等关键词汇反映了在台风恶劣影响下，供电设备受到严重破坏，政府和相关部门面对这种情况采取应急方案，全力以赴的维修供电设施，保障人民的日常生活和供电设备的正常运行，为灾后恢复提供坚实的电力保障。

中国知网 https://www.cnki.net

在主题二的主题分析中，“海葵”“影响”这两个词汇的再次出现，强调了台风海葵所带来的影响之深远与广泛。它不仅是一次简单的自然灾害事件，更是一次对公众生活、交通出行乃至生态环境造成重大冲击的严峻考验。“暴雨”“雨量”“季风”“残涡”几乎都是与台风的降雨强度、持续时间、季风气候有关，不仅反映了台风带来降雨的猛烈程度和持续时间之长，还体现了台风与季风等气象因素的叠加效应，经常出现道路积水、视线受阻等问题对公众的出行造成了极大的困扰与不便，给救援行动的出行交通带来了沉重的压力。“山体”代表在台风暴雨的强烈作用下，山上的土壤变得松散，容易引发山体滑坡等地质灾害，对山区可能带来潜在的危害，也对附近人们的生活和生命财产带来巨大的负影响。“列车”突出了台风对乘客的出行计划带来极大不便。如果山体滑坡、泥石流等灾害发生，铁路路线必然会因灾害而中断，导致列车取消或晚点。

在对主题三的探讨中，“方向”“预计”“海面”这些词汇被用来描绘风向的变化走势，不仅展现了气象专家们对台风灾情的路径详细分析和预测的技能，同时也反映了台风袭来在海洋区域中表现的复杂作用，及时告知公众预警信息，提前做好防护准备。“风力”“强度”“阵风”“速度”等词汇描述了台风期间的风力程度的情况特征。获取的这些特征数据，可以帮助我们去量化台风可能造成的破坏程度，还能比较不同时间的风速，对理解台风强度变化起到重要作用。这些与灾情情况的数据信息对于判断台风的危害等级和制定相应的紧急应急方案有很大的帮助。台风可能导致的大面积断电，人们才借助“蜡烛”去进行照明。在强风暴雨的影响下，电力基础设施容易受到损害，进而造成区域性的停电现象。这一细节提醒人们，在面对自然灾害时，做好应急物资储备、确保基本生活需求得到满足的重要性。

在主题四的关键词中，“海葵”、“影响”这两个词汇吸引着我们的关注，也反映了此次台风带来的影响不容小觑。良好的“预警”机制可以保证了灾情信息能够及时告知给公众，在灾害到来前，公众也有充足的准备时间去应对。其次像“降雨”、“暴雨”类似的词汇，更加直观了解台风带来的降水程度。还有对“路径”和“环流”的深度分析，专家对其灾害的移动路径的预测更加准确。面对海葵所带来的影响，共同抵御台风带来的威胁，“应急”措施与“信号”发布显得非常重要。在救灾过程中，政府相关部门部门及时发布预警信号，采取应对救灾措施，才得以保护人们的生命财产安全。

在主题五的分析中，“救援”“消防员”“群众”“民警”“影响”等词汇，反映了在面对台风灾害带来的破坏时，消防员和民警共同合作，第一时间冲在前锋，成为救灾救援队伍的重要力量，在救灾过程中他们极力寻找并救出受伤群众，搬运救灾物资，维持灾区的秩序，确保救援通道顺利畅行，受灾群众感受到了温暖和灾后重生的期待，体现了救援行动中的协同配合。而“开学”两字反映出当下的时间台风对学生日常生活的深刻影响。由于台风态势逐渐好转的时间恰恰临近学校开学，

中国知网 https://www.cnki.net

相关部门也在积极保障开学时间不变，确保不耽误学生的课程。“派出所”的出动在救灾行动中发挥着重要的角色，他们积极参与灾后救援，负责维护灾区的治安、做好人员信息登记和疏散引导等工作，为灾后的救援行动提供了坚实的基础。

（3）分析结论

积极文本主题分类与消极文本的主题分类之间既存在相同点，也有不同点。相同点第一是两者的核心都是围绕台风“海葵”展开，积极文本的四个主题与消极文本的五个主题的关键词重复的有“影响、海葵、雨量、应急、消防、救援”等词汇。前三个词汇代表着都是关于台风引起的暴雨强度，后三个词汇都是与救灾救援活动有关。在不同方面，积极文本的主题中的情感更倾向于政府有关部门的积极应对和公众对自然灾害的正面态度，而消极文本的主题中的情感更关注于灾害救援的人员伤亡、被困群众的窘迫。比如积极文本主题中的“预警”传达出在灾害面前政府有关部门及时开启应急机制保障灾后救援工作的立即执行等;而消极主题中的词汇“影响、核污染”反映了无情的自然灾害给公众生活、环境造成严重的影响性，描述台风海葵给社会带来的负面影响和环境破坏，如停水停电、交通设施损坏、人员伤亡等。总体来说，积极主题聚焦于人类如何主动面对台风的挑战，采取有效的预警系统及应急方案来减少负面影响；而消极主题则着重展现台风给人类社会和自然环境所带来的严重破坏与巨大损失。

5.3 本章小结

本章节主要是基于上一章节情感分类进行的主题分析。首先 5.1.1 介绍了 LDA 主题模型的构建，调用的是 Sklearn 库的 LDA 主题模型，通过调整参数进行训练；其次 5.1.2 介绍了主题模型的评估，主题模型当中的性能取决于选择的主题个数，本文选择合适的主题个数是通过主题困惑度和主题之间的距离来判断；然后 5.2 主要介绍了台风杜苏芮和海葵的主题提取结果并且分析，输入主题个数的参数输出主题结果，并且提取各主题当中的前 10 个关键词，通过主题关键词可以观察到主题的核心内容和主题之间的联系。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 6 章 重大自然灾害舆情的应对方案和引导策略

6.1 面对重大自然灾害舆情的应对方案

6.1.1 基于大数据技术提高识别不同主题舆情精准度

台风“杜苏芮”与台风“海葵”这两个自然灾害事件的网络舆情趋势图的评论数量的突然暴涨体现了台风事件的突发性和公众对此事件的关注。在网络舆情的四个阶段中，舆情爆发期和舆情波动期肯定是有效控制网络舆情和引导舆情方向的重要时期，而舆情潜伏期到舆情的爆发期也需要重点关注，精准预测舆情的爆发时间并提前采取行动及时控制，能够减少舆情发生。

随着大数据的技术愈加成熟，网络舆情可以借助现在成熟的大数据、人工智能等技术，对各个平台进行监控，一旦扫描到与自然灾害事件的信息，就立刻进行分析。同时号召应急管理部门、宣传部门、网信办、公安等多部门进行信息共享，加强各部门间的配合工作，增强面对重大灾害舆情应对的力量。而且现在社交媒体的多样性导致重大自然灾害事件的扩散源头非常广泛，若要全面提高网络舆情的识别精确度，需要从各大平台当中获取相关的信息进行分析，了解公众对自然灾害事件的态度和关注内容。利用大数据技术对各大平台获取相关的信息，经过对数据的处理获得有价值的信息，精准识别文本的情感倾向以及划分不同的主题并理解主题的核心内容，根据不同主题的关注内容和情感趋势通知政府的有关部门，及时响应并控制舆情的传播。本文研究的自然灾害的网络舆情研究，从积极文本和消极文本两个角度进行主题分类，通过不同的主题内容，更加了解公众的需求，针对不同主题的内容，及时制定合适的解决方案。比如通过本文当中的主题关键词“应急、物资”等词汇应迅速为灾区筹备相应的物资用品。

6.1.2 采用实时直播分析不同主题内容并制定方案

在没有发生灾害之前，政府或者官方媒体需要进行预估灾害发生的时间，并及时告知大众，提高警惕最好防护。一旦自然灾害发生，政府相关部门应迅速利用官方渠道向公众传达灾情严重程度、救援行动的实施和提出有效的防范措施防止二次伤害等重要信息，能够有效的遏制假性消息的传播。网络上公众对此事件的强烈的反应和需求，避免矛盾升级和舆情的产生，要及时做出积极回应并制作好解决方案。如果舆情产生了，让公众了解整个灾区的情况和灾情的发展形势，能够避免公众对信息的不确定而导致的恐慌和害怕，也在一定的程度上稳定公众的情绪。舆情的热

中国知网 https://www.cnki.net

点话题政府相关部门应该主动邀请各种专家，包括心理专家、与自然灾害有关的专家。采用各大平台的直播的方式向公众讲解灾情的情况，方便公众以理性的视角来看待灾害事件，稳定公众的情绪。除了在不同社交媒体的数据采集之外，还要在直播期间对群众在直播间的发言做到及时的筛选和整理，专家们根据公众发言内容的不同主题而分析群众的关注焦点，相应的提出一些解决方案。直播的方式不仅让来自各地的群众诉说自己的需求，而且加强了专家与群众的沟通，针对群众的需求制定相应的方案。

6.2 面对重大自然灾害舆情的引导策略

6.2.1 发布权威消息实现多渠道正确引导情感

在信息互联的时代下，面对重大自然灾害事件时，公众几乎都是从各种各样的社交媒体当中了解信息，正是因为引起社会的关注，有些人为了流量或者其他的原因，就撰写一些引导公众情绪的文章，导致公众信以为真网络舆情爆发。所以在面对网络舆情爆发前期，迅速瞄准引导舆情的博主账号和存在一定的隐患的账号进行针对性管理，前期对账号发布的内容进行严格审核，比如对发布不实的文章进行删除。评论的内容具有引导性以及有目的的在各种话题下进行重复评论，各大社交媒体平台系统应该自动检测并自动删除，系统的多次提醒还未制止则启用停止账号的使用。

为了正确引导网络舆情，增加各大社区、官方媒体的官方账号，除了对其他账号的内容进行审核之外，为了避免有人把官方账号的昵称提前注册，可以通过提交一些官方材料进行审核注册。官方账号能够及时公布灾情的情况，及时对不实信息打假。通过对大量公众关注的主题内容做到及时响应，采取相关的措施积极解决，缓解公众的情绪。

6.2.2 联动社区支援实现凝聚力正向引导情感

灾害无情，人有情。在面对重大自然灾害发生时，受灾群众的心理已经受到了巨大的打击，受灾群众的无助的情绪和求救的需求都体现在网络上的信息。通过对网络上信息的爬取分析，掌握网民的情感以及需求内容，积极响应并解决能够稳定公众的情绪。

我们应该呼吁周边社区的参与，方圆五百里一家亲，一方有难八方支援，希望各大社区能够及时响应，提供救灾设备和为受灾人群提供遮风避雨的住所。在冰冷的灾情面前，只有国家、社会、群众给予灾区人民的关怀，感受人间温暖。其次呼吁各大企业伸出援助之手，提供灾区物资，因为各大企业都有企业社会责任（经济

中国知网 https://www.cnki.net

责任、社会责任、环境责任），灾害面前各大企业为灾区提供日常生活物资和环保设备等，帮助了受灾人群的衣食住行，帮助了绿色环境的重建，都体现了它的社会责任和环境责任。还有呼吁各大医院的志愿者参与灾区救助受伤人员，利用自身的知识和技能本领，帮助灾区的受伤人员快速的恢复，解救当下医护人员的缺乏，同时也在自己的人生路上实现了自我价值。

6.3 本章小结

本章节主要是对重大自然灾害舆情提出应对方案和引导策略，在应对方案中提出了基于大数据技术来提高识别不同主题舆情的精确度、采用现在的直播方式进行分析主题内容，更能够及时捕捉重要信息。在引导策略上建议发布权威消息正确引导情感以及联动社区支援共同实现正向情感的传递。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第七章 总结与展望

7.1 总结

由自然灾害引起的网络舆情，不仅反映着公众对此灾害事件的关注，还能够从公众的言论获取有价值的信息。本文是对 2023 年台风杜苏芮和海葵两大自然灾害事件引起的微博舆情进行展开，首先对舆情的特点和影响、信息收集的方法、主题模型的构建以及应用、情感分析的方法及实现可视化等方面进行深入了研究，结合了本文研究的领域制定了合适的技术路线和理论方法；其次在数据获取上采用了 Python 爬虫的方法对微博平台针对性的爬取，经过数据筛选绘制出网络舆情趋势图；然后通过 Snownlp 技术对两大自然灾害事件的文本进行情感区分，不同情感下公众关注的内容不同，虽然有交叉的关键词，但是由于公众关注的不同而导致情感不同。接着在不同情感下文本通过 LDA 主题模型提取不同的主题，并在此基础上分析主题的内容并进行隐含的情感分析，这些情感起伏和当时灾害的严重程度、救灾工作的进展和网络媒体的传播等因素紧密相连。最后提出了面对重大自然灾害舆情的应对方案与引导策略，能实现良好的网络舆情管理。具体研究结论如下：

（1）首先爬取微博与台风杜苏芮和海葵有关话题下的微博博文和评论，其次根据灾害的具体发生周期，经过数据筛选，利用 Python 当中的 Matplotlib 模块绘制出网络舆情趋势图，最后从图中不仅可以观察到整个事件的发生周期，还能从趋势判断出网络舆情潜伏、高潮、波动到消匿阶段。

（2）首先对部分台风杜苏芮、海葵的文本数据进行人工情感标记，使用人工标记的数据对 Snownlp 模型进行训练，达到适合灾害领域的应用。其次经过数据预处理，包括数据去重、去停用词、提取中文文本和文本分词等操作。然后将文本信息划分为积极和消极两类，通过绘制积极和消极词云图分析公众的情感倾向和关注的话题内容。

（3）分别在积极文本和消极文本下，利用主题困惑度和主题之间的距离进行选取合适的主题个数，提取主题当中的前 10 个关键词，通过对关键词的分析大致可以了解主题的内容和主题之间的联系，针对不同的主题和公众的关注方向，可以及时的采取行动正确引导网络舆情。

（4）针对灾害的网络舆情的分析，提出了面对重大自然灾害的应对方案和引导策略，在应对方案中可以利用大数据技术提高识别不同主题舆情精确率，本文就是依托大数据技术进行主题识别，还可以采用直播方式分析不同主题，达到实时捕捉公众关注内容；在引导策略中可以发布权威消息和联动社区支援正向引导情感。

中国知网 https://www.cnki.net

7.2 展望

本文实证研究在自然灾害网络舆情分析中通过对 Snownlp 的情感语料库的补充，对灾害文本数据进行了情感分类，在不同情感文本下利用了 LDA 主题模型进行主题分析，为政府部门和网络媒体再次遇到相似的自然灾害时提供了非常重要的参考。但是还有一些不足之处：首先，此次研究的数据集缺少视频、图片等不同形态的，具有一定的局限性；其次，社交媒体单一，目前抖音、B 站、小红书也有大量的用户，结合多种社交媒体进行分析，研究结果会比单一的社交媒体更全面些；最后，在进行文本分类时 LDA 主题模型在短文本、复杂的文本情感的识别程度需要进一步改进。

针对以上的不足之处，第一，在将来的研究工作当中可以采集更多元化的数据，不限于视频、文本、图片、表情等格式，进而提升整个数据的准备性。第二，采取用户量大的 3 到 5 个社交媒体，每个社交媒体的风格不同，比如小红书多以图文展示，抖音则以视频居多，利用不同的社交媒体采集数据提取更加全面有价值的信息。第三，结合深度学习、大模型等前沿技术，改进 LDA 模型在短文本、复杂的文本情感表达识别上的性能。最后此次研究成果在灾害预警、掌握舆情导向等领域有一定的贡献，也对政府和社会提出相应的建议，希望在自然灾害中能够掌握公众的情绪，打造更为和谐、高效的灾害应对机制。

中国知网 https://www.cnki.net

参考文献

[1] 何娟, 叶运黎. 全媒体环境下高校辅导员网络舆情应对与治理[J]. 现代商贸工业, 2023, 44(11): 125-127.

[2] 李明德, 邝岩. 大数据背景下的网络舆情认知偏差: 表征、成因与应对[J]. 西南民族大学学报(人文社会科学版), 2023, 44(05): 138-143.

[3] 冯超. 关于新媒体时代的网络舆情分析及其应对探讨[J]. 电脑知识与技术, 2021, 17(30): 119-120.

[4] 艾敬怡, 耿亮,安彧, 等. 基于相关向量机的网络舆情反转预测研究[J]. 计算机时代, 2023(05): 113-117.

[5] 梁瑛楠, 张丽颖. 新媒体背景下突发事件网络舆情应对策略[J]. 新闻研究导刊, 2021, 12(05): 49-50.

[6] 胡锦玉. 新媒体时代网络舆情特点与应对策略[J]. 传播力研究, 2019, 3(36): 270+272.

[7] 张谱, 张豪, 孔锋, 等. 基于微博数据的暴雨洪涝灾害舆情特征研究: 以2021年中国三场暴雨洪涝为例[J]. 水利水电技术(中英文), 2023, 54(02): 47-59.

[8] 唐忠强. 新媒体环境下网络舆情对公共政策的影响[J]. 新闻传播, 2018(23): 35-36.

[9] 张伟平. 新媒体时代网络舆情对政策制定的影响[J]. 中共云南省委党校学报, 2019, 20(04): 173-176.

[10] 刘晓岚. 灾害信息传播研究的探索与实践——以防灾科技学院为例[J]. 科技视界, 2022(07): 65-68.

[11] 郭怡雷. 自然灾害危机的舆论引导问题研究——以邢台“7·19”洪灾为例[J]. 科技传播, 2018, 10(03): 55-56.

[12] 吴珺. 互联网与信息获取[J]. 光盘技术, 2009(06): 12+16.

[13] 王全兰. 网络舆情信息采集及预警方法研究[J]. 管理工程师, 2012(02): 34-37.

[14] 张颖, 林洋, 张澜, 等. 基于认证微博的灾情信息快速获取与信息提取技术研究[J]. 防灾减灾学报, 2020, 36(02): 75-81.

[15] 王金峰, 彭禹, 王明, 等. 基于网络爬虫的新浪微博数据抓取技术[J]. 中小企业管理与科技(上旬刊), 2019(01): 162-163.

[16] 杜晓旭, 贾小云. 基于 Python 的新浪微博爬虫分析[J]. 软件, 2019, 40(04): 182-185.

[17] Rungsawang A, Angkawattanawit N. Learnable topic-specific web crawler[J]. Journal of Network and Computer Applications, 2005, 28(2): 97-114.

[18] Blei D M, Ng A Y, Jordan M I. Latent dirichlet allocation[J]. Journal of machine Learning research, 2003, 3(Jan): 993-1022.

[19] Jelodar H, Wang Y, Yuan C, et al. Latent Dirichlet allocation (LDA) and topic modeling:

中国知网 https://www.cnki.net

models, applications, a survey[J]. Multimedia tools and applications, 2019, 78: 15169-15211.

[20] 蔡一村, 李家新, 黄小冬. 大陆青年网络社群涉台舆情的主题分布与情感特征——基于LDA 模型和文本情感计算的大数据分析[J]. 台湾研究集刊, 2024, (02): 31-53.

[21] 宋雅蓉, 王译啡. 基于 LDA 模型和情感分析的网上教学舆情分析研究[J]. 网络空间安全, 2023, 14(01): 112-118.

[22] 陈齐超, 林广发, 梁春阳, 等. 基于微博数据和情感分析法的台风“米克拉”灾情过程探测[J]. 亚热带资源与环境学报, 2021, 16(01): 70-76.

[23] Luo L. Network text sentiment analysis method combining LDA text representation and GRU-CNN[J]. Personal and Ubiquitous Computing, 2019, 23(3): 405-412.

[24] 曾子明, 陈思语. 基于 LDA 与 BERT-BiLSTM-Attention 模型的突发公共卫生事件网络舆情演化分析[J]. 情报理论与实践, 2023, 46(9): 158-166

[25] 杜景玮. 基于 LDA 主题模型的情感分析研究[D]. 广州: 暨南大学, 2020.

[26] Huang F, Yuan C, Bi Y, et al. Exploiting long-term dependency for topic sentiment analysis[J]. IEEE Access, 2020, 8: 221963-221974.

[27] 孙玲玲. 面向农产品在线评论的主题分类和细粒度情感分析研究[D]. 杭州: 浙江农林大学, 2021.

[28] 杨嘉怡, 李晓英, 何首武. 基于手机评论文本的用户情感分析研究[J]. 大众科技, 2022, 24(09): 22-24+21.

[29] Rosner F, Hinneburg A, Röder M, et al. Evaluating topic coherence measures[J]. arXiv preprint arXiv: 1403.6397, 2014.

[30] Huang L, Ma J, Chen C. Topic detection from microblogs using T-LDA and perplexity[C]. 2017 24th Asia-Pacific software engineering conference workshops (APSECW). IEEE, 2017: 71-77.

[31] Li C, Zhang S, Liu X. A Study on the Identification of the Water Army to Improve the Helpfulness of Online Product Reviews[J]. Mathematics, 2024, 12(20): 3234.

[32] 倪维斌, 姜垚松, 罗玮, 等. 基于 hLDA 层次主题模型的患者投诉分类框架研究[J]. 中华医学图书情报杂志, 2018, 27(10): 28-32.

[33] Ye J, Jing X, Li J. Sentiment analysis using modified LDA[C]. Signal and Information Processing, Networking and Computers: Proceedings of the 3rd International Conference on Signal and Information Processing, Networking and Computers (ICSINC) 3. Springer Singapore, 2018: 205-212.

[34] 李文潇, 梅红岩, 李雨恬. 基于深度学习的多模态情感分析研究综述[J]. 辽宁工业大学学报(自然科学版), 2022, 42(05): 293-298.

[35] 李杨, 徐泽水, 王新鑫. 基于在线评论的情感分析方法及应用[J]. 控制与决策, 2023, 38(02): 304-317.

中国知网 https://www.cnki.net

[36] 赵妍妍, 秦兵, 石秋慧, 等. 大规模情感词典的构建及其在情感分类中的应用[J]. 中文信息学报, 2017, 31(02): 187-193.

[37] Xu G, Yu Z, Yao H, et al. Chinese text sentiment analysis based on extended sentiment dictionary[J]. IEEE access, 2019, 7: 43749-43762.

[38] 王科, 夏睿. 情感词典自动构建方法综述[J]. 自动化学报, 2016, 42(04): 495-511.

[39] 蔡增玉, 韩洋, 张建伟, 等. 基于 SnowNLP 的微博网络舆情分析系统[J]. 科学技术与工程, 2024, 24(13): 5457-5464.

[40] 邱冬阳, 绘娴. 双十一活动消费者满意度研究——基于天猫个护美妆类产品文本挖掘[J]. 重庆邮电大学学报(社会科学版), 2023, 35(02): 131-145.

[41] Qu H, Teh B T, Nordin N A, et al. Analysis of Guangzhou city image perception based on weibo text data (2019–2023)[J]. Heliyon, 2024, 10(17).

[42] Zhang H, Wu Y. The Analysis and Implementation of Film Decision - Making Based on Python[J]. Scientific Programming, 2022, 2022(1): 4131316.

[43] Sugiyarto S, Eliyanto J, Irsalinda N, et al. Fuzzy sentiment analysis using convolutional neural network[C]. AIP Conference Proceedings. AIP Publishing, 2021, 2329(1).

[44] 金书丞, 王嘉梅. 基于 BERT-MABL 模型的客户评论情感分析研究[J/OL]. 云南民族大学学报(自然科学版), 2025: 1-11.

[45] 周凯, 李晖, 刘桐. 基于深度学习的网络媒体情感分析[J]. 微处理机, 2022, 43(05): 31-34.

[46] 温廷新, 陈依琳. 基于深度学习的不均衡评论文本情感分析模型[J]. 情报探索, 2022(07): 14-22.

[47] Wei J, Liao J, Yang Z, et al. BiLSTM with multi-polarity orthogonal attention for implicit sentiment analysis[J]. Neurocomputing, 2020, 383: 165-173.

[48] 曾莉, 杨添宝, 周慧. 基于 LDA 与注意力机制 BiLSTM 的微博舆情分析模型[J]. 南京理工大学学报, 2022, 46(06): 742-748.

[49] 张伶俐, 褚琦凯, 王桂娟, 等.文本情感可视分析技术及其在人文领域的应用[J]. 大数据, 2022, 8(06): 56-73.

[50] 刘华玲, 王希睿, 孙爱华. 基于 LDA 主题模型舆情预测与可视化——以 COVID-19 为例[C]. 第十六届（2021）中国管理学年会论文集, 2021: 303-316

[51] 麦丞程, 陈波, 周嘉坤. 微博信息传播可视化分析工具研究[J]. 网络新媒体技术, 2016, 5(02): 8-18.

[52] 吴帆. 基于热点事件的微博数据文本挖掘及其可视化[D]. 北京: 北京林业大学, 2018.

[53] 李亚芳, 王新刚, 梁庆云. 基于新浪微博大数据的新疆伽师 6.4 级地震舆情分析及可视化研究[J]. 内陆地震, 2020, 34(01): 103-110.

[54] 赵剑, 董文华, 史丽娟, 等. 针对突发公共事件的舆情监测与可视化分析[J]. 吉林大学学报

中国知网 https://www.cnki.net

(信息科学版), 2021, 39(06): 712-719.

[55] 刘丽群. 面向自然灾害事件的舆情分析及其可视化[D]. 上海: 华东师范大学, 2022.

[56] Ono J P, Freire J, Silva C T. Interactive data visualization in jupyter notebooks[J]. Computing in Science & Engineering, 2021, 23(2): 99-106.

[57] Nordmann E, McAleer P, Toivo W, et al. Data visualization using R for researchers who do not use R[J]. Advances in methods and practices in psychological science, 2022, 5(2): 25152459221074654.

[58] 宋成章, 黄晓东, 李棚, 等. 基于 Processing 的舆情大数据分析及可视化研究[J]. 福建电脑, 2014, 30(05): 19-21.

[59] 王心瑶, 郝艳华, 吴群红, 等. 基于登革热事件的官方微博网络舆情可视化分析[J]. 中国预防医学杂志, 2018, 19(06): 401-406.

[60] Cui Y, Li C, Chen C, et al. VineMap: A metaphor visualization method for public opinion hierarchy from text data[J]. Journal of Visualization, 2021, 24: 1097-1111.

[61] Wu Y, Liu S, Yan K, et al. Opinionflow: Visual analysis of opinion diffusion on social media[J]. IEEE transactions on visualization and computer graphics, 2014, 20(12): 1763-1772.

中国知网 https://www.cnki.net