中图分类号 TP311.5　　学校代码 10533

UDC　　004.41　　学位类别专业学位

硕士学位论文

基于机器学习的网络舆情分类算法研究

Research on network public opinion classification algorithm based on machine learning

作 者 姓 名	李小雄
专业学位类别	工程专业硕士
专 业 领 域	软件工程
研 究 方 向	机器学习、文本挖掘
二级培养单位	计算机学院
指 导 教 师	熊红云
副指导教师	

论文答辩日期 2022.5.25　　答辩委员会主席_____

中 南 大 学

2022 年 5 月

中国知网 https://www.cnki.net

基于机器学习的网络舆情分类算法研究

摘 要：随着互联网社交平台的快速发展，各类新闻、微博、微信、推持上时常会出现一些偏激言论、网络谣言和消极思想，严重影响了社会稳定和安定团结。如何从这些媒介信息文本中挖掘出舆情信息，对网络舆情进行有效的监测和管理意义越显重大。为此，本文基于机器学习提出了一种改进 ML-SVM（Machine learning support vector machines）舆情信息分类算法，主要工作如下：

（1）针对网络舆情非结构化的数据，采用机器自动分类处理的方法，从短文本中提取舆情信息关键词。基于现有的词向量原理，根据网络舆情的特点进行词向量编码，采用 One-Hot 与 Word2vec 方法实现舆情信息上下文输入，舆情信息的关键词预测和词向量编码。讨论了从局部序列到全局序列的舆情序列信息的本质含义，结合词向量与舆情语义特征进行分析，针对网络舆情信息进行预处理，以此构建舆情关键词提取算法。

（2）针对现有模型在网络舆情信息分词后信息稀疏、训练文本特征准确率不高等问题，提出了基于机器学习的 ML-SVM 支持向量机算法。通过舆情信息特征与香农定律建立舆情新词发现机制，解决了训练文本集特征不足的问题；为更好的衡量舆情信息间的亲疏关系，建立舆情文本信息更新算法，并通过不同数据集上的仿真实验与对比分析，验证了本文算法的有效性。

最后，将本文提出的分类算法应用于“社会舆情热点分析”九大类别分类测试，对不同规模的语料数据进行对比分析，结果显示 ML-SVM 分类模型的 F1 测度值在召回率、准确率两个指标上分别达到 95.2%和 96.6%，验证了本文提出的基于机器学习的网络舆情分类算法具有较好的性能。

图 22 幅，表 7 个，参考文献 60 篇。

关键词：网络舆情；机器学习；支持向量机；文本分类；
分类号：TP311.5

中国知网 https://www.cnki.net

ABSTRACT

With the rapid development of Internet social platforms, some extreme remarks, online rumors and negative thoughts often appear on all kinds of news, microblog, wechat and twitter, which has seriously affected social stability and unity. How to mine public opinion information from these media information texts is becoming more and more important for effective monitoring and management of network public opinion. Therefore, this paper proposes an improved public opinion information classification algorithm based on machine learning. The main work is as follows:

(1) For the unstructured data of network public opinion, we decided to use the method of automatic machine classification to extract public opinion information keywords from short texts. According to the existing Word embedding principle, the characteristics of network public opinion are encoded by Word embedding, and the one hot and word2vec methods are used to realize the input of public opinion information context, keyword prediction and Word embedding coding of public opinion information. This paper discusses the essential meaning of public opinion sequence information from local sequence to global sequence, analyzes it combined with word vector and public opinion semantic features, and preprocesses the network public opinion information, so as to construct the public opinion keyword extraction algorithm.

(2) Aiming at the problems of sparse information and low accuracy of training text features in the existing models after word segmentation of network public opinion information, a ml-svm support vector machine algorithm based on machine learning is proposed. Through the characteristics of public opinion information and Shannon's law, the discovery mechanism of public opinion neologisms is established, which solves the problem of insufficient characteristics of training text set; In order to better measure the affinity between public opinion information, a public opinion text information updated algorithm is established, and the effectiveness of this algorithm is verified by simulation experiments and comparative analysis on different data sets. Finally, the classification algorithm proposed in this paper is applied to "social public opinion hot spot analysis", and nine different categories are tested, and the corpus data of different scales are compared and analyzed. The

中国知网 https://www.cnki.net

results show that the F1 measurement value of ml-svm classification model reaches 95.2% and 96.6% respectively in terms of recall rate and accuracy rate. It is verified that the network public opinion classification algorithm based on machine learning proposed in this paper has good performance.

22 Figures, 7 Tables, 60 References.

Keywords: Internet public opinion; machine learning; support vector machine; text classification;
Classification: TP391

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 分词方法.....2
1.2.2 特征选择.....3
1.2.3 文本分类算法.....4
1.3 论文的主要研究内容.....6
1.4 论文的组织结构.....6
第二章 网络舆情文本分类相关技术.....8
2.1 舆情信息概述.....8
2.2 网络舆情分类预处理.....8
2.2.1 网络舆情文本分词.....9
2.2.2 网络舆情停用词.....10
2.2.3 网络舆情语料库.....10
2.3 网络舆情特征提取.....10
2.3.1 特征选择.....10
2.3.2 特征降维.....11
2.3.3 特征统计算法.....11
2.4 本章小结.....12
第三章 基于词向量的舆情关键词提取算法.....13
3.1 网络舆情词向量化方法.....13
3.1.1 One-hot 表示法.....13
3.1.2 Word2vec 方法(CBOW).....14
3.2 网络舆情序列信息.....16
3.3 舆情关键词提取算法.....18
3.3.1 舆情关联规则.....18
3.3.2 关键词提取算法.....19
3.4 本章小结.....20
第四章 基于 ML-SVM 向量机的文本分类算法.....21
4.1 SVM 向量机基本原理.....21
4.2 ML-SVM 向量机分类算法.....22
4.2.1 网络舆情主题分类模型.....22
4.2.2 舆情预处理过程.....23
4.2.3 特征学习模块.....26

中国知网 https://www.cnki.net

4.2.4 ML-SVM 舆情特征分类.....28
4.3 ML-SVM 更新算法.....29
4.4 本章小结.....31
第五章 基于 ML-SVM 的网络舆情分类实验分析.....32
5.1 分类主题的确立.....32
5.2 系统的总体设计.....32
5.2.1 系统的基本功能.....32
5.2.2 系统体系架构.....33
5.3 ML-SVM 向量机分类算法实验分析.....34
5.3.1 性能评估指标.....34
5.3.2 实验语料选择.....36
5.3.3 分类实验结果.....37
5.4 实验结果与分析.....41
5.5 本章小结.....43
第六章 总结与展望.....44
6.1 结论.....44
6.2 未来工作.....45
参考文献.....46

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景与意义

随着网络媒体的发展，人们可以通过微博、微信、推特、抖音等新闻娱乐交流平台，自由地表达对某一事件的观点、情感、态度。各行业领域的热点事件出现在互联网社交平台上，而这种突发性的热点或观点形成影响社会的舆论[1]。互联网开放性和传播性的特点，使得当前舆情环境的信息变得更加复杂和多样性，而互联网媒体的自由性和匿名性也为具有主观偏向性的言论、虚假信息、消极的思想提供有利的传播条件。当前互联网社交媒体平台上，社会话题与言论的自由表达，充分体现我国社会民主化程度，与日俱增的关注度使互联网行业成为影响社会与经济发展的重要影响，其网络舆情主要由社会生活中突发的事件、虚假信息和负面舆论引起的[2]，消极的舆论冲击着积极的主流舆论，直接影响到社会与经济发展的秩序。

因此，利用文本分类信息技术对网络舆情予以有效的控制和引导，加强网络舆情的预警和监察，正确的应对社会经济活动中突发的事件，促进互联网媒体行业健康的发展尤显重要。迄今，互联网的数据日益快速增长，人们用文字表达自己的感受和观点，声音、图像和音频、视频表达方式也发展迅速。舆情信息调查分析发现互联网信息以文本形式表现为主，网络舆情分析实现对网络用户的舆论趋势监察、热门事件跟踪、产品和商品评价，如何从海量、复杂、多样等特点的信息资源中全面、准确地分类出有价值的信息，已经成为分类技术研究的重点。

传统的文本分类，是通过人工的方式来进行识别加工处理的，它消耗了大量的人力与资源，就像古代的史册编纂耗时且效率低。网络舆情复杂多样，根据互联网发布的文本数据与舆情进行关联，找出舆情的关键词，起到监测与预警舆情功能，而这人工去完成文本的分析是不具可行性的。为解决此问题，需要借助计算机强大的分布式处理能力的协助和支持，对海量的互联网数据进行全面、准确、高效地分类处理。

网络舆情会随着时间的推移出现一定的规律，而舆情的关键特征选择是实现文本分类首要条件，舆情信息碎片化会增加特征维度，也会产生舆情信息的稀疏问题。从海量的互联网信息文本中提取出最能代表舆情的几个或多个关键特征，并将原始特征集更换为最有代表意义的关键特征，可以最大限度降低文本分类过程中的时间和空间复杂度。本文从语言模型出发对网络舆情信息采用词向量编码分布，将关键词的提取，建立词与词之间的编码规则，形成固定长度的连续稠密词向量。分析舆情特征提取步骤，加强相关特征项在分类中的影响，考虑了文本信息之间或内部的特征分布。同时，本文分析舆情信息向量用实数表示与舆情信

中国知网 https://www.cnki.net

息的特征之间的相关性，将词向量应用于网络舆情文本分类处理过程中,本文讨论了舆情语义的词向量、舆情序列信息、舆情分类模型、舆情主题分类模型、舆情分类算法等，在现有的研究基础上与舆情特征相结合，进行优化和改良[3]。尤其是在舆情分类模型、舆情主题分类模型、舆情分类算法方面，使得机器学习分类算法在面对海量舆情信息复杂、多样性、传播迅速等情况下，依旧体现出良好的分类效果。所以，基于机器学习的网络舆情分类算法研究是一项很有意义的研究工作。

1.2 国内外研究现状

在分类体系或规则内对文本实现自动划分类别的过程称为文本分类，广泛的应用于信息索引、数字图书管理、情报过滤等领域[4]。文本分类流程中关键的步骤是分词方法、特征选择和分类算法，本文结合网络舆情分类综述国内外目前在此领域研究现状。

1.2.1 分词方法

目前，国内的分词技术不断发展和改进，其研究的领域主要分为三大类：字符串匹配、语义分析和统计分析。汉字文本词与词之间不像英文文本有空格符号区分，汉字需要用分词的算法去分割词，英文有单数与复数之分，需要转换形态。所以对汉字进行分词处理主要是：词典训练和测试样本集、分词系统、通过改进算法而建立分词模型。

目前，分词系统主要包括英语分词器 stopanalyzer、standardanalyzer、simpleanalyzer 等，以及 ictcias 分词系统[5]，该系统使用级联隐马尔可夫模型进行分词，提出一种以中文分词、词性标识、分词消歧、未注册词识别等问题的理论框架，以提高分词的准确性和效率。THULAC 分词工具[6]主要采用国际 UTF8 字符编码，不支持其它的中文字符编码分词，计算准确率与效率较高。Jieba 分词工具[7]提供专业的中文分词库，具体实现过程把待分词的文本与专业词库比较分析，并引用图论的方法动态获取最大概率的词组,从而实现中文的分词。斯坦福分词工具[8]通过相关的算法对中文分词技术进行研究、从中文标注语料的获取、分词模型训练与封装，对于学术资源信息分词准确率高、稳定性强且可扩展性较好。

分词词典是文本分词的重要组成部分，许多学者利用相关算法对分词词典开展探索和研究，进一步的改进文本分词效果。2019年，胡欣杰等学者[9] 针对各类分词词典进行对比与分析词典构造的差异及优缺点，通过分词的过滤条件下，从而提出一种基于双数组的分词词典，实现部分解决分词过程中未登录词过多的切分问题，但该方法利用数组的方式存储数据。2019年，张文静等学者[10]在中文

中国知网 https://www.cnki.net

分词模型是以字为单位进行多粒度分词，字为一个汉字，而引入词实现两个汉字的多粒度中文分词模型，模型中利用双字向量在一定程度上消除单字歧义，但是在中文词组上有待完善。2019年，冯雪等学者[11]针对基于字的模型和基于词的模型融入字典信息进行错误比较，探索词典的差异性，但词典的选择上有局限。2018年，宫法明等学者[12]针对专业术语相关的词进行提取，通过现有的隐马尔可夫分词模型，先用专业词典和互信息等步骤提取组合词，再通过分词内容的语义、语法建立约束矩阵，以达到辅助分词的目的，以此构建一种自适应隐马尔可夫模型的分词算法，此算法的处理步骤相对繁琐，效率与速度会根据分词内容的规模有影响。

改进算法是建立分词模型，许多学者在传统的分词基础上，通过改进和优化已有的算法，并在特定的领域分词实验，验证分词算法的准确率与召回率。2019年，蒋卫丽等学者[13]通过隐马尔可夫模型对操作文本信息预处理分词，依据“搜狗领域专业词库”，专业领域词汇中提出一种领域词典的动态模型分词算法，解决专业名词的文本分类问题。2015年，刘泽文[14]针对舆情信息短文本的特征，采用条件动态模型对短文本进行分词，外部条件的随机性需要动态规划标记并进行特征优化，改进的算法可以提高传统分词的正确率和查全率，但由于分词过程中存在词未知和词歧义重叠等问题，因此该方法的选择有一定的局限性。

从上可知，舆情信息会随着网络的发展出现很多新的网络词语，解决未登录词的问题带来巨大的挑战，如何解决未登录词的识别问题，是本文重点要考虑的问题。网络舆情信息的特殊性缺少专业领域的词典，而充实专业领域的词典信息也非常重要。分词中很容易产生有歧义的词，如何利用上下文本关联和语义信息消除歧义词。由文献分析发现汉字分词的难度主要有这三点：未登录词识别、与舆情相关的词典，消除词的歧义性。

1.2.2 特征选择

文本分类的过程中特征的降维对文本分类影响较大，特征降维包括特征的提取和选择。特征提取主要原理是对原网络信息文档，根据舆情的特征采用一种新的表示形式，特征提取解决空间向量的维度问题。特征选择主要是对原特征集进行筛选，保留原有的文本特征。文本分类利用特征选择方法对舆情信息进行筛选，利用特征集生成分类器，可以进一步提高准确效果。

针对网络舆情信息有着长文本的特征，网络舆情新闻文档的特点是：维度高、内容杂、同量稀疏。在保证分类结果的准确率，尽量减少样本的训练时间，众多学者利用算法进行特征降维，提取出能反映舆情长文本的特征词，一些学者在传统算法的基础上进行优化，一些学者根据涉及的领域不同，提出了新的特征提取

中国知网 https://www.cnki.net

算法和模型。任永功在《基于信息增益的文本特征选择方法》中提出了 TDPIG 算法[23],主要是因为采集的数据不平衡性的影响，将特征出现概率进行量化，并根据信息的内容设置权重，为了减少不平衡数据集对特征选择的影响，提出了一种基于信息增益的文本特征选择方法，该算法不仅可以减少特征值的计算时间，而且可以有效地提高计算与分类的精度。文献[24]提出了 TF-KAI 算法，考虑文本间词语的相同与文本距离的影响，以词和簇作为特征单元的聚类权值生成向量空间模型，提出了一个基于多语义因子分层聚类的文本特征提取算法。该算法单层聚类每个簇对应的特征值计算不同，这会对处理的速度有影响，优点是引入相关词，在多层聚类对应了不同的阈值。文献[25]提出了 BPSO 算法，采用二进制粒子群优化算法进行优化，决策空间中粒子的相似度决定了粒子的相似度指数，并且通过适度调整局部搜索的范围，经过特征选择筛选后分类的精度更加精准。文献[26]针对混沌模型的特点，在更新机制中初始粒子的多样性和引入自适应因子。文献[27]提出了 PSO 算法，针对局部优化问题，通过自适应地调整权值，提升粒子群算法的应用，并建立粒子适应度评价体系。文献[28]提出了 VBBPSO 算法，通过采集的文本向量进行编码过程中，发现文本的稀疏性引起计算的复杂性，骨干粒子群优化算法将离散的问题转化为矩阵方法进行优化解码，以此来选定的文本特征值。

从上述工作证明将舆情信息以短文本的信息为多，所以将研究短文本的特征选取的算法，并结合以上特征值的提取算法，不仅能解决问题，还能大幅度提升分类的性能。舆情信息文本通过舆情预处理后，文本的分词结果具有稀疏的特征，不能精确地表达事件突发舆情信息。因此，本文将综合以上参考文献的算法改进信息的原本特征选择方式，通过稀疏特征编码的方式恢复原始特征其特征也进行压缩转换，空间复杂度也得到了很好的解决，从而保证的分类器 效果的稳定性。

1.2.3 文本分类算法

网络舆情文本分类不仅是领域的语言处理问题，也是对舆情信息识别的问题。将机器学习算法应用到网络舆情文本分类领域，常用的分类方法存在领域性适应能力差、算法处理过程中所需要的时间、空间复杂度较高等问题。学者在这方面的研究，主要的文本分类方法有：朴素贝叶斯算法[29]、支持向量机(SVM ,Support Vector Machine)算法[30-37]、神经网络算法[38-39]和决策树算法[40]等。

目前很多学者对文本分类的研究主要基于神经网络算法，同时根据算法的优缺点进行优化流程。CNN-AKNN[41]算法 Convolutional Neural Networks，针对文本特征提取不全面问题，讨论了基于加权卡方最近邻优化算法的特征文本训练，

中国知网 https://www.cnki.net

并将注意机制和卷积神经网络应用到文本分类过程中，从而实现全局和局部特征的提取，从而达到更有利于隐藏特征提取的目的。NLDA 算法[42]，以神经网络作为输入层，拟合主题-关键词-文本的概率，构建基于神经网络的文本分类算法 NLDA。针对局部词向量表示的不足特征，引入全局词向量统计信息特征，解决了模型的远程依赖关系，有效地提高了语言模型的性能。针对卷积神经网络和循环机制，实现文本之间的语义信息，提出一种基于深度学习的特征融合模型分类表示方法，从而降低文本表示对分类结果的影响[45]。

针对网络舆情信息的非线性问题，有些学者根据向量机支持高级数据运算的功能，不断地完善向量机（SVM）文本分类算法，比如情感分类、语义学习、消极性短文本识别、新闻分类等方面进行探讨，对网络用户的情感倾向、消极性、态度的文字特征值的提取有很大帮助[46]。针对海量的数据文本，将深度学习应用于特征提取，并与支持向量机算法相结合，从而实现深度的文本分类[47]。研究支持向量机核函数参数的改进算法，从语音中分类出情感词汇，该算法结合 Fisher 准则、最大熵原理与支持向量机的核参数方法，实现从语音信息识别出情感信息，舆情信息中最难取的特征就是情感方面的信息[48]。在文本分类问题上，首先提出将训练数据进行区域划分，然后利用支持向量机对小样本数据进行分类，将区域划分与 SVM 相结合实现提高文本分类的准确率[49]。根据中文的语义在情感中的特征进行分析，并对短文本属性的稀疏性特征，提出一种基于 SVM 的高维混合特征模型，此模型对短文本情感分类上有效，但随着规模扩大效率上有所影响[50]。根据 SVM 模型在情感分类过程中，加入混合特征向量生成云向量的方法，提取文本情感词，并以此建立多级文本情感分类算法，筛选的工作量相对较大，但此算法在分类准确率与训练效率上有着显著改善[51]。文本分类需要良好的计算速度，对硬件要求较高特别是规模较大的数据量，此文拟定分类器使用 GPU、Hadoop 及 Spark 提高计算速度，但从分类算法上无明显改变[52]。在传统的向量机上参数缺陷上，通过自适应调整 SA—SVM 优化参数的方法，并与同类优化算法对 UCI 数据集进行性能比较，从而达到优化算法的方法，效率有待提高[53]。传统支持向量机并不能应用舆情方面，支持向量机分类器泛化方法通过参数的优化建立函数值，使用蚁群优化算法遍历优化函数值，以找到合适的参数值组合[54]。

从上可知，SVM 在网络舆情信息方面有着良好的分类表现，众多学者的研究热点包括新闻短文本、消极短文本、论坛评论，评论情感与语音情感类等，并与其它的分类算法进行比较，向量机 SVM 性能更稳定。其次，发现文本分类的技术应用领域逐步以短文本、句子研究文本表示方法，并对文本特征值的参数进行优化。综合以上的因素，本文将首先对词向量与舆情信息征相结合，并根据短文本稀疏、维度的问题改进词向量编码的分布式信息编码方案。然后，探讨序列信息

中国知网 https://www.cnki.net

在文本中的本质，通过对内容的词进行分析归类划分，建立舆情信息的序列信息关联列表，实现词性的对比分析。最后，依据词与词之间的距离，建立上下文的关联方案，建立有监督文本表示的舆情语义和序列信息的学习模型。

1.3 论文的主要研究内容

本文主要研究基于机器学习的向量机网络舆情分类算法。目前，网络舆情监测主要是对网络各媒体上出现的热点事件，产生的舆论影响做出审视，其信息的突发性、随意性等特征影响舆情的采集。利用机器学习自动实现文本敏感词的提取，可以大幅度提高数据准确率，降低错误。因此，本文基于机器学习、SVM 理论模型提出 ML-SVM 改进文本分类算法。主要内容包括：

（1）提出一种基于词向量的舆情关键词提取算法。通过对短文本表示方法的分析，对网络舆情信息短文本的关键词提取和关联的规则进行探讨，从局部舆情序列到全局舆情序列对舆情词性进行分析对比，并结合词向量与舆情语义特征进行分析，针对网络舆情信息进行预处理，以此构建舆情关键词提取算法。

（2）提出基于 ML-SVM 向量机的文本分类算法。首先在概述传统的 SVM 向量机基本原理基础上，描述了二元的线性分类方案，针对网络舆情主题提出了舆情主题分类识别模型方案。此方案提出一种舆情信息特征与香农定律相结合建立舆情新词发现机制，从而解决训练文本信特征不足问题。为更好的衡量舆情信息间的亲疏关系，建立舆情文本信息更新算法，通过仿真实验在不同中数据集中进行对比分析，实现召回率、准确率、F1 测度值等验证本文算法的有效性。

1.4 论文的组织结构

本文一共分为六章，论文组织的主要结构如下：

第一章绪论。本章阐述了互联网媒体发展的背景和意义，分别论述网络舆情定义、类型、分词方法、特征选择及分类算法的应用领域。并依据现有的分类算法拟定研究的主要内容。

第二章阐述了网络舆情信息应用领域、概述舆情信息的预处理需要进行文本分词、去停用词、构建语料库，总结分析各类算法优缺点。

第三章从短文本中获取舆情信息关键词，根据已有的词向量原理，结合网络舆情的特征进行词向量编码，针对网络舆情进行预处理，以此构建舆情关键词提取算法。

第四章提出基于 ML-SVM 支持向量机算法。首先在概述传统的 SVM 向量机基本原理基础上，描述了二元的线性分类方案，通过舆情信息特征与香农定律建立舆情新词发现机制，解决了训练文本集特征不足的问题；为更好的衡量舆情信息间的亲疏关系，建立舆情文本信息更新算法，并通过不同数据集上的仿真实

中国知网 https://www.cnki.net

验与对比分析，验证了本文算法的有效性。

第五章实验仿真结果，从性能上设置评估标准，主要针对网络舆情文本分类器的实验测试，包括召回率、准确率、fi、时间性能等常用的评价标准。然后，使用 ML-SVM 分类模型进行实验仿真，分类测试在性能上优于其对比实验。

第六章：总结全文的研究工作并对未来研究工作做出展望。

中国知网 https://www.cnki.net

第二章 网络舆情文本分类相关技术

随着网络舆情信息数据的爆炸式增长，人工处理已经不再可行。基于机器学习的方法采用计算机程序进行自动处理，而网络舆情信息需要提前处理，如统一编码、文本域分析提取、错误词去除、文本分割等。网络舆情的分类对象范围很广，包括互联网中的论坛、微博、留言板、视频、音频等，不同的媒体处理对象都有各自的特点，分类方法需要建立相应的分类模型。

2.1 舆情信息概述

网络舆情涉及的领域较广泛，舆情信息主要围绕着政经舆情、名人舆情、公共案例、社会民生、教育舆情、司法案件、政策法规、医疗卫生、竞技体育等领域，热点的事件很容易产生社会舆论。

（1）政经舆情。新冠肺炎疫情的全球蔓延，各大城市采取的不同的限制措施，经济下划趋势逐渐加大，而以美国为首的政府利用舆论信息提出“中国负责论”，向中国政府索赔等舆论把我国推到极不利局面，而我国承担起大国责任，采取一系列的措施，迅速恢复国民经济。

（2）名人舆情。近几年网络新闻报道中的名人事件，对网络环境产生了很严重的污染，如“杨振宁去世”，而产生的流量成为部分网络账号的利益，诱导网民进行追逐热点，发表不当的言论。

（3）教育舆情。师德师风问题频繁爆发，学生忌惮教师的地位，一些师德失范的教师引发舆论的聚焦，同时也暴露学校日常管理的缺陷。一些民众在网络中传播的舆情信息产生非常大的影响 ，也间接影响到涉事教师所在城市与学校的好感度。

（4）社会民生。最近社会民生类事件与疫情相关较高，舆论中标题为博关注度，任意使用如：“山东青岛核酸检测外国人插队”信息，引发舆论对当地政府部门处理方式的质疑，使当地政府部门的公众形象受损。

综上所述，网络舆情是由对不同领域出现的问题的观点舆论信息，它有着很强的影响力、倾向性特点，也是网民在情感、意见、观点的一种表达互动方式，而如何有效的监管为政府在处理方式上提供帮助。

2.2 网络舆情分类预处理

网络舆情来源于网络的媒体如论坛、微信、微博、留言、评论区等，舆情信息的采集及分类与自然语言分类处理有着必然的联系。从数据类型可以分为文本、图像、音频和视频，网络舆情数据选择文本信息最为合适，社交媒体的日常话题领域种类较多，用户评论的信息广泛等特点。网络舆情表达的自由性、观点的多元性、交互方式等特点。

中国知网 https://www.cnki.net

而网络舆情信息的预处理是分类技术的第一步，中文表达的是每一段话只有标点符号进行分隔，英文的表达方式是每个单词间有空格连贯的，计算机只能对单个词语进行分类，而无论是中文或英文都会有介词、连词、语气相关词，这些词会影响分类的效果，所以需要在进行分词后去掉这些停用的词。

2.2.1 网络舆情文本分词

目前，国内的分词技术不断发展和改进，其研究的领域主要分为三大类：字符串匹配、语义分析和统计分析。如何快速实现对文本的精准分词、提高效率，也是当前研究热点之一。网络舆情信息进行分类首先要解决舆情特征项提取，舆情信息的复杂性、多样性的特点也为舆情分类带来困难，所以如何从网络信息文档中提取出特征项，就需要使用到分词技术。英文的基本单位是单词，语言结构上就用空格区分每一个单词，相对于中文更容易实现词分离，英文分词的步骤：首选根据空格、半角符号、段落结束符等分隔，英文重点通过相关的匹配算法实现词组关联，可以很好的反应出舆情的导向信息。然后，根据各类语法的规则将与分类所需不相关的介词、代词、连词等特征进行过滤掉。最后，根据算法 Lancaster Stemming 规则提取词干，完成单词组的映射。

中文分词以词、词组、句和段划界，而且中文词组灵活多样，中文的词与词之间歧义相差很大，舆情信息需要从词中提取出敏感、热点、观点等信息。把词从文本中分离成相对独立的词，与训练集中敏感词进行比对，才可以确定出事件的突发性，所以中文相对于英文分词难度大。

举例说明：英文句子“Research on the classification algorithm of network public opinions based on machine learning”，其中文含义为“基于机器学习的网络舆情分类算法研究”，计算机通过空格符号来区分单独的英文单词“learning”,但针对于中文“学”，“习”分词就不能表达出这个词的意识，只有将两个字组合在一起才能解释起含义。通过中文分词系统分离出“基”、“于”、“机器”、“学习”、“的”、“网络舆情”、“分类”、“算法”、“研究”九个特征项。

中文分词是汉字语言分析和信息挖掘的基础，本文主要采用 python 语言下的 Jieba 分词工具，因为此工具的词典包含 2 万多个日常用语料，并且每个词来源都是建立在新闻报刊、网页信息、焦点新闻等语料资源，其本身构建了语料词典 dict.txt。该词典将汉字嵌入到一棵前缀树中，非常利于词的统计、排序和存储。网络舆情信息主要发生媒介可以借用 Jieba 其丰富的新闻语料库资源，也是舆情分类算法实验分析最佳工具，Jieba 分词还结合 Viterbi 算法，以此来解决没有登录词的问题即词典中没有词的识别问题，而舆情信息会随着网络的发展出现很多新的网络词语。

中国知网 https://www.cnki.net

2.2.2 网络舆情停用词

网络舆情信息的采集过程中，会出现日常用语的一些词，如“一般、通常、如果、还是、啊”等，这些词会给机器学习过程增加额外的计算难度，而这些词语对我们判别舆情的发生作用很小，所以需要将这一部词进行分词后进行剔除。去除这些词最有效的方法是建立停用词表，利用停用词的表进行比对从而实现过滤操作，目前停用词表可以根据百度停用词表来实现。

2.2.3 网络舆情语料库

语料库以数字化存储自然语言某个领域的知识，是将非结构化信息通过相关规则收集和整理的语言材料。它是通过科研人员对某个行业领域交流的语言进行实例样本汇总而成的信息数据，并且有一定的价值和规模能够客观反映文本语言的实际应用。它的主要特征表现为计算机介质存储的数据、交流环境衍生信息、加工和处理的信息。语料库提供多个领域的数据，包括词典编撰、语言的研究、社会文明的发展都具有重要的意义。

目前，很多的学者对文本分类研究重点关注，根据各领域建立语料库同样具有重要的意义。语料库的内容主要用于为文本分类模型提供训练与测试的样本，在实验分析中建立两个数据集：测试文本集和训练文本集。文本预处理过程中将训练文本集的数据进行预处理、特征选择 、去除停用词、新词发现等操作，经过此加工和处理的训练文本集放到分类器进一步实现训练，并通过优化和调整参数，提高分类器的分词准确率。最后，通过文本分类器完成测试文本集的分类测试，分别用于短文本或长文档测试，测试分类结果的准确率，比较分类器结果是否在效时间范围内，因此达到检验文本分类算法的有效性。本文中我们使用社会舆情热点分析九大类别文本分类语料库[57],因其语料库是对新闻类汇总，分类体系包括的分类节点较多，每一类下面又存储万余篇网页文档，而网络舆情信息就是通过网页页面存储舆情信息的，所以选择舆情热点作为文本分类语料库。

2.3 网络舆情特征提取

互联网平台的舆情信息分析研究过程中，主要是对发现的内容主流的态度来进行分类检测，通过分类的检测舆情内容确定评论是正能量还是负能量的，而评论区的信息有着不同的特征，有些词语可能帮助我们进行判断，但有些词语确可能会影响我们的判断真实性，舆情信息的复杂性就在于如何通过舆情的特征来实现最后的判定分析。

2.3.1 特征选择

舆情信息的判定最直接的方法就是统计敏感词出现的频率即出现的总次数，根据舆

中国知网 https://www.cnki.net

情词频提取网站中的信息，当某文档中出现的舆情词超过设置的最小值，如果超过就将舆情词保留排序，反之就去除该舆情词，保留的舆情词就表示为网络舆情的特征项。舆情特征选取的算法就是根据舆情特征的词出现的频率来判断是否可以作为特征词。排序的关键点通过发帖量、浏览量、回复数等进行总分排名。比如“甲型 H1N1 流感肆虐”，事件传播过程中，病毒引起的恐慌加速该事件的传播速度，这事件当中分词后我们判定为负类，分词过程中为“甲型”、“H1N1”、“流感”、“肆虐”，这双词搭配就可以判定它的类别为负类，而这种双词的搭配就是舆情的特征，而还可以实现三词搭配、四词搭配、N 词搭配进行舆情特征的选择。

2.3.2 特征降维

特征降维，从网站文档中获取舆情词的特征数量。包含两类含义，一种是建立少量的特征词从而降低机器处理的时间，提高判定的效率；另一种是通过上下文的关联度判定某个词语在整个互联网出现的舆情数量的总和，统计每个帖出现舆情词的总的文档数量，如上一小节的例子中，采用单个词进行评判如“流感”，而在整个网络平台中检索这个词，我们就认定为负类，此方法减少特征数量的判别，通过统计的方法寻找目标分类相关联的词语，其它统计的思想是通过设置最小阈值或最大阈值进行舆情特征判定，超过阈值进入下一舆情词选择，否则就设为舆情特征项，需要统计训练文本集中计算机整个文档的集合，对所有的数据集都可特征降维，舆情文档频率提取特征，适用于大型的语料库。

2.3.3 特征统计算法

在网络舆情信息处理过程中，我们要对舆情语料库中的信息进行处理，提取舆情特征进行分类。网络舆情信息进行预处理后，需要从中提取出有用的特征，并且根据信息的来源选择有信息表达准确的舆情特征，改进算法舆情特征统计的算法 ，提高训练的效率。

针对网络舆情信息有着短文本的特征,简单的评论和观点，数量之多，信息量大和特征稀疏等显著特点。研究舆情信息的短文本的特征提取算法十分重要。目前，许多学者对短文本的特征提取方法存在的不足,对传统的特征提取算法进行优化与改进。文献[15]提出了 SFESGS 算法，针对短文本词语间与上下文的关联，词与词之间的稀疏等特征，提出融合语义与图结构的短文本特征算法，此算法较好的解决词语间的语义关联问题，使词语间的相关度更为贴切。但不考虑图结构特征，而重点对语义进行耦合。文献[16]提出了 CDCISE 算法，针对论坛出现的短词语分布稀疏的问题，改进文本间的间隔词数计算方法，动态调整词的权重值进行降序排充，选择前 N 个词为特征词集合。该算法未考虑到文本间的符号会影响词与词的间隔，词与词的间隔也是一种上下文间的关联，所

中国知网 https://www.cnki.net

以该算法相关度的运算只靠间隔词还是有局限性。文献[17]提出了 TF-IDF 算法，针对特定领域实现短文本特征提取，此算法调整文本特征向量权重的方式来提升算法性能。该算法是对某个特殊行业的领域进行分类，不预先构建词向量词典，这种方法的分类效果很难保证准确率。文献[18]提出 MCFS 算法，以短文本的信息特征影响着机器学习分类算法为背景，构建一套系统的短文本分类框架，主要基于 CNN 的分类系统词向量嵌入、特征选取、主题合并策略等方面，降低短文本预处理的难度。该算法根据原始文本的词对应主题特征，也是我们将引入的方法，分类器的选择上可以选择多个分类器进行测试。文献[19]提出了 SSE-BOW 特征模型,该学者通过爬虫微博新闻数据集进行中文短文本分词研究，建立基于语义与相似度的特征扩展模型，并对模型采用不同粒度文本扩展的短文本分类模型进行对比分析。该算法扩展权重方面，权值的设置可以通过训练样本集进行优化。文献[20]提出了 BSAT 模型，分别实现字粒度的字向量与词粒度形式的信息划分，从双向长短时记忆神经网络和注意机制提取文本特征,分类预测并标签每个单词，单个字向量模型校正词向量模型的关键词抽取结果。文献[21]提出的 PNE 算法，针对海量文本分类中的特征降维问题，分别从海量文本集、邮件、微博新闻推荐、微博短文本情感研究分类的方法，算法比对三种有代表性的噪音消除算法，并完成两个常用数据集上实验验证，算法有效地降低运行时间，并提高较快的分类准确率。文献[22]提出的 FS 算法,针对短文本信息量少、高维稀疏的特征和传统特征提取方法缺乏语义的问题,选用多因素融合的特征函数 FS,消除稀疏文本的冗余,有类别区分能力特征的权,并验证方法的有效性。

2.4 本章小结

首先，阐述了网络舆情信息涉及的领域 ，对网络舆情分类进行概述。然后，概述舆情信息的数据分类的预处理需要分别进行文本分词、去除停用词、构建网络舆情语料库，网络舆情领域的知识的语料库及训练方法特为重要，以大量的训练文本建立模型，计算量大、分词精度及准确性难以控制，为提高分词的精度及准确性。最后，总结相关文献的特征统计算法，分析其优缺点，为后续的研究打下基础。

中国知网 https://www.cnki.net

第三章 基于词向量的舆情关键词提取算法

网络舆情信息多属于非结构化的数据,采用机器自动分类处理的方法从短文本中获取舆情信息关键词,比如热点、敏感词、情绪、观点等,但其非结构化的数据增加了机器学习时间与空间复杂度。为解决此类问题,首先根据已有的词向量原理，结合网络舆情的特征进行词向量编码，采用 one-hot 与 Word2vec 方法实现舆情信息上下文输入，预测舆情信息关键词对词向量进行编码处理，编码方式更加有利于文本分类处理速度。其次探讨舆情序列信息主要从局部序列到全局序列分析舆情序列信息的本质含义，结合词向量与舆情语义特征进行分析，针对网络舆情信息进行预处理，以此构建舆情关键词提取算法。

3.1 网络舆情词向量化方法

网络舆情信息是日常生活中的语言，不能够被计算机所理解，需要通过机器学习模型转换成可以处理的词向量。将舆情信息进行词向量（word embedding）编码，减少存储量，更好的实现词与词之间的相似性比对，如何计算一段舆情信息在某个媒介平台上出现的概率，将有助于舆情信息的监测。目前，基于词向量的文本表示的方法主要 one-hot 表示法与 Word2vec 方法。

3.1.1 One-hot 表示法

首先，词向量是基于分布式结构的语言模型，舆情信息文本每个部分的位置与其它的元素位置信息相互有联系，它根据语义与句法的需要，各元素分布位置相对固定和受限，舆情反映出来的含义也不同。舆情信息的表述上可以是一个词、一个表情、一个词组、一段文本，每个文字的语义可以通过一个相关性网络进行描述，可以得出舆情信息的语义呈现分布式并相互之间有着关联关系。在舆情信息语义处理方法，信息经过预处理过程之后，运用相关的算法将非结构化的信息内容进行整理及编码，形成计算执行和识别的程序。网络舆情信息主要比较杂乱，所有的文本信息呈离散表示，而最初文本的表示方法主要为离散表示（One-Hot Representation），每单个词被看成一个最小的符号，将网络舆情的信息通过语料库处理后形成一个词表，利用词表的大小维度为每个词建立向量模型,中文常用词总计 3500 个，则每个汉字的表示需要 3500 向量维度，此向量表中依据中文字典建立索引，对应词语的索引为 1，其余词维度的值设置为 0，从而将词语编码成 0 和 1 表的示的固定维度的向量，例如“造成”和“产生”就可以表示为：

造成[0,0,1,0,0,……0]

产生[0,0,0,1,0,……0]

从以上例子可以发现离散表示的信息存在的问题，主要表现为：

中国知网 https://www.cnki.net

（1）维度较高。网络舆情信息的词规模通常呈现出爆炸增长，向量的维度等于词表的大小,如果给每一个词都生成向量模型，词向量的维数灾难严重，通过机器学习算法时会产生较高的时间和空间复杂度。

（2）词义分散。离散的表示给第一个词分配一个编码，词与词之间的语义关系不能突出关系 ，组合过程中很难逾越词之间的联系，通过机器学习算法是也会产生时间与空间的复杂度。

3.1.2 Word2vec 方法（CBOW）

Word2vec 是 Google 发布的一款开源词量训练工具， One-hot 编码方式，其缺点会随着词个数的增加，向量的维度会不断增加，其计算机的复杂难度也会相应增加；One-hot 编码使词义分散，词与词之间的相似性很难判断。Word2vec 工具使得运算效率和效果有明显的提升。目前，主要使用连续词袋模型（Continuous Bag of Words,CBOW）方法进行向量编码。

CBOW 模型可以通过目标的舆论信息的语境推测出可以出现的舆情词，进行分词时，把所有舆情数据进行向量化。首先需要使用一个语料库进行训练数据，训练完成后生成舆情和向量的对应表，具体的训练流程图如下所示：

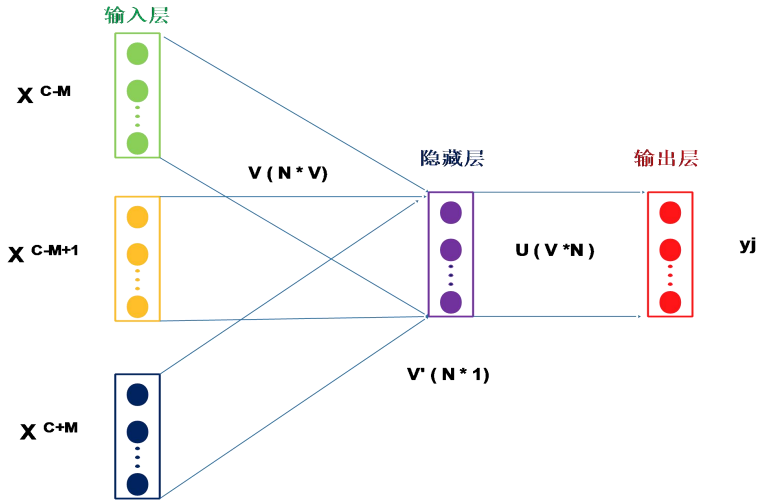

图 3.1 CBOW 模型示意图

其中，CBOW 模型为三层，第一层为输入层：X^c 为舆情词，X^{c-m}，…,X^{c-1},X^{c+1},…,X^{c+m} 以 one-hot 向量形式目标舆情信息的输入模型。第二层为隐藏层，当模型计算时通过公式 $V^{`} = \frac{1}{2m}\sum_{i} VX^{i}$ 来完成。第三层为输出层， $y = soft\max(UV^{`})$，隐藏层中的 $V^{`}$ 即为输出的向量,通过 CBOW 模型可以把相关舆情信息的上下文作为输入 ，从而实现上下文词来预测舆情词，CBOW 模型的方法大致分为五步：

（1）在输入层，将舆情信息的上下文采用 One-hot 进行编码，例如表 3-1 所示训

中国知网 https://www.cnki.net

练样本句为”Network public opinion classification based on machine learning”，以训练第 6 个样本为例：选定“machine”为目标预测词，维度 V*1。

表 3-1 舆情信息样本列表

Input1	Input2	Input3	Input4	target
classification	based	On	learning	machine

（2）在输入层进行舆情信息的上下文信息的向理处理，首先通过计算每个周围词的词嵌入向量：得到$(v_{c-m}=V_{x_{c-m}},...,v_{c-1}=V_{x_{c-1}},v_{c+1}=V_{x_{c+1}},...,v_{c+m}=V_{x_{c+m}})$；例如：“classification based on machine learning”此段句中除了“machine”其它词嵌入向量进行向理化得到如下：

“classification”：[0,0,0,1,0,0,0,]

“based”：[0,0,0,0,1,0,0,]

“on”：[0,0,0,0,0,1,0,]

“learning”：[0,0,0,0,0,0,1,]

（3）将所有周围词的词嵌入向量加和取平均值，得到$\tilde{v}=\left(\sum_{i=c-m,i\neq c}^{c+m} v_i\right)/2m$；初始化权重矩阵 W，设定词向量的维度为 3：

$$x\cdot w=\begin{bmatrix}0&0&0&1&0&0&0&0\\0&0&0&0&1&0&0&0\\0&0&0&0&0&1&0&0\\0&0&0&0&0&0&0&1\end{bmatrix}\cdot\begin{bmatrix}1&2&1\\2&4&3\\2&5&-1\\1&2&1\\-1&1&0\\0&1&0\\0&0&-1\\2&2&1\end{bmatrix}=\begin{bmatrix}1&2&1\\-1&1&0\\0&0&-1\\2&2&1\end{bmatrix}$$

求出平均作为第二层隐藏层向量 h：

$$\tilde{v}=\left[\frac{1-1+0+2}{4},\frac{2+1+0+2}{4},\frac{1+0-1+1}{4}\right]=\left[0.5,1.25,0.25\right]$$

（4）计算打分向量$z=U\tilde{v}$；

中国知网 https://www.cnki.net

初始化权重矩阵$w' = \begin{bmatrix} 2 & 0 & -2 & -1 & -3 & -1 & 0 & 0 \\ 1 & -1 & 0 & 2 & 1 & 4 & -2 & 1 \\ 0 & 2 & 1 & -2 & 0 & 0 & 3 & -1 \end{bmatrix}$

在隐藏层中得利用公式进行计算：$U = h \cdot w'$

$$z = \begin{bmatrix} 0.5 & 1.25 & 0.25 \end{bmatrix} \bullet \begin{bmatrix} 2 & 0 & -2 & -1 & -3 & -1 & 0 & 0 \\ 1 & -1 & 0 & 2 & 1 & 4 & -2 & 1 \\ 0 & 2 & 1 & -2 & 0 & 0 & 3 & -1 \end{bmatrix}$$

$$= \begin{bmatrix} 2.25 & -0.75 & -0.75 & 1.5 & -0.25 & 4.5 & -1.75 & 1 \end{bmatrix}$$

（5）将打分向理归一化为概率，得到$\tilde{y} = soft\max(z)$。每一维度上的值代表属于该维所对应词的概率，根据概率可以预测舆情的出现程度。

$$soft\max\left(\begin{bmatrix} 2.25 & -0.75 & -0.75 & 1.5 & -0.25 & 4.5 & -1.75 & 1 \end{bmatrix}\right)$$

$$= \begin{bmatrix} 0.087 & 0.004 & 0.004 & 0.041 & 0.007 & 0.829 & 0.002 & 0.025 \end{bmatrix}$$

因此从语言模型基础之上对网络舆情信息采用词向量编码分布方法，词向量分布式的基本思想是：将舆情信息的每一个词通过训练形成固定长度的连续稠密词向量，每一类的词向量维度介于 50~1000 范围内，且区别每类舆情信息采用信息的向量都使用实数表示，将所有的向量放在一个向量空间，每个词转换为空间的一个点，每个点在空间中引入“距离”，根据词之间的距离（余弦度计算）来判断它们的语义、词性上的相关性，能够捕获时序文本上下文语义特征，依据其特点实现舆情信息的综合编码。例如“造成”和“产生”就可以表示为：

造成[0.45281,-0.50108,-0.53714,0.015697,0.22191,0.54602…]

产生[0.1108,-0.38781,0.57615,-0.27714,-0.70521,0.53994…]

通过计算余弦相似度为 0.9218（相似度取值区间为[0,1]）,表时这两个词的向量空间上距离是非常相近的，从而也证明“造成”与“产生”在语义上是相关性。因此，利用词向量与舆情语义相结合的分类方法，建立预训练文本集初始化词，并在训练集中对词向量进行迭代更新，从而有助于网络舆情信息的文本分类精准性。

3.2 网络舆情序列信息

网络舆情序列信息指的是有规律和有顺序的舆情文本信息，序列信息体现在文本信息的语法、语义、逻辑结构上，例如形容词一般修饰名词，副词修饰动词，介词来连接地点与时间；语法中按照主谓宾的结构排列；所以词序可以反映句子的语法、语义和逻

中国知网 https://www.cnki.net

辑关系。通过学习序列信息可以达到学习句子语义的目的。而句子又是构成长文档的基础，各段落中又有因果、递归关系 ，学习句子的顺序信息也就学习到文章的逻辑结构，从而根本总结出舆情的重要信息。网络舆情信息的文档中，通过对内容的词进行分析归类划分，可以推测出文档存在的舆情信息是否具有导向性，如果按照序列阅读与分析，就可以很大程度上掌握舆情的爆发点，例举一段话进行分析见表 3-1 所示。

表 3-2 舆情词性分析对比

类别	词性分析对比
网络新闻原文	国际货币基金组织在实时报告显示，新冠病毒的爆发，导致了石油的价格爆跌降价20%，这样的价格爆跌，起码使全世界很多的海湾地区损失了数百亿美元。随着全球持续受新冠病毒的影响，人们对石油的需求量急速下降，海湾地区必须对此次疫情进行更深层面的改革，否者造成的损失将达至数万亿美元。作为占了全球石油需求增长量 3/1 的中国，此次的新冠病毒正对中国产生着巨大的影响，如果新冠病毒导致中国进行二次“封城”，那么影响将会持续扩大，并对国内实体经济造成更加严重的影响[59]。
词性比例	爆跌，损失，全球，新冠病毒，石油，改革，价格，持续，影响，扩大，国内，需求，实体经济，海湾地区，

从词性比例表示中可以推断出新冠病毒的爆发，导致海湾地区的石油价格爆跌了20%，但是很难知晓海湾地区的市场行为是否影响着国际的石油价格，虽然分析的过程带有主观上的因素，所以如何将序列信息用于文本分类学习模型中，进一步去验证序列信息对文本分类的影响。

网络舆情信息文本分类出现，舆情的信息文本如何表示非常重要，也是文本语义处理任务的基础。舆情文本学习的难点有两方面：一方面舆情信息表示的方法；另一方面是将分散的舆情信息表示统一模型进行分类学习。网络舆情序列学习方法解决机器学习对舆情文本信息的表示及舆情信息的处理方式，主要分类两大类：一类全局的序列信息，二类是局部的序列信息。

全局序列信息是指从网络舆情提供的评论、留言等数据中进行综合学习。如果机器要识别一个舆情信息句子，全局序列就是要学习每个单词的有序的序列信息；对于整个文档信息，不仅要获取单词的顺序信息，还要获取每个段落的顺序信息。

局部序列信息是指舆情信息特征会呈现稀疏方式爆发，机器只能获取到文本的部分序列信息。例如 1-2 个词或者是学习 2-3 个句子的顺序信息，从而加大机器的计算与存储资源，而如何减少存储，构建舆情文本词向量编码或优化编码就可以实现资源损耗。

中国知网 https://www.cnki.net

3.3 舆情关键词提取算法

3.3.1 舆情关联规则

网络舆情信息如果以短文本的方式出现，将会给事件信息的定位带来难度，其发布的信息又较为稀疏，从而更加无法准确表达事件信息。舆情信息爆发很容易集中在同一话题，此时的文本内容相互彼此关联，通过近邻的时间序列构建相似度矩阵，然后通过对相似度进行排序来选择测试文本最相似的文本，通过此类局部的关联规则，判断文本之间的关联性。

对于网络舆情信息文本分类，本文提出一个假设用于处理文本的关联分类器中，假设内容为$s_{\mathrm{i}}=(u_k,K_i,t),w_i=\{w_1^i:m_1^i,w_2^i:m_2^i,\mathrm{L}\ ,w_n^i:m_n^i\}$，其中$w_n^i$是$\mathrm{S_i}$的第 n 个关键词，$m_n^i$为文本中出现的频率次数；

L 指是本次事件话题系列中的最后一个有短文本所构成的组合，文本集合的降序排序主要是根据发布的时间来决定;$s_{i-1}=(u_{k-1},K_{i-1},t),w_{i-1}=\left\{w_1^{i-1}:m_1^{i-1},w_2^{i-1}:m_2^{i-1},\mathrm{L}\ ,w_n^i:m_n^i\right\}$且$s_{i-1}\in L$。采用词向量编码分布，将词编码成为一个固定长度持续的稠密向量，其维度主要把控在 50 到 100 之间，并且每一维都用实数，网络舆情信息从根本上体现出词的语义信息、语法、词性、语义等特征信息,编码每个关键词的维度控制在 50 维,构建一个词向量集。其中w_n^i关键的词向量为vec_i^k，依次类推w_j^{k-1}的词向量分别为vec_j^{k-1}。将距离转化为相似度，通过非空分量反映相似度，然后根据关联规则获得文本间的关联矩阵$C=(c_{ij})_{m\times n},w_{ij}$，可由公式（3.1）：

$$c_{ij}=vec_i^k\bullet vec_j^{k-1} \tag{3.1}$$

依据关联矩阵 C 计算出每个关键词的在时间序列发布的最近文本的距离情况，距离值最近的为关联的文本，比较最近的相似文本矩阵通过设置阈值划分，如果关联度矩阵 C 中元素超过阈值设置为 1 向量标识，否则不具有相关性设置 0 向量标识，从而得出关键词关联矩阵$S=(S_{ij})_{m\times n},S_{ij}$由公式（3.2）计算得出。当矩阵某行全部标识为 0 的时候，也就是此行中的关键词与近邻的短文本关联度较小，证明此行为无关联关键词，即噪声。所以主要关键词S_i的权重向量与关联话题权重向量相乘，就可以过滤无关联数据信息，从而保留主要的关键词，依此可对关键词的权重系数进行调整，增强主要关键词的权重系数，消除噪声带来的影响。

$$S_{ij}=\left\{\begin{array}{lll}1, & if & c_{ij}=\max(C[i][n])\geq\lambda\\ 0, & if & c_{ij}\leq\max(C[i][n])<\lambda\end{array}\right\} \tag{3.2}$$

其中，$C[i][n]$表示文本关联矩阵 C 位于 i 行；而划分的阈值范围$\lambda\in(0,1)$，主要用于判断每个关键词上的偏移情况。

中国知网 https://www.cnki.net

根据时间序列构建多个文本相似度矩阵后，通过新的短文本与已有话题进行比较，判断是否存在关联性，文本S_i与S_{i-1}的相似度为$tsiml_k$，计算的公式（3.3）所示：

$$tsiml_k = x_k / N \tag{3.3}$$

其中，x_k为矩阵 S 中的非零向量的行数。

在判断短文本之间的相似度存在几种情况：（1）$tsiml_k \geq 0.5$，即文本S_{i-1}与S_{i-1}相关联，实际情况中也会发现，两个文本比较关键词相似度的时候，有一半的关键词是相同的，这时我们可以通过这个阈值来判断两个文本是有关联的，否则为无关联度。所以判断过程中时序因素和时间、空间复杂度都是要考虑的，通过相似度的文本，就用S_i替换 L 中的文本S_{i-1}，从而实现文本加入到相关话题的序列中。（2）$tsiml_k < 0.5$，即文本S_{i-1}与S_{i-1}不存在关联，根据时间序列最近原则，S_{i-1}依次遍历 L 直到遍历完所有的文本。如果文本S_i与文档集 L 中的所有文档没有发现关联，则可以判断为一个新的话题序列。

3.3.2 关键词提取算法

网络舆情文本特征：关键词复杂、词稀疏，选取难度大等特征。如果抽取的关键词不能反应出事件的本质，就会对分类的效果产生较大的影响，所以使用适应各类文本关键词的提取步骤尤其重要，本文将结合各类文本的类型，通过从中提取相关的时间、地点、人物及事件等信息作为文本的关键词。

目前的网络舆情信息主要出现在新浪、今日头条、微信等媒体平台中，可采用爬虫方式获取相关信息。首先，通过注册合法用户并正常登录后，获取到 Web 起始的页面，一篇新闻文档页面一般包括作者信息与内容信息，作者信息主要包含：昵称、地址、关注人数、粉丝数、性别、等级等基本信息；内容信息包括：每条内容、链接地址、点赞数、评论数、转发数等信息。网络舆情的事件信息及涉及人物获取，只能通过“@”和空格来抽取文中的人物信息，地址抽取直接根据分词系统的词典可完成提取，发布内容文档先进行关键词的提取，并结合短文本、词级别进行序列信息分析。（1）长文档以句为基本单位提取句子文本中的动词；（2）短文档以词组为基本单位提取文本中的动词；然后根据动词后面一般跟名词特点，找到其后相邻的名词作为事件的关键词提取，最后都以分词后的序列实现关键词的选取，通过提取关键词的伪代码算法 1 如下所示。

算法 1 关键词提取算法

Input: S_i分词后的词序列 list

Output: $w_i = \{w_1^x, w_2^x, \mathrm{L}\ , w_m^x\}$

中国知网 https://www.cnki.net

```
for str_word in list
  If str_word 汉语词性为 nr/nrl/nt/nz
w_i =str_word;  //分词存储人名;
  else if str_word 在@之后
w_i =str_word;//分词存储昵称
  else if str_word 词性为 ns/nsf
w_i =str_word; //分词存储为地名
  else if str_word 在动词后且为名词，长度<=3
w_i =str_word;//分词存储事件关键词
  end if
end for
return w_i
```

3.4 本章小结

本章通过对短文本表示方法的分析，对网络舆情信息短文本的关键词提取和关联的规则进行探讨，首先分析基于词向量的舆情语义，并根据短文本稀疏、维度的问题来进一步深入研究词向量编码的分布式信息，主要为综合编码是不仅包括了语法和词性，还包括了语义和关联性等；然后，探讨了序列信息在文本中的本质，实现局部序列到全局序列的舆情序列信息的分类方法。以关键词、短文本、长文本等特点相结合，判断舆情上下文的文本关联性，实现短文本的舆情关键词提取算法，为后续章节研究网络舆情词向量分类模型打下基础。

中国知网 https://www.cnki.net

第四章 基于 ML-SVM 向量机的文本分类算法

传统的支持向量机（Support Vector Machines，SVM）算法进行舆情信息的分类有着良好的效果，但面对数倍级的网络数据和不断出现的新网络词语，原 SVM 算法提取训练文本特征准确率不高。为解决这一缺点，提出一种基于机器学习的支持向量机舆情信息文本分类算法（Machine learning support vector machines，ML-SVM）。

本章首先概述传统的 SVM 向量机基本原理基础上，描述了二元的线性分类方案，针对网络舆情主题提出了舆情主题分类识别模型方案。此方案提出一种舆情信息特征与香农定律相结合建立舆情新词发现机制，从而解决训练文本信息特征不足问题。然后，为了改善网络舆情信息分词的后信息稀疏问题，给出了一种舆情信息稀疏编码对短文本进行的特征学习方法，进一步实现舆情文本特征的学习和选取。最后，综合以上内容改进 ML-SVM 舆情特征分类方案，并证明了方法的有效性。

4.1 SVM 向量机基本原理

网络舆情词向量 vec_i^k 维的值越大，机器学习所需的时间与空间越复杂。因此，为了降低向量 vec_i^k 的维度，实现二维空间的识别，从而了提出 SVM 支持向量机算法。支持向量机的分类的理论，首要解决的就是提供足够的训练样本集，引入结构风险最小化原理，识别网络舆情的样本之间的平衡点。

首先,SVM 方法分类之前，介绍二维空间中将时序的短文本,通过直线进行的线性分类的方法，如图 4.1 所示:

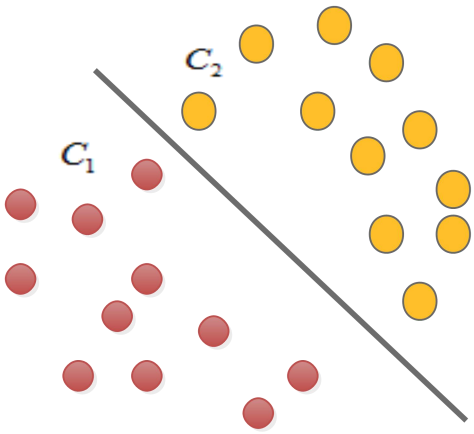

图 4.1 SVM 文本普通分类面

中间的分隔线表示区分两种文本类型的分类线性函数。如果在相似的文本之间有一个线性函数，它是线性可分的。假设划分过程是在三维空间中进行的，则坐标的纵向方向为平面，即为最优分类平面。

中国知网 https://www.cnki.net

而使用支持向量机方法将两个训练集的文本从向量空间平面上划分为最优文本分类平面，在合适的阈值下，两个训练集的文本分离距离最佳。在文本训练集分类中，样本由一个文本向量与标识组成,具体如下：

$$w_i = (s_i, v_i) \tag{4.1}$$

采用二元的线性分类划分，其文本向量用 s_i 表示，标识用 v_i 表示，标识通过时间的序列确定文本的训练集，v_i 只有两个值:1 和-1,分别代表隶属于不同的类别,即可以得出某训练文本集的最优分类平面之间的距离:

$$\sigma_i = v_i(ws_i + b) \tag{4.2}$$

当训练集的文本与最佳的平面 H 的距离越接近，也就是两个文本训练集之间的最佳平面距离，其分类也就是最优平面划分,如图 4.2 所示:

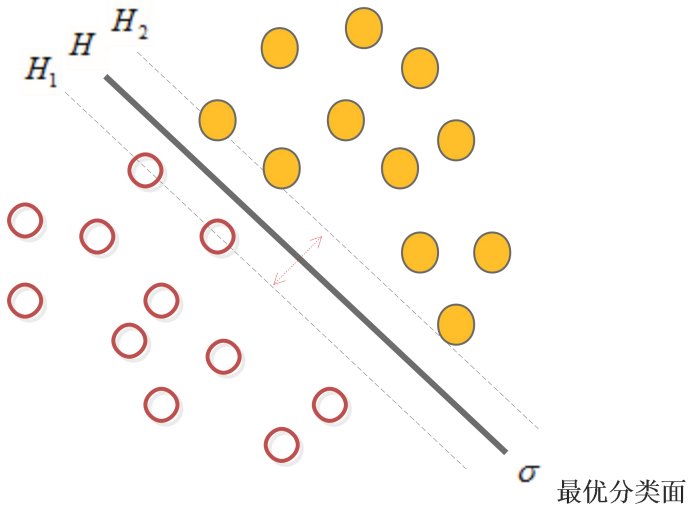

图 4.2 SVM 文本最优分类面

三条平行线 H_1、H 和 H_2，,其中 H 为最优的分类面，H_1 与 H_2 到 H 的距离称为几何间隔，此值越小代表两条距离最优分类面，支持向量是最接近 H 分类面的向量。

4.2 ML-SVM 向量机分类算法

4.2.1 网络舆情主题分类模型

网络舆情分类模型在本文 3.3 节中进行研究,主要是对短文本、序列信息及长文本表示等建立模型，通过词向量输入模型利用词级的序列信息学习文本集，并对网络舆情的关键词和关联规则进行处理，本节将主要解决网络舆情文本的主题分类问题。首先，对网络舆情主题进行信息归类，对新的文本进行关键词提取和文本关联训练，从而实现

中国知网 https://www.cnki.net

文本判断，并划分到不同的主题类。

舆情信息的分类主要通过关联主题类别的方法，分类其实就是数学应用中的映射过程，有 1：1 或 1：N 映射，如分类映射公式 4.3：

$$f: A \xrightarrow{vec_i} B\text{，包括：}A=(w_1,w_2,...,w_n)\text{，}B=(w_1,w_2,...,w_m) \quad (4.3)$$

其中，A 为待分类集合；B 为转化的有限分类的集合；vec_i 为分类的词向量规则，f 表示舆情规类的准则，划分舆情信息分类功能模块的步骤如下：

（1） 舆情文本集的来源。舆情文档集主要包括两大类数据集，一种文本集完成舆情训练，另外一种文本集完成测试，舆情训练文本集可以通过对新闻、邮件与微博等文本爬虫获取信息，通过学习和获取组成训练文本的分类文档；舆情测试文本集目前在国内外有很多测试文档，通过测试同样的文档评价分类模型性能。舆情文档集的来源，要保证数据文本适合标准化的语料库，训练文本集只有合适的规模才能得出最有价值的信息数据，实验过程中要验证其分类的效果及性能。

（2） 舆情特征选择。通过对舆情信息向量化，将计算文本之间的关联性转化为三维空间的向量距离，舆情特征选择根据字、词、词组、敏感词等网络新用语构建，保留舆情文本原有特征的形式,特征的有效选择直接影响文本分类的效果。

（3） 舆情特征提取。

舆情信息文本在原特征基础上做改变,特征降维并加权重,形成新的特征形式。

（4） 舆情表示模型：网络舆情分类过程中，文档表示形式直接影响分类的效果，所以舆情表示模型使用关键词向量模型来表示，减少其存储量和计算复杂度，并根据舆情的特征调整权重，有利于舆情的分类。

（5） 舆情分类器：舆情分类将基础信息收集 70%进行分类训练形成训练文本集，然后将剩余 30%用于分类测试形成测试集，从而完成网络舆情的分类文本集。

（6） 性能评估：算法的优劣是通过测试比较性能的方法，评价舆情分类效果。

舆情信息文本分类步骤，如下图 4.3 所示。

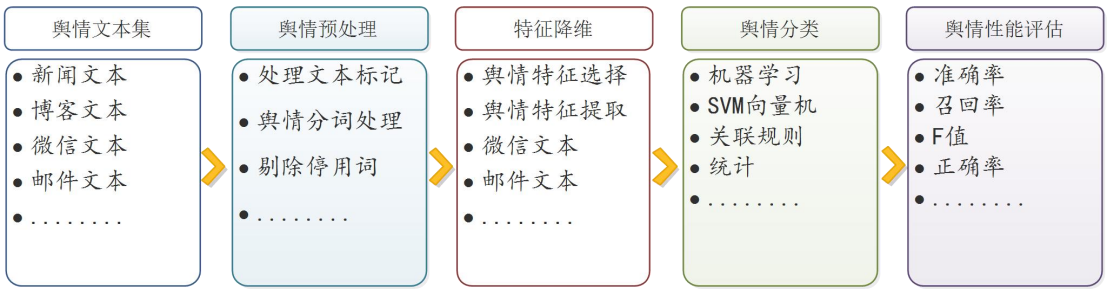

图 4.3 舆情信息文本分类步骤

4.2.2 舆情预处理过程

网络舆情信息复杂多样，信息碎片化，从大量的非结构化的数据集中理解突发事件

中国知网 https://www.cnki.net

话题，需要对舆情信息进行预处理，将非结构化的信息进行转换和识别。文本预处理的主要步骤包括：（1）统一编码；（2）分词；（3）过滤停用词；(4)发现新词。

（1）统一编码。

基于机器学习的网络舆情方法是计算机程序自动处理的过程，需要对不同主题类型的信息进行文本处理。根据提取的舆情信息进行字符集编码标准化，字符集主要包括 latin1、Unicode（UTF8）、GBK、gb18030 等编码，本文的文本集通过选择 UTF8 文本字符集统一编码。根据实际的需求统一编码后，计算机程序根据不同的主题类型的参与率、流动信息情况，对舆情文本信息进行主题类型切分与遍历搜索解析提取文本。

（2）分词。

网络舆情分析需要使用词来表示文本的特征，舆情分词依据语言类别来建立分词规则。英文的基本单位是单词，语言结构上就用空格区分每一个单词，相对于中文更容易实现词分离，英文分词的步骤：首选根据空格、半角符号、段落结束符等分隔，英文重点通过相关的匹配算法实现词组关联，可以很好的反应出舆情的导向信息。然后，根据各类语法的规则过滤掉无关的连词、介词、代词等特征，这类停用词在舆情分析中意义不大。最后，根据算法 Lancaster Stemming 规则提取词干，完成单词组的映射。

中文分词以词、词组、句和段划界，而且中文词组灵活多样，中文的词与词之间歧义相差很大，舆情信息需要从词中提取出敏感、热点、观点等信息。把词从文本中分离成相对独立的词，与训练集中敏感词进行比对，才可以确定出事件的突发性，所以中文相对于英文分词难度大。目前，国内的分词技术不断发展和改进，主要包括：字符串匹配、语义分析和统计分析三种类型，其处理思想如下：

a）字符串匹配的方法。

它是根据已有的中文词典信息与文本匹配分离的方法。目前有些学者根据舆情敏感词构建词典，然后通过相关的规则去选取中文词组，并与词典中的词进行遍历匹配，如果在遍历过程中相匹配，就完成切割分离词组，否则跳到下一次匹配规则中一直到最后文本。利用字符串匹配的方法优点是分词的内容可以对照词典，其分词的准确率较高，但缺点是词典没有包含的词组，就会产生错误和误差。

b）语义分析的方法。

它是利用机器理解和分析语言和句子，通过上下文的关联性来达到识别词组的功能。汉字分布在不同的位置，表示出来的词性与表达出来的词意差异也不相同，例如“我努力学习”与“我学习很努力”，前都的学习是动词，后者是一个名词。所以机器完全理解在不同情境下的句子含义难度较高，也会影响分词的效果。

c）统计分析的方法。

它不需要建立专门的字典比较，而是通过统计分析计算两个相邻字符的概率。一般来说，一个词是词的组合。计算单词之间的相似性概率，并设置判断阈值。当单词之间

中国知网 https://www.cnki.net

的相邻概率高于该阈值时，它被识别为单词，本文的舆情词向量统计模型就建立在统计分析方法上。本文提出的 ML-SVM 分类方法不同于其它分类方法，它使用词向量统计方法与舆情构造新词典方法相结合，不仅提升分词的效率，又能通过舆情词典发现新词，从而提高事件准确的判断性，消除句子的歧义性。

（3）过滤停用词。

过滤停用词是因分词后有些内容会增加计算的成本，必须把跟舆情信息内容无关的词去掉，从而降低特征的计算量，有助于改善舆情信息的文本分类性能。过滤停用词的方法分为两类：一类是舆情信息中一些虚词、助词、连词不能反应出舆情的特征，通过构建停用词列表的方法，与舆情信息文本特征进行比较，比如：“俺门”、“挨个”“旁人”、“几时”、“do”、“began”、“need”等。二类是设定停用词的词频阈值，根据舆情信息的特点去统计文本中所有词项出现的频次，如果词项总次数没有达到阈值，就将这个词项归纳为停用词项序列中。

(4) 发现新词。

舆情的特点是舆情信息会随着时间、地域和文化的情境影响都会产生新词，新词的出现给舆情提取关键词带来难度。舆情信息的新词识别，一般可以通过信息熵与互信息来进行量化指标。信息熵用来衡量舆情信息含量的一个量化指标，互信息用来确定舆情信息的相关性，此概念由香农提出[35]。

假设 X 是舆情信息新词变量，用函数给出新词发生的概率，其概率密度函数为 $p(x)$（$x=x1, x2, x3, \cdots$），即描述词向量的概念分布，其舆情信息熵定义为:

$$H(X) = -\sum p(x)\log p(x) \tag{4-4}$$

从公式（4-4）中可以看出 $H(X)$ 是平均信息量，信息熵为存在不确定因素的标志，不确定因素越多，随机变量的熵就越大。

假设 X 和 Y 是舆情信息文本分散的随机变量，也是新词在信息中的分布情况，新词联合分布为 $p(x,y)$，它们的边际分布为 $p(x)$ 和 $p(y)$，其联合分布情况为：

$$H(X,Y) = -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(x,y) \tag{4-5}$$

条件熵：

$$H(X\mid Y) = -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(x\mid y) \tag{4-6}$$

$$H(Y\mid X) = -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(y\mid x) \tag{4-7}$$

由信息论知识可知：

$$H(X,Y) = H(X) + H(Y\mid X) = H(Y) + H(X\mid Y) \tag{4-8}$$

随机变量 X 和 Y 是的互信息(*Mutual Information*)公式为：

中国知网 https://www.cnki.net

$$I(X,Y)=\sum_{x\in X}\sum_{y\in Y}p(x,y)\log\frac{p(x,y)}{p(x)p(y)}$$
$$=H(X)-H(X\mid Y)=H(Y)-H(Y\mid X) \tag{4-9}$$

综合以上公式，本文结合舆情信息特征与香农定律，提出建立舆情新词发现，从而满足新生的网络语词的分词处理。由上可知，如果变量 X 和 Y 是相互独立，则 $I(X,Y)=0$，因为此时 $p(x)$ 和 $p(x)p(y)$ 相等。否则，如果变量 X 和 Y 是相关联性高，则 $I(X,Y)$ 的值远远大于零。舆情信息的新词就可以用统计方法来计算新词的概率，分别通过变量 X 和 Y 判定两个相邻词的互信息是否大于阈值，从而可以识别是否为新词。

4.2.3 特征学习模块

网络舆情分类的过程中，舆情的碎片化造成维数较多、数据量大，舆情的特征项很难确定为舆情类信息。为克服现有的算法在处理舆情信息出现的稀疏性问题，本文在特征学习阶段，使用第三章中提出的词向量关键词提取算法，对稀疏的舆情信息进行特征预处理，特征学习流程如图 4.4 所示。

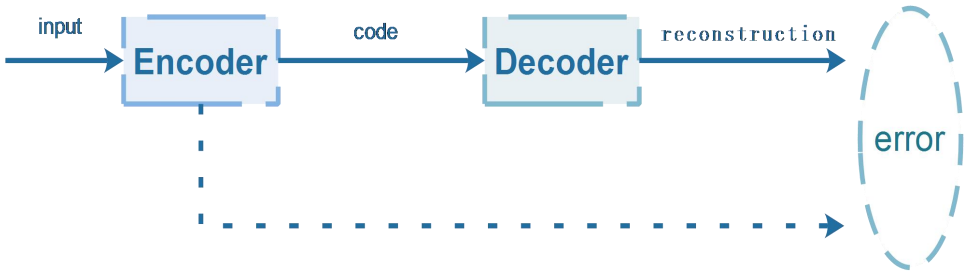

图 4.4 稀疏特征学习流程

舆情信息文本通过舆情预处理后，文本的分词结果具有稀疏的特征，不能精确地表达事件突发舆情信息。因此，本文改进信息的原本特征选择方式，通过稀疏特征编码的方式恢复原始特征具体流程：首先，舆情预处理后，分词得到的文本经过 SVM 的特征向量后输入到编码器（Encoder）中，得到一系列的舆情特征编码。然后，将舆情特征编码输入到解码器（Decoder）中，得到一种重构的舆情特征编码。舆情的特征能否正确地表达出事件的舆情出来，主要是通过调整编码器与解码器的参数来实现机器学习，调整后的参数会进一步的降低输入与重构间的误差（error）。最后，根据舆情特征的准确性可以循环此步骤，将第一次得到的编码当成第二次循环的输入，根据上次的训练经验调整编码与解码过程的参数，据此方法进行循环测试训练，并提取舆情信息的文本特征。

舆情特征学习模块根据稀疏特征编码的方式，本文根据不断地调整编码与解码的参数，测试的结果得出采用训练循环二次稀疏特征编码和解码过程最为合适。如果循环的次数无限增加，会改变原舆情信息文本的其本质，从而使用原始数据无法恢复。根据稀

中国知网 https://www.cnki.net

疏自动特征学习过程中，发现编码与解码的过程会改变舆情信息文本的原本特征，所以在组合 ML_SVM 分类器时，使其特征中的舆情文本具有准确特征表达能力，第一次稀疏特征学习的过程文本特征值在向量机中的高维空间可以实现映射，高维空间的使用能确保特征表达的准确性，表示的范围舆情更加广泛。而第二次稀疏特征学习的过程有着良好的数据恢复性，其特征也进行压缩转换，空间复杂度也得到了很好的解决，从而保证的分类器效果的稳定性。

将经过稀疏编码的特征文本输入到分类器中，进一步实现舆情文本特征的学习和选择，利用舆情语义和序列信息的学习模型，将编码过程固定在一个连续的稠密向量，维度控制在 50~1000 维度之间，可以进行判断短文本舆情信息的相似度，由稀疏编码后的舆情文本与新加入话题的文本进行关联，具体伪代码算法 2 所示。

算法 2 ML-SVM 向量机文本分类算法

Input:*舆情文本序列* $ST=\{s_1,s_2,\mathrm{K}\ ,s_{n,}\mathrm{K}\ \},L$

Output：舆情话题及其文本序列

```
1.for s_n in ST
2.   sort(L);//将序列文本由大到小进行排列
3.   Flag=0;//标志位
4.  for s_{n-1} in L
5.       将关键词进行稀疏特征学习提取特征值
         再选择 word2Vec 将 s_{n-1} 和 s_n 的关键词转化为词向量 vec_j^{k-1} 和 vec_i^k ;
6.        计算 s_{n-1} 和 s_n 的关联度矩阵 C = (c_ij)_{m×n}, w_ij ;
7.        计算舆情关键词偏移矩阵 D;
8.        计算矩阵 D 中非零行数 zero_n
9.       tsiml_k = S_k / N ;
10.      If tsiml >0.5
11.          Flag=1;
12.        将 s_n 添加到舆情文本 s_{n-1} 话题序列表中;
13.        用 s_n 替换掉 L 中的舆情文本 s_{n-1};
14.        break;
15.      end if
16.   end for
17.        if flag=0
18.          将 s_n 加入到舆情文本序列中;
19.          将 s_n 作为新的舆情话题序列初始文本;
```


中国知网 https://www.cnki.net

```
        end if
    end for
    return 舆情话题及其序列文本;
```

4.2.4 ML-SVM 舆情特征分类

ML-SVM 实现对舆情信息文本的分类，舆情的热点主要集中在新闻数据、微信数据、留言版数据、微博数据，统计分析网民关注的舆情信息点，其舆情的热点、拐点、疑点、焦点、重点、粘点、难点等敏感关键词构成舆情信息的分类依据，本文根据舆情信息的特征进行多类别的分类设计，SVM 向量机处理分类的问题一般包括：1:1,1:N,决策树及最大类间距法。本文我们利用敏感关键词对文本进行二分类 SC（second classifier），从而解决 ML-SVM 多分类问题，它的基本思路是舆情信息敏感关键词为样本的第一类，剩下的样本集合为第二类，这种分布式的方法把复杂的问题进一步的简化，所有的问题就由多类分类转换为若干个二分类来进行处理。假设舆情信息分类的前提为“x”、“y”和“z”三类别，每一类别都隶属于不同的坐标区间，如图 4.5 所示。

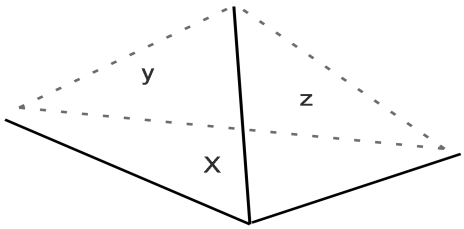

图 4.5 舆情分类图

舆情信息采用的 SVM 进行分类过程中，最优的分类函数公式为：

$$f(x)=\mathrm{sgn}\left(\sum_{i=1}^{n}a_i y_i(x_i * y_i)+b\right) \tag{4-10}$$

其 ML-SVM 多分类方法步骤为：

(1) 舆情分类假设将“x”、“y”和“z”三类别中的“z”集合为正类，其它两个集合为负类，依据 ML-SVM 的决策函数 $f^1(x)$ 所“x”类的舆情关键词分词提取出来。

(2) 然后再依据 ML-SVM 的决策函数 $f^2(x)$ 和 $f^3(x)$，把剩余的两个集数据分离出来；其理想状态下，任意输入值 n，ML-SVM 的决策函数 $f^1(x)$、$f^2(x)$ 和 $f^3(x)$ 中有且仅有一个为正数，在此条件下就可以进行舆情信息的分类。

中国知网 https://www.cnki.net

(3) 假设决策函数产生误差，比较三个函数的值，取最大值类。

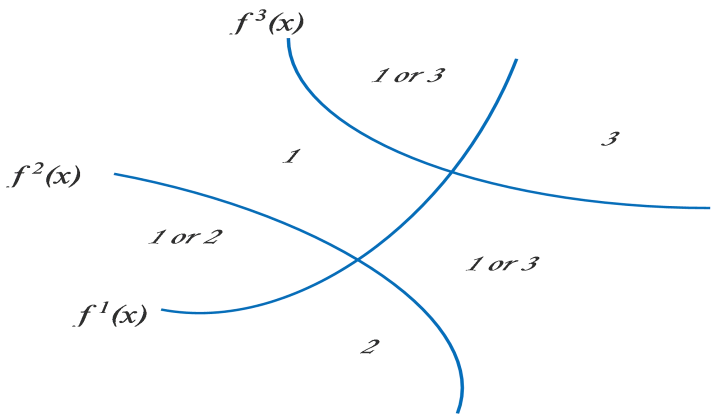

图 4.6 决策函数误差分布

舆情分类方法根据以上处理规则进行多类分类，但实际情况下，舆情信息的数十 PB 级的信息量，会产生更多的舆情信息类别，所以需要构建多个子分类器，来解决舆情信息的分类问题，假设有 n 个类别，ML-SVM 就必须设计出 n 个子分类器，其中最后一个子类二分类器 SC（second classifier），就设置为正类，其它的设置为负类，然后对舆情训练集文本进行训练，其分类结构图为 4.7 所示。

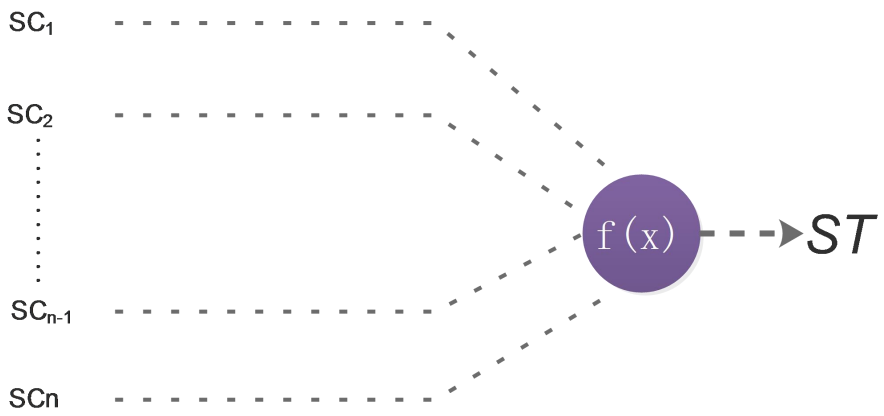

图 4.7 ML-SVM 分类结构图

图 4.7 的 SC_1 到 SC_n 分别为各类舆情文本的二分类器，实现多类分类变成若干个二类分类设计，舆情文本通过二分类后进入到 $f(x)$ 最优的决策函数进行分类减小误差，最后输出 ST 舆情短文本序列文本分类结果。

4.3 ML-SVM 更新算法

舆情文本 S_{n-1} 话题序列表中，话题的种类与数量复杂，每一类的相关话题规模分布较稀疏，容易产生大量的无用信息如孤立点和噪声点，而这些信息也会使文本的集合无限

中国知网 https://www.cnki.net

增长,从而影响算法的稳定性和准确度,所以舆情文本序列需要定时的进行话题更新，保持舆情文本的适当规模。舆情话题序列 $S_k \subseteq G$, S_k 隶属于话题集 G_n 相关的集合，LCK 为舆情话题的生命周期时长，$SText_n$ 为 S_k 的舆情信息总数。舆情的爆发点可以通过设置阈值来进行更新序列话题文本，比如 LCK 的值 > τ 小时，且 $SText_n < \eta$，则删除 G 中的 S_k，消除舆情话题序列中的孤立点 G 和控制舆情信息集 $SText_n$ 的规模增长。根据时间 > τ 的比较结果，把时序上最新的文本进行移除，通过设置 Count=1，time=5minute，每 5 minute 检测话题的相关的信息，判断是否有新的舆情信息到达，时间 t 为文本 $nText_n$ 到达的时间，并保存 $SText_n$ 在 $t - Count \times time$ 时间前的副本。如果两个舆情文本集的交集不为空，则表示部分舆情文本信息持续没有更新，则需要将舆情的中交集部分移出此类主题中，保存到外部存储中。舆情与最新的信息的集合更新伪代码如下所示：

算法 3 ML-SVM 向量机文本更新算法：

Input:舆情文本序列 G, S_k 舆情文本集合 $SText_n$.

Output：更新后的舆情话题及其文本序列

```
1. for S_k in G
2.    if LCK>1 hour and SText_n <10// 1 小时检测舆情文本增长缓慢
3. delete S_k in G ;// S_k 为孤立点与噪声
4.      delete nText_n in SText_n // nText_n ∈ S_k
5.    else : nText_n I SText_n // 存在新舆情在规定时间内没有更新
6.       nText=nText − nTextI sText // 更新文本序列
7.     for xk in nTextI sText
8.        存储 S_k 到外部文件 S_k.txt;
9.        delete S_k in G ;// 更新 S_k
10. end for
11.  end if
12. end for
13. return S_k, SText_n ;
```


中国知网 https://www.cnki.net

4.4 本章小结

本章首先概述网络舆情中使用 SVM 向量机，提出基于 ML-SVM 向量机的舆情信息文本分类算法，首行构建网络舆情主题分类模型，此主题分类模型首先对网络舆情信息复杂多样性的特点进行舆情信息预处理，分词之前改进文本统一编码的问题。然后，分词方案中总结了三种分词方法，提出词向量统计方法与舆情构造新词典方法，提高舆情事件准确性，并消除句子的歧义性。其次，对网络舆情新词发现构建舆情信息特征与香农定律方案，对新网络词的发现提供帮助。为进一步改善网络舆情信息分词的后信息稀疏问题，给出了一种舆情信息稀疏编码对短文本进行的特征学习方法，并输入到分类器，进一步实现舆情文本特征的学习和选取，并改进 ML-SVM 向量机分类算法；最后，利用敏感关键词对文本进行二分类，使一对多的分类方法变成若干个二类分类方案，其优势是降低文本分类的误差。接下来第五章对本章提出的方案进行实验分析，并与传统的分类算法进行比较，探讨不同条件下的文本分类效果。

中国知网 https://www.cnki.net

第五章 基于 ML-SVM 的网络舆情分类实验分析

5.1 分类主题的确立

根据媒体的报道情况、网民参与度、各平台的转载、事件性质及影响度等要素，网络舆情分类通过对监管的内容来进行分类划分，从实际需求出发分析确定分类的主题，构建明确的主题分类体系。根据新浪舆情事件数据，确定 9 类主题：政经舆情、名人舆情、公共安全、社会民生、教育舆情、司法案件、政策法规、医疗卫生、竞技体育。

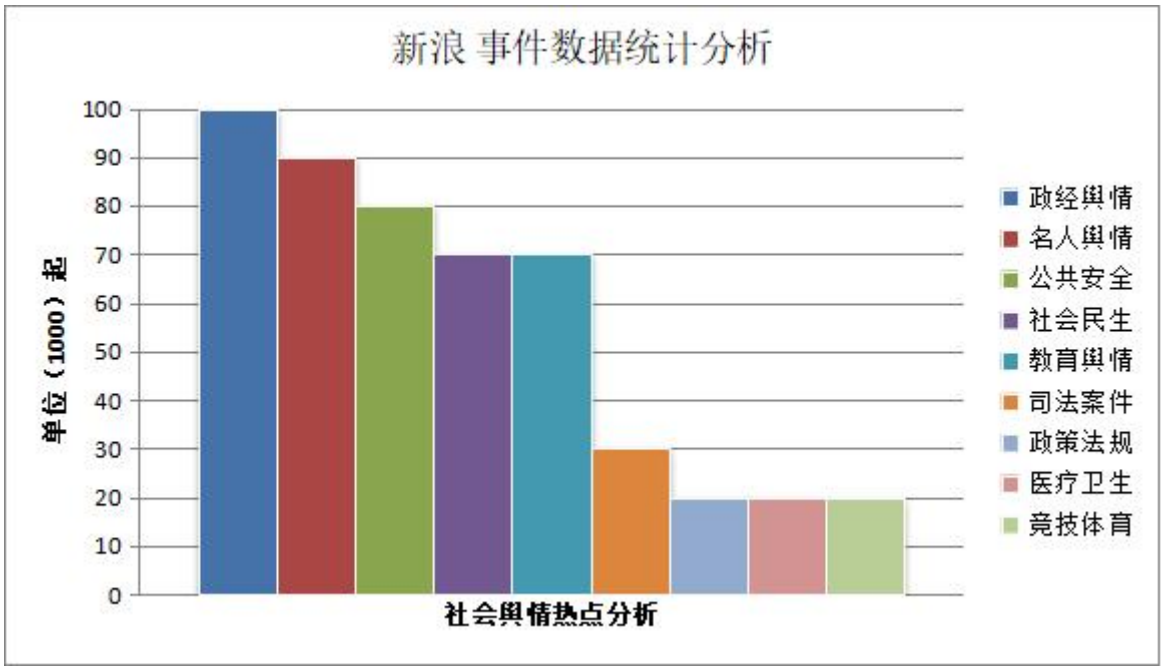

图 5.1 社会舆情热点分析

5.2 系统的总体设计

网络舆情信息的内容是多元的，包含政治、经济、文化、军事等方面，舆情的话题会随着网民的情绪自由增长。网络舆情信息主要监测多媒体，利用论坛、微博上的信息，通过舆情热点的分析建立网络舆情分类系统，系统设计总体的目标如下：

（1）高效性。网络信息的传播快，舆情的提取处理的信息较多，分类系统设计需高效地处理海量信息。

（2）操作性。系统操作流程简单，可操作性强，易上手。

（3）准确性。分类准确，降低网络信息中的噪音与干扰。

5.2.1 系统的基本功能

网络舆情的分类系统设计，从实际需求出发分析确定分类的主题，应基于舆情相关

中国知网 https://www.cnki.net

文本结合中文分类系统划分特征值，构建明确的主题分类体系：

（1）舆情信息预处理：对舆情信息的文本采用中文分词方法，去除停用词，完成词云统计，输入到分类器中。

（2） 舆情特征选择。ML-VSM 通过对舆情信息向量化，将计算文本之间的关联性转化为三维空间的向量距离，舆情特征选择根据字、词、词组、敏感词等网络新用语构建，保留舆情文本原有特征的形式,特征的有效选择直接影响文本分类的效果。

（3） 舆情特征提取。

舆情信息文本在原特征基础上做改变,特征降维并加权重,形成新的特征形式。

（4） 舆情表示模型：网络舆情分类过程中，文档表示形式直接影响分类的效果，所以舆情表示模型使用关键词向量模型来表示，减少其存储量和计算复杂度，并根据舆情的特征调整权重，有利于舆情的分类。

（5） 舆情分类器：舆情分类将基础信息收集 70%进行分类训练形成训练文本集，然后将剩余 30%用于分类测试形成测试集，从而完成网络舆情的分类文本集。

（6） 性能评估：算法的优劣是通过测试比较性能的方法，评价舆情分类效果。

5.2.2 系统体系架构

根据网络舆情系统的基本功能设计要求，舆情的热点主要集中在新闻数据、微信数据、留言版数据、微博数据，统计分析网民关注的舆情信息点，系统主要包括舆情信息采集、预处理、提取和管理四大功能模块：

（1）舆情信息采集模块：主要任务实现网络数据采集，通过读取 URL 列表及去重 URL 列表，解析成功后获取网页中的内容，并进行内容分析，依次重复读取 URL 获取网页中的内容。

（2）舆情信息预处理模块：主要任务就是各媒体平台抓取网页文本信息，并获取有用的信息即正文，利用分词方法进行完成特征的选取、舆情文本的表示、降维及权重的计算，生成特征向量保存到数据库中。

（3）舆情信息提取模块：包括舆情的文本分类功能，与提取文本信息中的舆情关键词、舆情话题等信息。

（4）舆情展示管理模块：包括系统基本参数的设置，舆情的展示及分类统计，分类器的设置与结果查询等操作。

中国知网 https://www.cnki.net

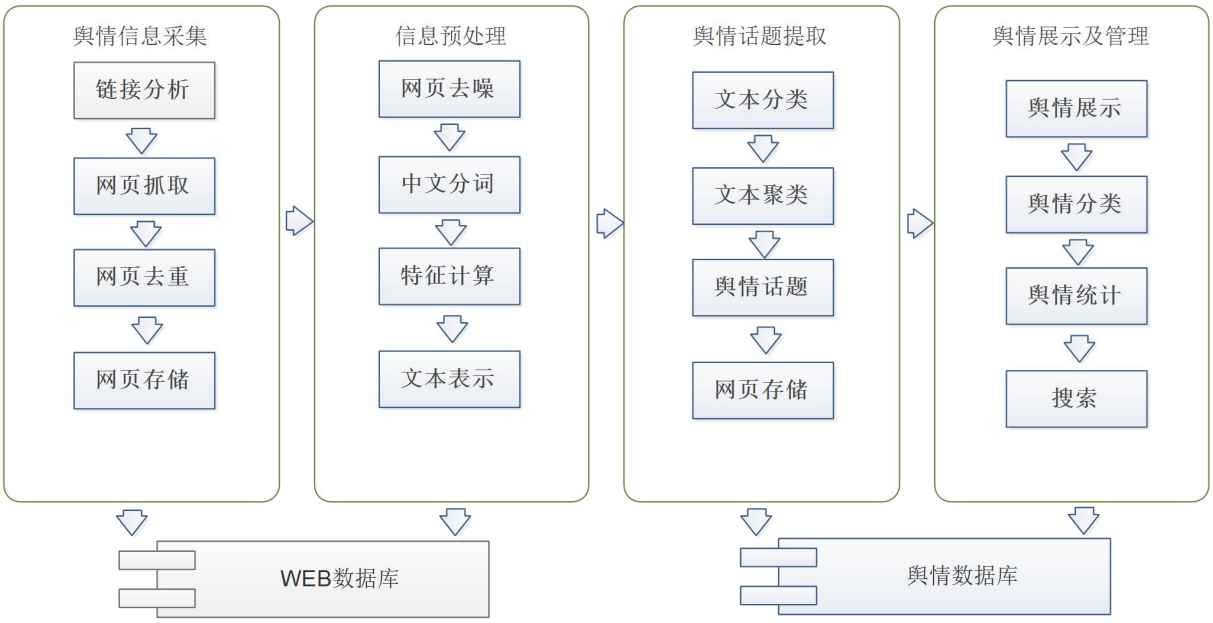

图 5.2 总体系统架构

5.3 ML-SVM 向量机分类算法实验分析

5.3.1 性能评估指标

根据网络舆情信息的碎片化，复杂多样性等特点，网络舆情文本 ML-SVM 向量机分类算法的有效性验证，可以使用标准的评估方案，分类算法实验采用常用的评估标准来进行分析处理，包括准确率、召回率、F_β 值、微平均、宏平均[42]等性能指标。

假设舆情信息类别集合为 $s=\{s_1,s_2,\mathrm{L}\ s_i\},(1\le i\le m)$，通过 ML-SVM 向量机分类器划分的任意类别关联表 5.1 所示：

表 5-1 类别列表

	实属于类别 S_i	实不属于类别 S_i
分类器划分成功 S_{flag}	$\mathrm{S}_1\in S_i$，$\mathrm{S}_1\in S_{\mathrm{flag}}$	$\mathrm{S}_1\notin S_i$，$\mathrm{S}_1\in S_{\mathrm{flag}}$
分类器划分错误 S_{flag}	$\mathrm{S}_1\in S_i$，$\mathrm{S}_1\notin S_{\mathrm{flag}}$	$\mathrm{S}_1\notin S_i$，$\mathrm{S}_1\notin S_{\mathrm{flag}}$

以上表 5-1 描述舆情文本 S_1 实际是否属于 S_i 文本类，且是否被分类器错误划分 S_i 文本类几种状态：

(1) 网络舆情类别 $\mathrm{S}_1\in S_i$，$\mathrm{S}_1\in S_{\mathrm{flag}}$ 关联状态: S_1 实际属于 S_i 文本类，且是被分类器划分到 S_i 的样本，记为 X 个文本数量；

(2) 网络舆情类别 $\mathrm{S}_1\notin S_i$，$\mathrm{S}_1\in S_{\mathrm{flag}}$ 关联状态: S_1 实际不属于 S_i 文本类，且是被分类器错误划分到 S_i 的样本记为 Y 个文本数量；

中国知网 https://www.cnki.net

(3)网络舆情类别$S_1 \in S_i$，$S_1 \notin S_{flag}$关联状态：S_1实际属于S_i文本类，且被分类器错误划分到其它S_i的样本，记为Z个文本数量；

(4)网络舆情类别$S_1 \notin S_i$，$S_1 \notin S_{flag}$关联状态：S_1实际不属于S_i文本类，且未被分类器划分S_i的样本，记为F个文本数量。

根据舆情类别的划分状态，用 X、Y、Z、F 表示符合相关规则的单个样本数量。另外也可以得到类别S_i正确划分到S_i的比例，即准确率简写为 P，准确率(Precisio)是指舆情文本正确分到S_i集合序列中的的文本数量占分类器划分成功的所有样本总数的比例。其计算公式为：

$$P = \frac{X}{X + Y} \tag{5-1}$$

正确划分类别的召回率（Recall）是舆情文本正确分到S_i中的文本数量占所有样本隶属于S_i样本数量比例。其简写为 R，计算公式为：

$$R = \frac{X}{X + Z} \tag{5-2}$$

在舆情信息分类评估过程当中，P和 R彼此之间相互影响，其任意改变一个值都会影响另一个值的范围。舆情评估标准的F_β值是优化 P和 R分类的性能，其公式如下：

$$F_\beta = \frac{\left(\beta^2 + 1\right) \times P \times R}{\beta^2 \times P \times R} \tag{5-3}$$

舆情信息评估F_β值中下标β取值范围介于$0 < \beta < \infty$，主要用来调整 P和 R在F_β中重要程序。当$\beta = 0$时$F_\beta = P$；当$\beta = \infty$时$F_\beta = R$；当$\beta = 1$时，使用评价标准变为F_1，其公式变为（5-4）所示：

$$F_1 = \frac{2 \times P \times R}{P + R} \tag{5-4}$$

其值当$\beta > 1$时，在评估标准F_β中召回率更重要；当$0 < \beta < 1$时，在评估标准F_β中准确率更重要。P和 R在F_β三个评估标准完成S_1单个类别的分类性能评估，用此方法完成每个S_i舆情文本集的的性能评估，在评估的过程中体现出分类的效果。

在所有类别的分类性能进行的整体性能评估，就必须采用微平均值：Micro_avg 和宏平均值：Macro_avg 变量评估计算，同样按照表 5-1 计算出 X、Y、Z、F 的样本数量和值，将所有类别的分类性能通过微平均准确率：$Micro_P$、微平均召回率：$Micro_R$与微平均 F_1：$Micro_F_1$进行统计运算，其公式为：

中国知网 https://www.cnki.net

$$Micro_P = \frac{\sum_{i=1}^{m} X_i}{\sum_{i=1}^{m} X_i + Y_i} \tag{5-5}$$

$$Micro_R = \frac{\sum_{i=1}^{m} X_i}{\sum_{i=1}^{m} X_i + Z_i} \tag{5-6}$$

$$Micro_F_1 = \frac{2 \times Micor_P \times Micro_R}{Micro_P + Micro_R} \tag{5-7}$$

采用同样的方法，完成宏平均准确率：*Macro_P*、宏平均召回率：*Macro_R* 与宏平均 F_1：*Macro_F*$_1$ 计算，其公式如下：

$$Macro_P = \frac{\sum_{i=1}^{m} P_i}{m} \tag{5-8}$$

$$Macro_P = \frac{\sum_{i=1}^{m} R_i}{m} \tag{5-9}$$

$$Micro_F_1 = \frac{2 \times Macor_P \times Macro_R}{Macro_P + Macro_R} \tag{5-10}$$

5.3.2 实验语料选择

舆情信息的回归评估测试分类器的准确率，把舆情信息的语料库分为训练和测试两种样本集。实验过程的分类语料库，本文根据新浪舆情事件数据进行分类统计，确定 9 类主题：政经舆情、名人舆情、公共安全、社会民生、教育舆情、司法案件、政策法规、医疗卫生、竞技体育。以新浪媒介为主体的原始语料内容丰富，每一类下有 1800 篇文档。根据舆情信息的分类效果，本文采用不同规模的语料数据集完成实验的对比分析。

数据集：采用训练文本集。由上面评估标准选定的标准，各一半的原则，分别从新浪舆情事件中的 9 类主题选择训练样本集 1000 篇文档，测试样本集 800 篇，语料数据集分布情况，如表 5-2 所示。

中国知网 https://www.cnki.net

表 5-2 语料数据集的分布情况

编号	类别	训练样本集	训练样本集大小	测试样本集数	测试样本集大小
1	政经舆情	1000	2.85 MB	800	3.05 MB
2	名人舆情	1000	1.80 MB	800	2.03 MB
3	公共安全	1000	3.38 MB	800	3.08 MB
4	社会民生	1000	2.31 MB	800	2.41 MB
5	教育舆情	1000	1.99 MB	800	1.96 MB
6	司法案件	1000	1.45 MB	800	2.51 MB
7	政策法规	1000	5.25 MB	800	5.61 MB
8	医疗卫生	1000	2.40 MB	800	3.32 MB
9	竞技体育	1000	2.94 MB	800	4.32 MB
合计		9000	24.1MB	7200	28.29

5.3.3 分类实验结果

（1）数据集:利用 ML-SVM 分类模型，实现 9 类主题类数据集分类测试结果，如表 5-3 所示:

表 5-3 ML-SVM 分类模型分类测试结果表

类别	政经舆情	名人舆情	公共安全	社会民生	教育舆情	司法案件	政策法规	医疗卫生	竞技体育	总计
政经舆情	695	15	13	4	22	10	11	10	20	800
名人舆情	30	625	20	29	15	13	30	15	23	800
公共安全	12	7	622	10	10	2	88	29	20	800
社会民生	3	2	21	716	14	0	38	5	1	800
教育舆情	35	10	13	0	679	6	41	12	4	800
司法案件	17	21	1	0	11	738	2	10	0	800
政策法规	9	16	29	38	28	13	582	40	45	800
医疗卫生	16	15	20	10	17	0	17	638	67	800
竞技体育	13	11	27	0	0	0	41	17	691	800
实际文本	830	722	766	807	796	782	850	776	871	7200
召回率	0.904	0.833	0.830	0.925	0.888	0.947	0.790	0.846	0.890	0.873
精准率	0.869	0.894	0.860	0.919	0.892	0.985	0.752	0.868	0.830	0.874

中国知网 https://www.cnki.net

F1	值	0.886	0.863	0.845	0.922	0.890	0.966	0.770	0.857	0.859

（2）数据集：对比原 SVM 分类模型，实现 9 类主题类数据集分类测试结果，如表 5-4 所示：

表 5-4 SVM 分类模型分类测试结果表

类别	政经舆情	名人舆情	公共安全	社会民生	教育舆情	司法案件	政策法规	医疗卫生	竞技体育	总计
政经舆情	676	35	13	4	22	10	11	9	20	800
名人舆情	30	645	19	20	25	13	10	15	23	800
公共安全	12	7	642	10	10	2	78	19	20	800
社会民生	3	2	11	736	14	0	28	5	1	800
教育舆情	25	10	23	0	689	6	31	12	4	800
司法案件	17	21	6	5	11	728	2	10	0	800
政策法规	19	16	29	28	18	13	600	40	35	800
医疗卫生	11	20	15	15	17	0	17	658	49	800
竞技体育	13	21	37	0	0	10	41	17	661	800
实际文本	806	777	795	818	806	782	818	785	813	7200
召回率	0.899	0.823	0.825	0.920	0.868	0.927	0.770	0.826	0.870	0.853
精准率	0.849	0.874	0.850	0.909	0.882	0.960	0.732	0.858	0.815	0.844
F1	值	0.856	0.853	0.830	0.895	0.875	0.9566	0.750	0.837	0.845

（3） 数据集:对比朴素贝叶斯分类模型，实现 9 类主题类数据集分类测试结果，如表 5-5 所示:

中国知网 https://www.cnki.net

表 5-5 朴素贝叶斯分类模型分类测试结果表

类别	政经舆情	名人舆情	公共安全	社会民生	教育舆情	司法案件	政策法规	医疗卫生	竞技体育	合计
政治舆情	665	45	13	4	22	0	11	9	21	800
名人舆情	31	792	21	31	42	3	34	14	22	800
公共安全	12	6	794	10	10	1	79	28	50	800
社会民生	3	2	26	910	4	0	39	5	1	800
教育舆情	51	10	3	0	832	6	73	11	4	800
司法案件	17	21	1	0	11	938	2	0	0	800
政治法规	9	15	31	63	24	3	768	38	39	800
医疗卫生	17	14	11	0	16	0	18	818	96	800
竞技体育	9	11	47	0	0	0	35	17	877	800
实际文本	800	800	800	800	800	800	800	800	800	7200
召回率	0.874	0.8	0.802	0.92	0.84	0.947	0.776	0.826	0.886	0.852
精准率	0.858	0.865	0.838	0.894	0.866	0.986	0.725	0.870	0.790	0.855
F1 值	0.866	0.831	0.820	0.907	0.853	0.966	0.750	0.848	0.835	0.853

（4）数据集:本文采用的 ML-SVM 分类模型、与前学者研究的 SVM 分类模型及朴素贝叶斯分类模型进行的平均时间效能比较，具体指标如表 5-6 所示:

表 5-6 平均时间效能比较

编号	功能	ML-SVM	SVM 分类模型	朴素贝叶斯
1	训练语料库	23885	52313	61598
2	政治舆情	11584	32133	57219
3	名人舆情	12415	33929	53949
4	公共安全	14271	52623	79262
5	社会民生	11474	32123	64059
6	教育舆情	10897	25496	59795
7	司法案件	9584	34879	52472
8	政治法规	15970	46879	68399
9	医疗卫生	11757	24693	60236
10	竞技体育	12397	24971	57103

（5）网络舆情分类实验测试：本文采用用召回率（Recall）、正确率(Precision)、F1 值作为评估的标准，改进的 ML-SVM 召回率指标所有样本的比例优于其它两类分类模

中国知网 https://www.cnki.net

型如图 5.3.1 所示。

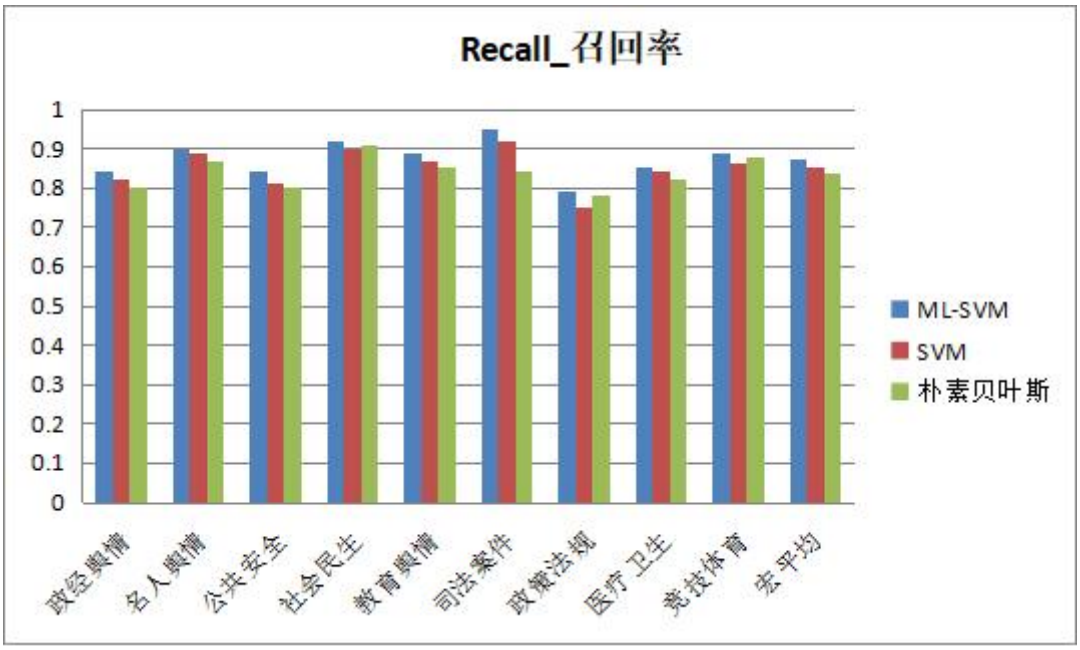

图 5.3.1 召回率

通过图 5.3.2 所示，改进的 ML-SVM 正确率划分成功的所有样本总数的比例优于同分类模型的性能指标。

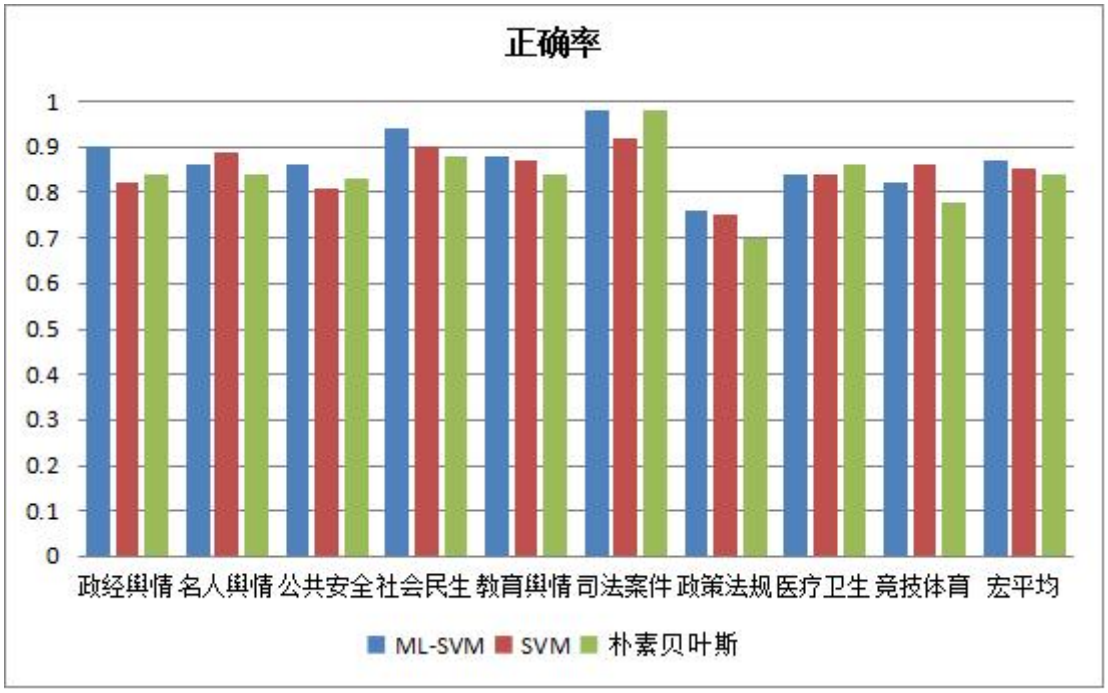

图 5.3.2 正确率

中国知网 https://www.cnki.net

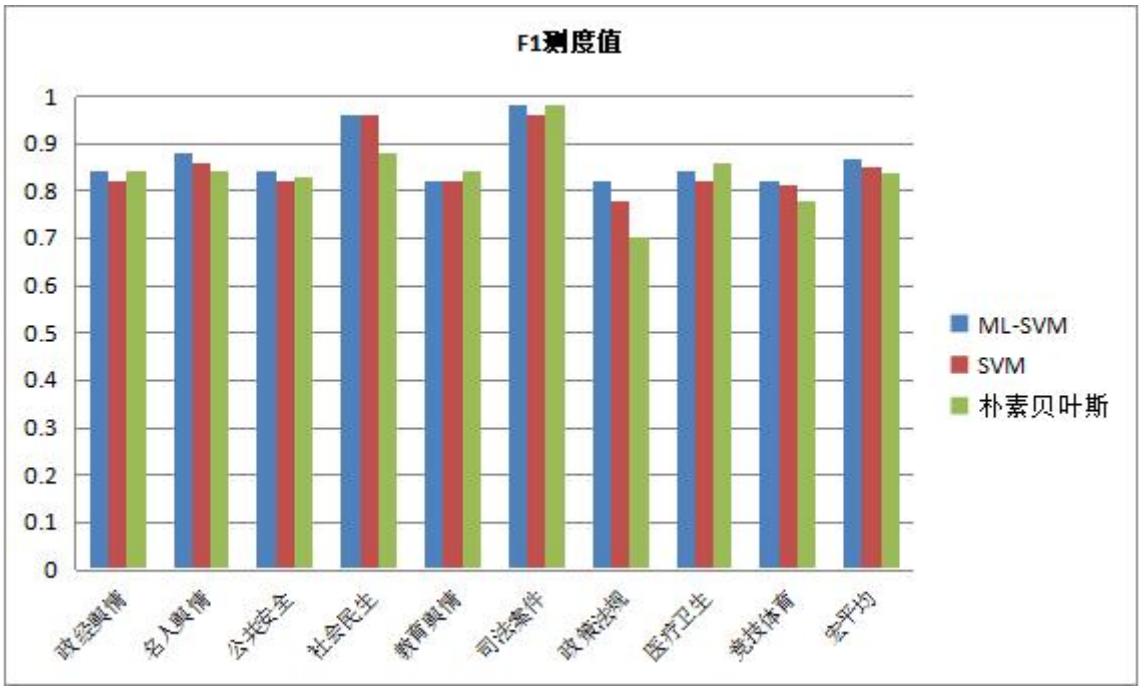

图 5.3.3 F1 测度值

网络舆情分类模型中，希望其速度快，内存小，精度高，所耗费的平均时间性能反映出 ML-SVM 分类模型的优势。

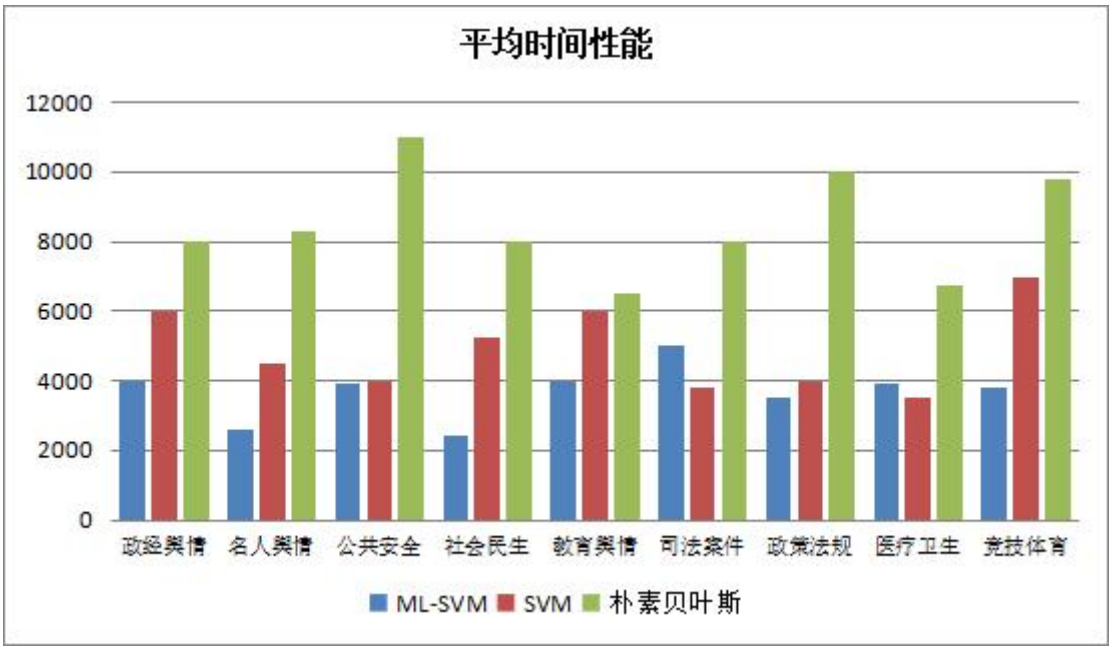

图 5.3.4 平均时间性能

5.4 实验结果与分析

综合以上训练集与测试集的实验结果，ML-SVM 分类模型在各项评估标准上都优于 SVM 分类模型和朴素贝叶斯分类模型。从中发现政治舆情、社会民生、司法案件的文

中国知网 https://www.cnki.net

本分类效果优于其它类别，并且各项测试值都高于其它类，平均保持在 82%以上，这是因为这几类的关注度相对而言网络用户群体大些，并且类别的独立性也更强；而其它类别的交叉度高些，既可以属于文化类，也可以属于其它类，所以分类过程中很容易产生误判，所以改善语料库的文本的质量是以后文本分类的研究方向。其次，修改语料数据集的规模也可以反映出两种分类模型优缺点，从时间性能上，ML-SVM 分类模型比 SVM 分类模型和朴素贝叶斯分类模型花费的时间相对少，图 5.4.1-5.4.3 所示，证明分类效果更优于 SVM 和朴素贝叶斯两分类模型，ML-SVM 分类模型的稳定性较好。

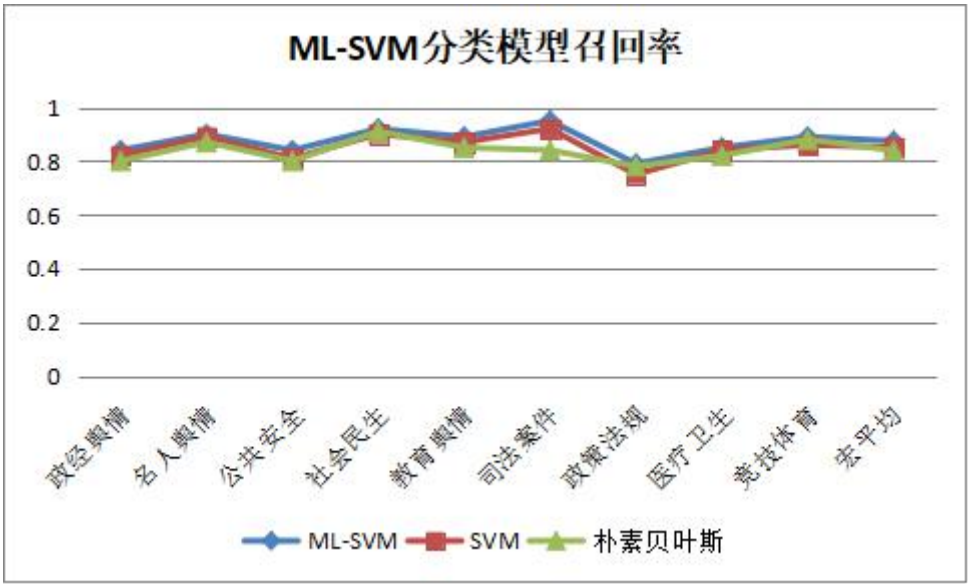

图 5.4.1 ML-SVM 分类模型的召回率

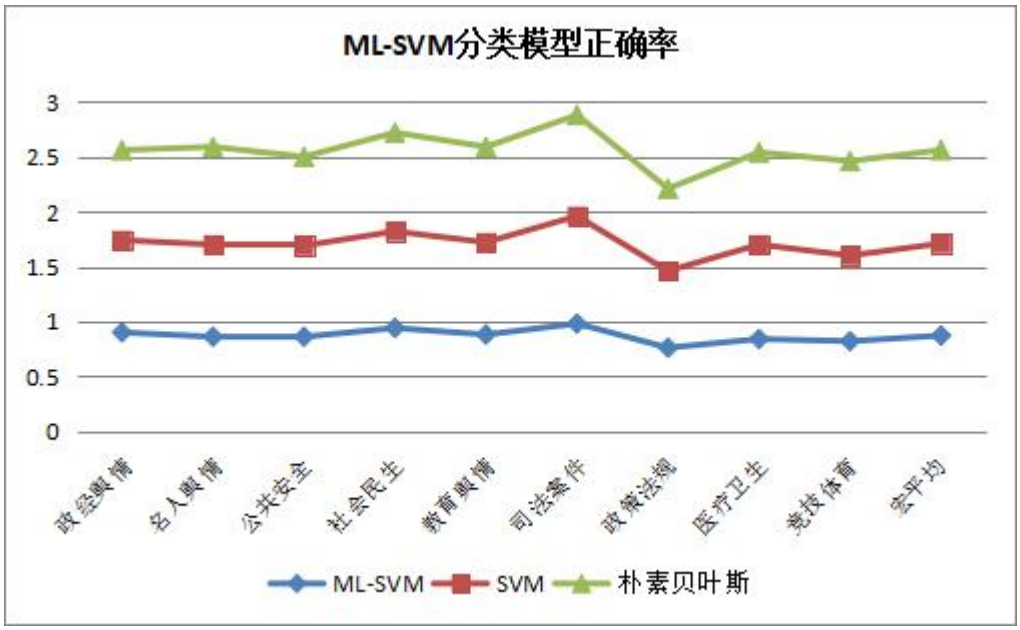

图 5.4.2 ML-SVM 分类模型的正确率

中国知网 https://www.cnki.net

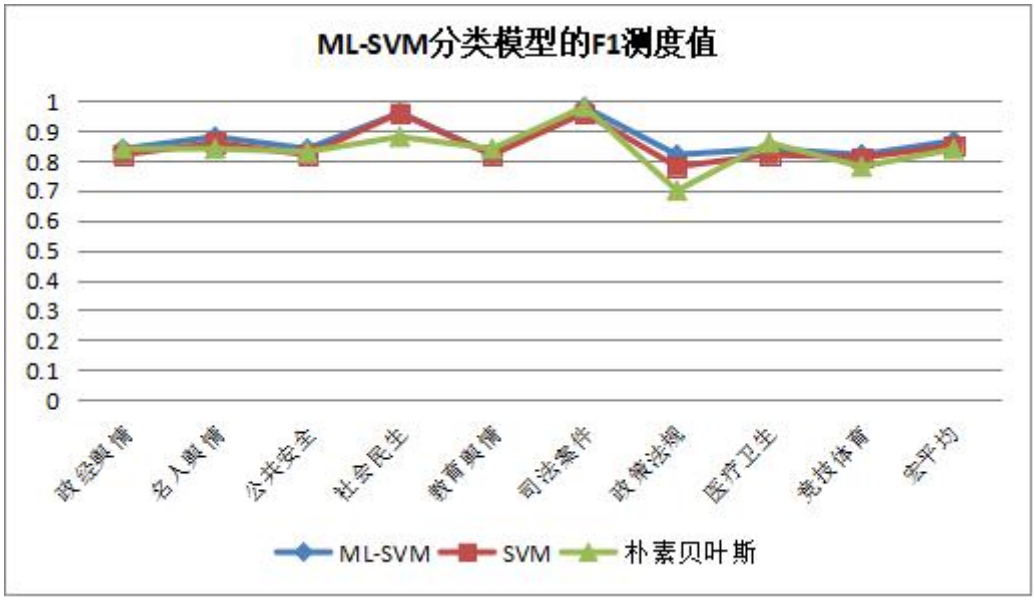

图 5.4.3 ML-SVM 分类模型的 F1 测度

通过对 ML-SVM 分类模型的召回率、准确率、F1 测度值等评估指标各项比对分析，本文提出的 ML-SVM 分类模型的 F1 测度值的测试指标达到峰值 0.8 以上，表现性能与其它分类模型幅值趋于平衡，总体幅值和幅值都有轻微的波动。当中，政治法规与教育舆情召回率最高，召回率为 95.2%;准确率最高的是运动类，准确率为 96.6%。

5.5 本章小结

本章实现 ML-SVM 向量机分类算法性能上评估测试，首先，详细概述分类算法常用的性能评估指标，然后，假设舆情信息类集合 S_i，并根据单个类别的分类性能主要从准确率、召回率、F_β 值三个公式中进行评估计算，接着对所有类别的分类性提出整体性的性能评估主要从微平均值和宏平均值计算评估。

最后，在实验语料选择“社会舆情热点分析”九大类别进行分类评测，提出将部分语料划分到训练样本集，一部分划分到测试样本集的性能评估方案，同等条件下对本文提出的 ML-SVM 分类模型、与其它学者研究的 SVM 分类模型及朴素贝叶斯分类模型进行评测，在九大类别中从语料库的分类测试、时间性能比较、分类效果对比（召回率、正确率、F1 测试值、平均时间性能）等方面进行比较分析，单个分类性能测试中 ML-SVM 分类模型一般达到 95%左右，整体分类性能测试中可以达到 85%以上，通过两种分类模型比较，ML-SVM 分类模型降低时间与空间上的复杂度，分类效果更强，性能更稳定。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 结论

随着互联网舆情信息的爆炸式增长,舆情信息出现在各类新闻、微博、微信、推持等社交媒介平台上，事件的突发性经过网络的传播引发舆情的热点和热议，此类不受限制的和不受约束的言论打破了时间和空间的限制,那么如何从各种媒介信息文本中挖掘出舆情信息，如何从新闻评论中分析人们的行为，如何正确的引导舆论的发展方向等任务，将有利于促进社会的发展。而实现对互联网的舆情信息进行有效的监管，基本手段是对互联网信息进行分类处理。文本分类技术研究已久，随着机器学习分类技术的发展将舆情信息文本分类变成研究的热点，很多的学者从各个方面对网络舆情分类算法进行了深度研究。

本文以传统的向量机（SVM）理论为基础，从词向量的舆情语义、舆情的序列信息、舆情分类模型、舆情主题分类模型、舆情分类算法等研究热门方向进行探讨与研究。提出基于机器学习的向量机网络舆情分类算法，并使用选择“社会舆情热点分析”九大类别在同等条件下对 ML-SVM 分类模型和朴素贝叶斯分类模型进行分类比较。最终，ML-SVM 分类模型降低时间与空间上的复杂度，分类效果更强，性能更稳定。

（1）在词向量的舆情语义方面。通过对传统词向量的原理分析后，发现舆情信息表示的信息存在维度高和词义分散问题,本文从语言模型出发对网络舆情信息采用词向量编码分布将关键词提取，建立词与词之间的编码规则，形成固定长度的连续稠密词向量。分析舆情特征提取步骤，加强相关特征项在分类中的影响，考虑文本信息之间或内部了的特征分布。同时，本文分析舆情信息向量用实数表示与舆情信息的特征之间的相关性,将词向量应用于网络舆情文本分类处理上，针对网络舆情进行预处理，以此构建舆情关键词提取算法。

（2）在舆情序列信息方面。本文从词到句子，句子到整篇文档，实现了局部与全局网络舆情信息的本质含义的探讨。词的顺序性主要体现在句子的语法、语义、逻辑结构上。同时，对舆情的词析进行分析对比，进一步验证序列信息对文本分类的影响，揭示舆情文本学习的难点有两方面：一方面舆情信息表示的方法；另一方面是将分散的舆情信息表示统一模型进行分类学习，提出根据舆情信息特点建立分类模型的思路。

（3）在舆情分类算法方面。本文依据传统 SVM 模型原理,描述了二元的线性分类方案，针对网络舆情主题提出了舆情主题分类识别模型方案。此方案提出一种舆情信息特征与香农定律相结合建立舆情新词发现机制,从而解决训练文本信特征不足问题。为更好的衡量舆情信息间的亲疏关系，建立舆情文本信息更新算

中国知网 https://www.cnki.net

法，验证了本文算法的有效性。最后，本文提出的分类算法在“社会舆情热点分析”九大类别语料库中，通过对 ML-SVM 分类模型的 F1 测度值在召回率、准确率、F1 测度值中，分别获得 95.2%和 96.6%的准确率，从单个分类性能测试中 ML-SVM 分类模型一般达到 95%左右，整体分类性能测试中可以达到 85%，宏观平均值方面是稳定的，通过实验结果表明，提出的基于机器学习网络舆情分类算法优于其他经典文体分类算法证明算法有效性。

6.2 未来工作

当前文本分类的方法较多，但对不同的网络舆情文本分类较少，且舆情事件的突发性因时间、地域、平台等不断发生改变，至今网络舆情语料库还不够完善。文章中揭示舆情分类算法在词向量、关键词、关联规则的改进，但仍有些问题需要进一步的实验与研究：

（1）本文对词向量与舆情信息相结合的编码规则，建立词与舆情关键词之间的关联规则，并且使用选择“社会舆情热点分析”九大类别语料库进行文本分类测试，而语料库的新词发现还有很大的提升空间，如何补充语料库与舆情相关的新词汇，如何学习适合于网络舆情信息分类的词向量及充实或建立专门的网络舆情语料库是我们研究的一个重要方向。

（2）本文从词到句子，句子到长文档分析舆情文本的序列信息词性进行分析，并揭示舆情文本学习的难点，提出根据舆情信息的特点建立学习方法，舆情特点的整理，实验数据相对还是比较弱，如何掌握整个网络舆情信息导向，建立全局舆情序列和局部舆情序列学习方法，下一步探索更的舆情序列信息的策略是研究的另一个方向。

（3）舆情的特点是舆情信息会随着时间、地域和文化的情境影响都会产生新词，新词的出现给舆情提取关键词带来难度。舆情信息的新词识别，本文通过信息熵与互信息来进行量化指标，结合舆情信息特征与香农定律，提出建立舆情新词发现机制，下一步研究可以采用其它的定律、公式及量化指标，建立更加适合网络舆情新词发现的新方法。

（4）关于舆情文本分类算法实验效果测试部分，本文提出将部分语料划分到训练样本集，一部分划分到测试样本集的性能评估方案。实验过程中实际选择训练样本集1000篇文档与测试样本集800篇，在以后的研究工作中将调整训练样本集与测试样本集，分别可以从大规模、中规模、小规模数据集选择语料，从三种不同数据集规模条件下实验分析，将有助于验证ML-SVM处理文本分类的性能与效率。

中国知网 https://www.cnki.net

参考文献

[1]黄建,李建江,王铮,方明哲.基于上下文相似度矩阵的Single Pass短文本聚类[J].计算机科学,2019(04):56-62.

[2]胡欣杰,路雨楠,路川.基于聚类分析的网络舆情倾向性分析研究[J].兵器装备工程学报,2019(05):121-124.

[3]夏梦婷,祁云嵩,朱丹.基于语义角度的网络舆情情感强度研究[J].计算机与数字工程, 2019(05):185-189.

[4]郑捷.NLP 汉语自然语言处理原理与实践[M].北京:电子工业出版社,2017.

[5]刘群,张华平,俞鸿魁.基于层叠隐马模型的汉语词法分析[J].计算机研究与发展,2004,41(8):1421-1429.

[6]孙茂松,邹嘉彦.汉语自动分词研究评述[J].当代语言学,2001(01):22-32+77.

[7] 徐博龙. 应用Jieba和Wordcloud库的词云设计与优化[J]. 福建电脑,2019(6).

[8]马伟娜.学术资源中英文分词和分布式存储系统的设计与实现[D].北京邮电大学,2016.

[9]胡欣杰,路川,齐斌.基于SOM神经网络的网络舆情信息分类模型[J].兵器装备工程学报,2019(03):114-117.

[10]张文静,张惠蒙,杨麟儿,荀恩东.基于Lattice-LSTM的多粒度中文分词[J].中文信息学报,2019,33(01):18-24.

[11]冯雪.中文分词模型词典融入方法比较[J].计算机应用研究,2019,36(01):8-10+17.

[12]宫法明,朱朋海.基于自适应隐马尔可夫模型的石油领域文档分词[J].计算机科学,2018,45(S1):97-100.

[13]蒋卫丽,陈振华等.基于领域词典的动态规划分词算法[J].南京理工大学学报,2019,43(01):63-71.

[14]刘泽文,丁冬,李春文.基于条件随机场的中文短文本分词方法[J].清华大学学报(自然科学版), 2015, 55(08): 906-910+915.

[15]马慧芳,刘晓倩,马兰,伍诗萌.融合语义与图结构的短文本特征提取算法[J].小型微型计算机系统,2019,40(09):1864-1868.

[16]马慧芳,邢玉莹,王双,张旭鹏.融合词语共现距离和类别信息的短文本特征提取方法[J].计算机工程与科学,2018,40(09):1689-1695.

[17]曹姗.基于TF-IDF特征提取的短文本分类方法[J].工业控制计算

中国知网 https://www.cnki.net

机,2018,31(04):109-110.
[18]赵芃.基于主题模型与深度学习的短文本特征扩展与分类研究[D].天津工业大学,2018.
[19]曾奇.面向微博的短文本分类算法研究[D].电子科技大学,2019.
[20]杨丹浩,吴岳辛,范春晓.一种基于注意力机制的中文短文本关键词提取模型[J].计算机科学,2020,47(01):193-198.
[21]胡小娟. 基于特征选择的文本分类方法研究[D].吉林大学,2018.
[22]李文慧,张英俊,潘理虎.多因素影响特征选择的短文本分类方法[J].计算机系统应用,2018,27(12):216-221.
[23]任永功,杨荣杰,尹明飞,马名威.基于信息增益的文本特征选择方法[J].计算机科学,2012,39(11):127-130.
[24] 王靖,柳青,张德海,赵华,杨云.基于多语义因子分层聚类的文本特征提取方法[J].计算机应用研究, 2020,37(10):1-6.
[25]李炜,巢秀琴.改进的粒子群算法优化的特征选择方法[J].计算机科学与探索,2019,13(06):990-1004.
[26]Shalini Puri,Satya Prakash Singh. An efficient Devanagari character classification in printed and handwritten documents using SVM[J].Procedia Computer Science,2019(152):111-121.
[27]任圆圆.基于文化粒子群算法的文本信息过滤研究[D].山东师范大学,2014.
[28]王明慧.基于骨干粒子群算法的中文文本聚类研究[D].江南大学,2017.
[29]Fang Miao, Pu Zhang, Libiao Jin. Chinese News Text Classification Based on Machine Learning Algorithm[C]// 2018 10th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC). 2018.
[30]Battineni G , Chintalapudi N , Amenta F . Machine learning in medicine: Performance calculation of dementia prediction by support vector machines (SVM)[J]. Informatics in Medicine Unlocked, 2019, (16):100-121.
[31]李策.基于自适应粒子群算法的特征选择研究[D].南京邮电大学,2017.
[32] Rajib Ghosh,Saurav Shanu,Sugandha Ranjan,Khusboo Kumari. An approach based on classifier combination for online handwritten text and non-text classification in Devanagari script[J]. Sādhanā, 2019,44(8):178-190.
[33]Sun A , Lim E P , Liu Y . On strategies for imbalanced text classification

中国知网 https://www.cnki.net

using SVM: A comparative study[J]. Decision Support Systems, 2010, 48(1):191-201.
[34] Borkar G M , Patil L H , Dalgade D , et al. A novel clustering approach and adaptive SVM classifier for intrusion detection in WSN: A data mining concept[J]. Sustainable Computing, 2019, 23(9):120-135.
[35] 朱烨,陈世平.最近邻注意力和卷积神经网络的文本分类模型[J].小型微型计算机系统,2020,41(02):375-380.
[36] Mohamed,Goudjil,Mouloud Koudil,Mouldi Bedda,Noureddine Ghoggali.A Novel Active Learning Method Using SVM for Text Classification [J].International Journal of Automation and Computing,2018,15(03):290-298.
[37]牛硕硕,柴小丽,李德启,谢彬.一种基于神经网络与 LDA 的文本分类算法[J].计算机工程,2019,45(10):208-214.
[38] SAHA D. Web text classification using a neural network[C]// 2011 Second International Conference on,2011.
[39]KALCHBRENNER N,GREFENSTETTE E,BLUNSOM P.A convolutional neural network for modeling sentences[C]//Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics.2014
[40] 任倚天. 基于支持向量机的海量文本分类并行化技术研究[D].北京理工大学,2016.
[41] Xie W , Liang G , Yuan P . Research on the incremental learning SVM algorithm based on the improved generalized KKT condition [J]. Journal of Physics Conference Series, 2019, 1237(2):1-6.
[42] CHENG Ming,WU Guoqing,YUAN Mengting,WAN Hongyan.Semi-supervised Software Defect Prediction Using Task-Driven Dictionary Learning[J].Chinese Journal of Electronics,2016,25(06):1089-1096.
[43] 陈波.基于循环结构的卷积神经网络文本分类方法[J].重庆邮电大学学报(自然科学版),2018,30(05):705-710.
[44]李华,屈丹,张文林,王炳锡,梁玉龙.结合全局词向量特征的循环神经网络语言模型[J].信号处理,2016,32(06):715-723.
[45][1] Jin W , Zhu H , Yang G . An Efficient Character-Level and Word-Level Feature Fusion Method for Chinese Text Classification[J]. Journal of Physics Conference Series, 2019, 1229(1):12-57.
[46]李军. 基于支持向量机的消极性短文本分类方法研究与实现[D].国防科学技术大学,2017.
[47]刘国锋. 基于深度学习理论和 SVM 技术的文本分类研究与实现[D].江苏科

中国知网 https://www.cnki.net

技大学,2017.
[48]刘明珠,李晓琴,陈洪恒.基于支持向量机的语音情感识别算法研究[J].哈尔滨理工大学学报,2019,24(04):118-126.
[49] 冯占芳. 基于支持向量机的并行文本分类方法研究[D].辽宁工业大学,2019.
[50] 王义真,郑啸,后盾,胡昊.基于 SVM 的高维混合特征短文本情感分类[J].计算机技术与发展,2018,28(02):88-93.
[51]邢玉娟.基于混合特征云向量模型和 SVM 的文本情感分类[J].宁夏大学学报(自然科学版),2017,38(01):69-73.
[52]Yin Y , Yang W , Yang H , et al. Research on Short Text Classification Algorithm Based on Convolutional Neural Network and KNN[J]. Computer Engineering, 2018,44(7):193-198
[53]郭超磊. 基于 SA-SVM 的中文文本分类研究[D].上海师范大学,2019.
[54]庄严,白振林,许云峰.基于蚁群算法的支持向量机参数选择方法研究[J].计算机仿真,2011,28(05):216-219.
[55]王旭.互联网舆情监控系统中聚焦爬虫的设计与实现[D].北京邮电大学,2011.
[56] 魏程程.基于 Python 的数据信息爬虫技术[J].电子世界,2018(11):2-2.
[57]Sogou实验室,Sogou文本分类语料库
[EB/OL].http://www.sogou.com/labs/dl/c.html
[58]孙吉贵,刘杰,赵连宇.聚类算法研究[J].软件学报,2008,19(1):48-61.
[59] 项梦曦.多重利多因素主导国际油价持续走高[EB/OL]. https://bank.hexun.com/2019-03-28/196639781.html,2019-03-28.
[60]聂庆庆. 基于文本序列和语义信息学习的文本分类研究[D].电子科技大学,2018.

中国知网 https://www.cnki.net