第42卷第5期 辽宁工业大学学报(自然科学版) Vol.42, No.5
2022年10月 Journal of Liaoning University of Technology(Natural Science Edition) Oct. 2022

DOI:10.15916/j.issn1674-3261.2022.05.003

基于深度学习的多模态情感分析研究综述

李文潇，梅红岩，李雨恬
（辽宁工业大学 电子与信息工程学院，辽宁 锦州 121001）

摘 要：对深度学习完成多模态情感分析进行了综述。简要介绍了多模态情感分析的概念、背景及意义；详细介绍了深度学习在多模态情感分析当中的应用；总结了多模态融合技术和交互技术；讨论了多模态情感分析未来发展的走向。

关键词：深度学习；情感分析；多模态；模态融合

中图分类号：TP391 **文献标识码**：A **文章编号**：1674-3261(2022)05-0293-06

Survey of Multimodal Sentiment Analysis Based on Deep Learning

LI Wen-xiao, MEI Hong-yan, LI Yu-tian
（School of Electronics & Information Engineering, Liaoning University of Technology, Jinzhou 121001, China）

Abstract: This paper mainly reviews the multimodal sentiment analysis completed by deep learning: first, the concept, background and significance of multimodal sentiment analysis are briefly introduced; secondly, the application of deep learning in multimodal sentiment analysis is introduced in detail; then the multimodal fusion is summarized. The multi-modal fusion technology and interaction technology are summarized. The future development trend of multimodal sentiment analysis is discussed.

Key words: deep learning; sentiment analysis; multimodality; modal fusion

情感分析(sentiment analysis)，也被称作观点挖掘(opinion mining)，是分析人们对产品、事件等实体对象持有的个人观点及主观感受。利用自然语言处理(natural language processing，NLP)技术以及机器学习(machine learning)、深度学习(deep learning)等方法对带有感情色彩的数据进行情感倾向分析与判断。

多模态情感分析是指将2种或2种以上模态的信息结合到一起进行情感倾向的预测。其中文本、图像、语音、视频等模态常用于多模态情感分析的研究，各模态通过深度学习等方法对各个模态的特征进行提取，再将这些特征进行有效融合，从而更加全面、直观地关注多个模态的情感信息，更加精准地进行情感倾向预测。

目前，多模态情感分析主要体现为2种方式，分别是叙述式多模态情感分析和交互式多模态情感分析[1]。其中叙述式多模态情感分析是对用户在社交平台上发布的多模态博文进行分析，如微博、YouTube、Flickr、Getty Images、MOSI等平台[2-3]，这些博文大多是作者就某事件主观表达的个人看法，目的是表达作者本身的观点态度，这些博文因为很少涉及多人看法，所以比较稳定。交互式多模态情感分析是指即时通讯，涉及多人多角度表达多种情感，如通过QQ、微信等聊天平台进行交流的内容，以及通过天猫精灵、小爱同学进行互动交流的内容，这些内容由于每个谈话者所占角度不同表达情感也不同，所以不够稳定，有着不确定的变化。因此，本文围绕叙述式多模态情感分析，基于不同的多种模态组合概括各模态进行情感分析的方法研究以及多模态融合与交互研究展开叙述。

收稿日期：2022-01-18
作者简介：李文潇(1997-)，女，辽宁凤城人，硕士生。
梅红岩(1978-)，女，辽宁锦州人，副教授，博士。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

1 基于深度学习的多模态情感分析

近年来，深度学习带动人工智能快速发展，在自然语言处理、图像处理等方面都发挥着重要作用，因此大多研究者在解决多模态情感分析问题时会选用深度学习的方法。因为深度学习包括诸多优点，如不同领域的自适应能力强；在大量的数据信息当中，深度学习取得的性能远超于机器学习；深度学习可以实现“端到端”的效果，将数据输入通过训练优化参数，即可输出想要的结果，所以其特征工程相对简单。

根据现实情况，本文将多模态划分为图文多模态和基于视频的多模态。其中图文模态是指数据集中只包括文本和图像；基于视频的多模态，一般包括语音、图像以及文本模态，但是根据实际需要考虑 2 种情况，其一是集文字语音于一体的在线视频，其二是文本与视频相互独立，视频对文本起补充说明作用。对于在线视频需要解决的问题是各模态间数据的对齐，对于文本视频独立状态需要解决各模态间的语义相关性。

1.1 图文多模态情感分析

2015 年，卷积神经网络被应用到多模态情感分析的研究中，Cai 等[4]提出将卷积神经网络模型(convolutional neural network，CNN)用于由文本和图像组成的多模态情感分析当中，利用 2 个独立的 CNN 模型分别对 2 个模态的特征进行提取，之后输入一个 CNN 框架学习 2 个模态之间的联系，从而进行情感极性预测。图文多模态进行情感分析的数据集一般都来自于用户发表的博文，其中包括很多的隐藏信息缺乏突出的情感词。因此，用户发表情感时，不仅仅只有积极和消极，还会存在其他的隐藏情绪，所以进行情感分析时还需要推断用户的潜在情绪。针对这一问题，Anthony 等[5]提出结合心理学研究，增添情绪研究，开发一种新的多模态特征提取模型，这个模型可以挖掘数据中存在的隐藏信息，自动产生合理的词汇列表，因此，为社交媒体上图像和文本的联合提供了新的工具。Liu 等[6]提出用于推文的情感分析概率(CASA)模型，通过引入伯努利参数将信息联合进行情感分析，在考虑上下文语义关系的同时还考虑各模态间的语义相关性，因此更加全面地进行情感预测，取得较好的效果。凌海彬等[7]针对此前的情感分类方法由于忽略博文中包含表情符号等隐藏信息带来的分析不准确问题，提出了多特征融合的图文微博情感分析方法，设计了基于参数迁移和微调图片情感分类(TFCNN)模型来捕捉隐藏的情感语义。

根据现实需求，股票预测以及商品推荐都依赖情感分析做出决策[8]，那么，大规模数据更加有助于提取用户的真实情感信息。对于大规模数据集研究者们提出了相关的提取方法，You 等[3]提出跨模态一致回归(CCR)模型，将数据集通过机器弱标记和人工标记区分进行实验，结果证明该方法具有可行性。在此基础上，You 等[9]又将各模态信息以结构化的形式共同处理，可以达到各模态数据对齐的目的，还通过引入注意力机制的长短时记忆网络训练文本和图像联合的语义相关内容，有效考虑上下文信息和语义相关，从而有效地判断情感倾向。

注意力机制在多模态情感分析中发挥了重要的作用。Poria 等[10]提出基于注意力的融合机制循环模型，在考虑上下文语义信息的同时，还能衡量各模态不同的重要性，通过该模型对输入的模态特征自动输出对应的影响分数。Chen 等[11]提出引入时间注意力机制的门控循环单元多模态情感分析架构，使信息可以在词语级进行模态融合，解决数据集中存在嘈杂数据和复杂融合带来的困难。Huang 等[12]提出了深度多模态注意力融合(DMAF)模型，首先通过注意力网络模型对多个模态进行特征提取，其次通过含有融合技术的注意力机制模型联合 2 模态之间的语义相关性，最后将 3 个注意力模型组合完成情感极性预测。

1.2 基于视频的多模态情感分析

针对有视频的数据集进行情感分析时，除了考虑图文信息，还需要考虑语音信息。Wöllmer 等[13]对电影评论当中的在线视频进行情感分析，将连续音频和视频当中的上下文语音信息作为视频特征，通过双向长短时记忆网络模型输入得到语音模态和视频模态的情感得分，最后通过决策融合将所有模态情感分数融合进行情感极性判断。陈敏[14]针对文本和短视频数据无法有效融合问题，提出基于决策级加权融合的情感分类方法，将数据集分为支撑级和查询级之后，分别进行特征提取设计不同权重，通过引入加权矩阵对各模态有效融合。卷积神经网络在基于视频的多模态情感分析中也具有很大贡献，Poria 等[15]利用深度卷积神经网络对各模态进行特征提取，利用这些特征向量对多核学习分类器训练得到情感分数，再利用可并行化的最大投票机制决策级融合方法得到情感分析结果。

语音常会受环境和信号流的影响出现噪音，从而为研究者带来困难。针对这一问题，Chen 等[11]关注时间步长对语音特征提取有很好的作用，利用

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

门控多模态嵌入模型对嘈杂数据进行选择性过滤，从而使数据集更加规范化。Mansoorizadeh 等[16]利用深度神经网络识别视频中出现人物的面部表情和语音规律得到各模态特征，再创建统一的混合特征空间，得到各模态融合后的情感得分，最后判断情感极性。Hussain 等[17]提出多通道信号的情感识别框架，为每个模态设定一个通道，通过加权多数投票机制混合融合框架再排除各模态噪音数据后整合多个通道的特征级融合和决策级融合结果，实现更好的情感倾向预测。

针对在线视频，各模态间数据对齐尤为重要。为了使各模态数据对齐，Poria 等[18]于 2013 年通过高斯核特征融合方法达到各模态数据对齐的效果。2016 年，Poria 等[19]通过合并多种融合技术使各模态间数据对齐信息有效融合。2018 年，Poria 等[20]考虑说话人的专有情感以及不同模态具有不同的重要性，提出 3 种不同的深度学习架构，为在线视频多模态情感分析提供了基线模型。杨锦涛[21]提出了引入注意力交流机制的 Transformer 网络模型解决数据不对齐问题，从而捕获更多的隐藏信息、更准确地判断情感倾向。

2　多模态融合与交互技术

多模态情感分析与单模态情感分析一样都需要进行特征提取，而后进行情感极性的判断。那么，两者最大的区别在于多模态需要对各个模态的特征进行有效融合，因此，多模态融合是多模态研究的关键之处。现阶段包括 3 种多模态融合技术，分别是特征级融合、决策级融合以及混合融合。

多模态情感分析中由于各模态之间交互存在间接性与不稳定性，因此，精准且全面地建立多模态交互的模型就存在一定难度[22-24]。另外，传统的交互建模在多模态情感分析领域还存在一定的局限性。因此，从不同层面出发主要分为 2 种交互问题，分别是模态内部的词与词交互问题和模态间的多模态交互问题[25-28]，模态间的多模态交互问题包括多模态特征交互和多模态决策交互。

2.1　模态内的词项交互问题

进行文本情感分析时，上下文语义联系是影响分析结果的关键因素。为了考虑相关的语义信息以及一词多义的问题，研究者们早期通过 one-hot 编码、词袋模型、神经网络模型、BERT 模型、图神经网络模型[29-32]考虑上下文语义信息，在文本情感分析任务中获得了较好的效果。

进行图像和视频情感分析时，像素点的组成是影响分析结果的直接因素。为了处理像素点，研究者们早期通过 SIFT、局部二值模式、卷积神经网络模型[29,33-34]考虑像素点组成，在图像及视频情感分析任务中获得了较好的效果。利用 LSTM 模型提取推文中具有情绪倾向的词，并将这些信息词与视觉语义特征、对象和场景聚合起来，得到了一种多模态情感分析的深度语义网络[35]。

2.2　特征级融合与多模态特征交互

特征级融合又被称作早期融合，是指各个模态进行特征提取之后将这些特征立即融合到一起，属于简单的连接各模态特征，重点在于各个模态间的连接。特征级融合如图 1 所示。

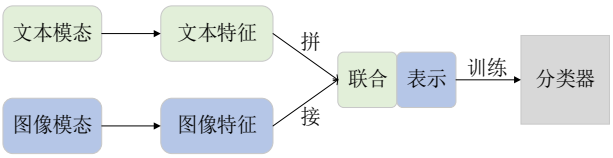

图 1　多模态特征级融合图

这种融合方式很好地把握了多模态特征之间的相关性，但是当各模态的特征来自不同语义空间时，由于存在差异较大不能直接合并。2013 年，Pérez-Rosas 等[36-38]建立了第一个话语级别注释的数据集并且使用特征及融合的方法将语音、面部以及文本模态的特征进行融合送到支持向量机当中进行情感极性的分析，得到很好的效果。Poria 等[39]通过卷积神经网络和 openSMILE 对各模态进行特征提取，而后使用特征级融合将各模态特征有效融合。Kumar 等[40]通过注意力机制获取在线视频的相关性并且学习各模态间的相互关系，最后将各模态的特征向量连接，利用 softmax 函数进行情感极性的判断。

多模态特征交互是指将不同模态特征映射到一个空间中完成特征融合，因为不同模态的特征具有不同的空间，从而导致多模态数据不对齐。研究者们通过引入注意力机制的特征融合、特征连接、共享隐层深度网络模型、张量融合[12,15,36-38]等方法将特征映射至同一个空间中使各模态数据对齐。

2.3　决策级融合与多模态决策交互

决策级融合[41-42]又被称作后期融合，是指各个模态的特征进行独立分析，得到局部决策结果后将分析结果融合成为决策向量得到最终的决策结果。决策级融合如图 2 所示。

这种融合方式在数据集存在模态缺失的情况下，依旧能通过其他模态得到最终结果。Yu 等[43-44]通过卷积神经网络和引入 DropConnect 的动态神经网络对文本和视频模态进行特征提取，再通过平均

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

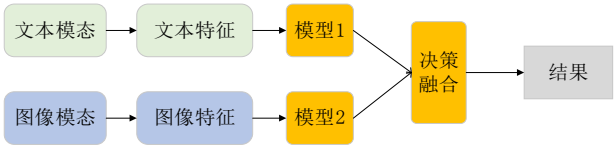

图 2 多模态决策级融合图

策略和权重对特征分析结果进行融合。Poria 等[15]通过深层 CNN 对各模态的特征进行提取，再将这些特征送到相应的分类器中进行有效分析，最后将结果在决策级进行可并行化的融合。

多模态决策交互是指将不同模态特征通过决策分析后联合。在联合的过程中，容易忽略事件发生顺序不同导致的各模态信息相互干涉的问题。针对这一问题，研究者们通过最大投票法、经典概率法[36,39-41]等方法使每个事件地位相同，从而无需考虑事件发生的先后顺序，也不会影响分析结果。

2.4 混合融合

混合融合[45]是特征级融合和决策级融合方法的结合。混合融合如图 3 所示。

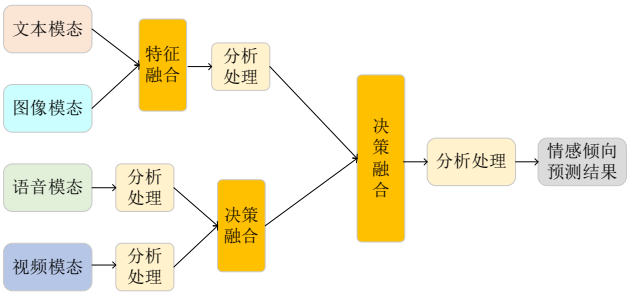

图 3 多模态混合融合图

这种融合方式结合了前 2 种融合技术的优点，克服 2 种技术的缺点，但是模型的复杂度和实现难度也随之增加。Chen 等[11]首次提出双输入门控循环单元处理各模态的噪音数据，通过时间注意门控嵌入的多模态 LSTM 模型对各模态特征在单词级进行混合融合。Gunes 等[45]对在线视频进行多模态情感分析，将视频中的面部表情和手势进行特征级融合，而后将分析结果加权进行决策级融合，得到融合结果，最后进行情感极性的判断。

3 结语

目前，经典的多模态情感分析研究已经成熟，在判断多模态间语义相关性以及多模态数据不对齐导致的无法有效融合的研究也在不断深入。随着自然语言处理和人工智能技术的不断进步，将深度学习应用到多模态情感分析中更加受研究者的欢迎。因此，深度学习相关技术将成为多模态情感分析研究的重要发展方向。

参考文献：

[1] 张亚洲，戎璐，宋大为，等. 多模态情感分析研究综述. 模式识别与人工智能, 2020, 33(5): 426−438.

[2] Zhang Y, Song D, Li X, et al. A quantum-like multimodal network framework for modeling interaction dynamics in multiparty conversational sentiment analysis[J]. Information Fusion, 2020, 62: 14−31.

[3] You Q, Luo J, Jin H, et al. Cross-modality consistent regression for joint visual-textual sentiment analysis of social multimedia[C]. In: Proceedings of the Ninth ACM international conference on Web search and data mining. 2016: 13−22.

[4] Cai G, Xia B. Convolutional neural networks for multimedia sentiment analysis[M]. Springer, Cham: Natural language processing and Chinese computing, 2015: 159−167.

[5] Anthony Hu, Seth Flaxman. Multimodal Sentiment Analysis To Explore the Structure of Emotions[C]. In: Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. London, United Kingdom: ACM, New York, NY, USA, 2018: 19−23.

[6] Liu B, Tang S, Sun X, et al. Context-aware social media user sentiment analysis[J]. Tsinghua Science and Technology, 2020, 25(4): 528−541.

[7] 凌海彬，缪裕青，张万桢，等. 多特征融合的图文微博情感分析[J]. 计算机应用研究, 2020, 37(7): 1935−1939, 1951.

[8] Kaur R, Kautish S. Multimodal sentiment analysis: A survey and comparison[J]. International Journal of Service Science, 2019, 10(2): 38−58.

[9] You Q, Cao L, Jin H, et al. Robust visual-textual sentiment analysis: When attention meets tree-structured recursive neural networks[C]. In: Proceedings of the 24th ACM international conference on Multimedia, 2016: 1008−1017.

[10] Poria S, Cambria E, Hazarika D, et al. Multi-level multiple attentions for contextual multimodal sentiment analysis[C]. In: 2017 IEEE International Conference on Data Mining (ICDM). New Orleans, LA, USA: IEEE. 2017: 1033−1038.

[11] Chen M, Wang S, Liang P P, et al. Multimodal sentiment analysis with word-level fusion and reinforcement learning[C]. In: Proceedings of the 19th ACM International Conference on Multimodal Interaction, 2017: 163−171.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[12] Huang F, Zhang X, Zhao Z, et al. Image-text sentiment analysis via deep multimodal attentive fusion[J]. Knowledge-Based Systems, 2019, 167: 26−37.

[13] Wöllmer M, Weninger F, Knaup T, et al. Youtube movie reviews: Sentiment analysis in an audio-visual context[J]. IEEE Intelligent Systems, 2013, 28(3): 46−53.

[14] 陈敏. 融合文本和短视频的双模态情感分析[D]. 南京: 南京邮电大学, 2020.

[15] Poria S, Cambria E, Gelbukh A. Deep convolutional neural network textual features and multiple kernel learning for utterance-level multimodal sentiment analysis[C]. In: Proceedings of the 2015 conference on empirical methods in natural language processing, 2015: 2539−2544.

[16] Mansoorizadeh M, Charkari N M. Multimodal information fusion application to human emotion recognition from face and speech[J]. Multimedia Tools and Applications, 2010, 49(2): 277−297.

[17] Hussain M D S, Calvo R A, Pour P A. Hybrid fusion approach for detecting affects from multichannel physiology[C]. In: International Conference on Affective Computing and Intelligent Interaction. Springer, Berlin: Heidelberg, 2011: 568−577.

[18] Poria S, Hussain A, Cambria E. Beyond text based sentiment analysis: Towards multi-modal systems[J]. University of Stirling, 2013.

[19] Poria S, Cambria E, Howard N, et al. Fusing audio, visual and textual clues for sentiment analysis from multimodal content[J]. Neurocomputing, 2016, 174: 50−59.

[20] Poria S, Majumder N, Hazarika D, et al. Multimodal sentiment analysis: Addressing key issues and setting up the baselines[J]. IEEE Intelligent Systems, 2018, 33(6): 17−25.

[21] 杨锦涛. 基于多模态融合的情感分析关键技术研究[D]. 成都: 电子科技大学, 2021.

[22] Xu N, Mao W, Chen G. A co-memory network for multimodal sentiment analysis[C]. In: The 41st international ACM SIGIR conference on research & development in information retrieval, 2018: 929−932.

[23] Li Z, Fan Y, Jiang B, et al. A survey on sentiment analysis and opinion mining for social multimedia[J]. Multimedia Tools and Applications, 2019, 78(6): 6939−6967.

[24] Poria S, Majumder N, Mihalcea R, et al. Emotion recognition in conversation: Research challenges, datasets, and recent advances[J]. IEEE Access, 2019, 7: 100943−100953.

[25] Cambria E, Das D, Bandyopadhyay S, et al. Affective computing and sentiment analysis[M]. Springer, Cham: A practical guide to sentiment analysis, 2017: 1−10.

[26] Zhang Y, Song D, Zhang P, et al. A quantum-inspired multimodal sentiment analysis framework[J]. Theoretical Computer Science, 2018, 752: 21−40.

[27] Zhang Y, Li Q, Song D, et al. Quantum-Inspired Interactive Networks for Conversational Sentiment Analysis[C]. In: 28th International Joint Conference on Artificial Intelligence (IJCAI2019), Macau, China,2019: 5436–5442.

[28] Wang Y, Hou Y, Che W, et al. From static to dynamic word representations: a survey[J]. International Journal of Machine Learning and Cybernetics, 2020, 11(7): 1611−1630.

[29] Mikolov T, Yih W, Zweig G. Linguistic regularities in continuous space word representations[C]. In: Proceedings of the 2013 conference of the north american chapter of the association for computational linguistics. Human language technologies, 2013: 746−751.

[30] Akbik A, Bergmann T, Vollgraf R. Pooled contextualized embeddings for named entity recognition[C]. In: Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics.Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 724−728.

[31] Wang H, Meghawat A, Morency L P, et al. Select-additive learning: Improving generalization in multimodal sentiment analysis[C]. In: 2017 IEEE International Conference on Multimedia and Expo (ICME). Hong Kong, China: IEEE, 2017: 949−954.

[32] Yang X, Feng S, Zhang Y, et al. Multimodal Sentiment Detection Based on Multi-channel Graph Neural Networks[C]. In: Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 328−339.

[33] Sarzynska-Wawer J, Wawer A, Pawlak A, et al. Detecting formal thought disorder by deep contextualized word representations[J]. Psychiatry Research, 2021, 304: 114135.

[34] Joze H R V, Shaban A, Iuzzolino M L, et al. MMTM:

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Multimodal transfer module for CNN fusion[C]. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020: 13289−13299.

[35] Xu N, Mao W. Multisentinet: A deep semantic network for multimodal sentiment analysis[C]. In: Proceedings of the 2017 ACM on Conference on Information and Knowledge Management, 2017: 2399−2402.

[36] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]. In: 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). San Diego, CA, USA :IEEE, 2005: 886−893.

[37] Pérez-Rosas V, Mihalcea R, Morency L P. Utterance-level multimodal sentiment analysis[C]. In: Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2013: 973−982.

[38] Wagner J, Andre E, Lingenfelser F, et al. Exploring fusion methods for multimodal emotion recognition with missing data[J]. IEEE Transactions on Affective Computing, 2011, 2(4): 206−218.

[39] Poria S, Cambria E, Hazarika D, et al. Context-dependent sentiment analysis in user-generated videos[C]. In: Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vancouver, Canada: Association for Computational Linguistics, 2017: 873−883.

[40] Kumar A, Vepa J. Gated mechanism for attention based multi modal sentiment analysis[C]. In: ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Barcelona, Spain: IEEE, 2020: 4477−4481.

[41] Zadeh A, Chen M, Poria S, et al. Tensor fusion network for multimodal sentiment analysis[EB/OL]. https://arxiv.org/pdf/:1707.07250.pdf, 2017.

[42] Fridman A, Stolerman A, Acharya S, et al. Decision fusion for multimodal active authentication[J]. IT Professional, 2013, 15(4): 29−33.

[43] Debie E, Rojas R F, Fidock J, et al. Multimodal fusion for objective assessment of cognitive workload: a review[J]. IEEE transactions on cybernetics, 2019, 51(3): 1542−1555.

[44] Yu Y, Lin H, Meng J, et al. Visual and textual sentiment analysis of a microblog using deep convolutional neural networks[J]. Algorithms, 2016, 9(2): 41.

[45] Gunes H, Piccardi M. Bi-modal emotion recognition from expressive face and body gestures[J]. Journal of Network and Computer Applications, 2007, 30(4): 1334−1345.

责任编辑：孙　林

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net