DOI:10.13467/j.cnki.jbuns.2011.04.011

宝鸡文理学院学报(自然科学版),第31卷,第4期,第40-44页,2011年12月
Journal of Baoji University of Arts and Sciences (Natural Science), Vol. 31, No. 4, pp. 40-44, Dec. 2011
DOI:CNKI:61-1290/N. 20111215. 1631. 001
http://www.cnki.net/kcms/detail/61.1290.N.20111215.1631.001.html

基于聚类分析的网络舆情监控系统的设计*

黄美璇
(黎明职业大学 机电工程系,福建 泉州 362000)

摘　要:目的　结合中文信息处理技术,设计一个网络舆情监控系统;针对网络舆情挖掘研究中存在的问题,提出了一种K-means改进算法,实现Web挖掘基础上的文本聚类与主题发现。**方法**　构建一个基于聚类分析的网络舆情监控系统,并详细介绍系统各个模块用到的关键技术;提出了一种K-means改进算法,对K-means算法中的关键环节(聚类初始值的选择和孤立点的剔除)进行了改进。**结果**　设计的系统能通过对网页、论坛、博客、新闻评论等网络资源的精确采集,并结合网页净化、中文分词、向量模型建立、特征选择、降维处理,文本聚类等中文信息处理技术,实现对网络舆情的监测;改进算法的总体思路是要求用户输入簇的初始个数 k 和最大值 k_{max},由改进算法在计算过程中自动计算出聚类的结果数 k。**结论**　设计了一个基于聚类分析的网络舆情监控系统;提出了一种K-means改进算法。具体算法实施及将这些关键技术整合实现成一套自动化的网络舆情信息采集、分析、监测与预警系统,是网络舆情挖掘研究工作的下一步重点。

关键词:舆情监控;K-means;文本聚类;主题发现
中图分类号:TP311.1　　**文献标志码:**A　　**文章编号:**1007-1261(2011)04-0040-05

The design of the network public opinion monitoring system based on cluster analysis

HUANG Mei-xuan
(Electrical and Mechanical Engineering College, Liming University, Quanzhou 362000, Fujian, China)

Abstract: Aim　To design a network public opinion monitoring system combined with Chinese information processing and to achieve text cluster and theme discovery by introducing an improved K-means approach for solving the problem that exists in the study of network public opinion mining. **Methods**　An improved K-means approach is set up by constructing one network popular feelings supervisory system based on the cluster analysis, and introducing key technologies in detail, and the key link in K-means algorithm (the cluster starting value's choice and the isolated point rejection) has been improved. **Results**　The system can monitor network public opinions by gathering precisely network resources like webpages, forums, blogs and news commentaries and combining Chinese information processing technology such as webpage purification, Chinese word segmentation, establish of vector model, feature selection, dimensionality reduction and text clustering. The general idea of the improved algorithm is that the improved algorithm can automatically compute the clustering results k after users input the initial number k of the cluster and maximum value k_{max}. **Conclusion**　Based on the cluster analysis, a network public opinion monitoring system is designed and an improved K-means ap-

* 收稿日期:2011-09-07,修回日期:2011-10-16,网络出版时间:2011-12-15 16:31
基金项目:黎明职业大学2010年度研究规划课题(LZ201002)
作者简介:黄美璇(1982-),女,福建泉州人,讲师,硕士,研究方向:数据库技术、数据挖掘. Email: flowerhmx@163.com

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

proach is introduced. The next key step of network public opinion mining and the integration of the key technology is to implement concretely the algorithm and create a set of automatic system of network public opinion gathering, analysis, monitoring and early warning.

Key words: public opinion monitoring; K-means; text clustering; theme discovery

1　引言

舆情是指在一定的社会空间内，围绕社会事件的发生、发展和变化，民众对社会管理者产生和持有的社会政治态度[1]，它是较多群众关于社会中各种现象以及问题所表达的信念、态度、意见和情绪等表现的总和。

随着互联网的迅猛发展，网络已成为庞大的公共信息集散地和民众参政议政最常用的平台。目前，对网络舆情的研究，在理论方面有学者注意到网络舆情的影响力，提出需要建立网络舆情信息汇集、分析、预警机制，但尚未进一步涉及深入到细节的具体实施方式[2]。

本文结合中文信息处理技术，设计一个网络舆情监控系统，为网络舆情监控系统的实现提出解决思路；针对网络舆情挖掘研究中存在的问题，提出了一种 K-means 改进算法，实现网络挖掘基础上的文本聚类与主题发现。

2　系统的整体设计及功能模块

设计该系统的基本思想是：充分利用计算机进行网络舆情监控工作，最大程度减少人工干预。系统设计的目标是：通过对网页、论坛、博客、新闻评论等网络资源的精确采集，并结合网页净化、中文分词、向量模型建立、特征选择、降维处理、文本聚类等中文信息处理技术，实现对网络舆情的监测。

基于聚类分析的网络舆情监控系统框图如图 1 所示。主要由舆情主题规划模块、舆情信息收集模块、舆情信息预处理模块、舆情信息分析模块和舆情预警告处理模块 5 个部分组成，这 5 部分构成一个完整的网络舆情监控的生命周期。

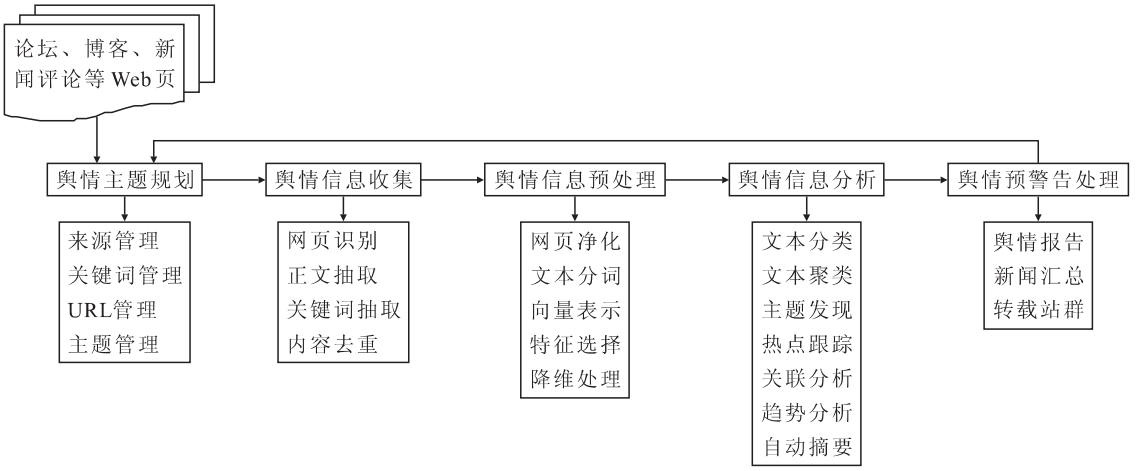

图 1　舆情监控系统整体功能模块框图

2.1　舆情主题规划模块

该模块实现的功能是确定需要实时跟踪监控的网站；对网站监控的内容确定其需要实时跟踪的关键词；根据实际需求，调整采集主题。

2.2　舆情信息采集模块

该模块实现的功能是利用软件将非结构化的信息从大量的网页中抽取出来保存到结构化的数据库中。针对规划好的舆情主题，经过抽取剔除主题无关的舆情信息，将主题相关的舆情信息保存到数据库中；然后对于已经定位好的网络资源，通过“网络雷达”技术判定网络资源是否已经保存到历史数据库中，如果是，系统将忽略该资源继续下一资源的收集。否则，系统将对该网络资源运用网络爬行器(Crawler)、网络蜘蛛等技术手段[3]进行信息获取，将信息保存到数据库中，为接下来的信息预处理做好准备。为了能够高效地采集页面数据，该模块采用多线程并行的采集策略，如图 2 所示。

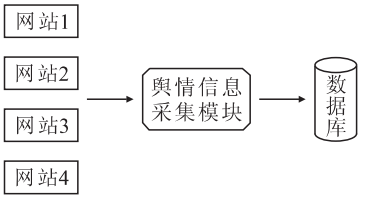

图 2　舆情信息采集模块概念图

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

2.3 舆情信息预处理模块

该模块主要任务是,将舆情信息收集模块所获取的网页源码作进一步的信息处理,包括:网页净化、文本分词、特征向量表示(VSM)、停用词及虚词净化、词频统计(TF*IDF)、降维处理等,是舆情监控系统的数据准备阶段。舆情信息预处理模块的流程如图 3 所示。

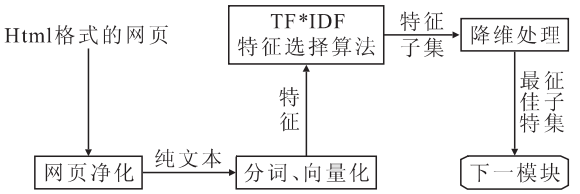

图 3 舆情信息预处理过程图

1) 网页净化

网页净化过程一般可以分为网页内容结构的表示和网页内容块的取舍[4] 2 个步骤。HTML 是一个标识语言(Markup Language),它定义了一套标签来刻画网页显示时的页面布局。因此,对于 HTML 网页最常用的结构表示方法是构造网页的标签树[5]。

网页根据内容可以分为主题网页、目录网页和图片网页 3 类,其净化方法各不相同。目录网页是将网页中间区域的内容块作为网页的主题内容,而边缘的内容块则通过与主题内容计算相似性的方法来决定取舍。图片网页则采用保留网页中间区域的图片型内容块达到网页净化。主题网页净化方法为:先识别出网页中的主题内容块;再依据主题内容在剩余内容块中识别出与主题相关的内容块;最后剩下的内容块就是噪音内容块。对于相似性的计算,本文采用如下公式:

$$w_i = \frac{\sum_{j=1}^{BN} BWeight_j \times BTf_{ij}}{\sqrt{\sum_{i=1}^{n}\left(\sum_{j=1}^{BN} BWeight_j \times BTf_{ij}\right)^2}}$$

式中:BN 为网页中内容块的总数;n 为网页中不同关键词的总数;$BWeight_j$ 为网页中内容块 j 的权重;BTf_{ij} 为关键词 i 出现在内容块 j 中的词频。

2) 中文分词

中文分词(Chinese Word Segmentation)指的是将一个汉字序列切分成一个一个单独、有意义的词。现有的分词算法可分为 3 大类:基于字符串匹配的分词方法、基于理解的分词方法和基于统计的分词方法。系统采用中科院的 ICTCLAS 分词系统,分词后根据得到的词性标注将介词、助词、叹词、语气词、拟声词、标点符号、停用词去掉,得到该文档中的特征词。

3) 向量空间模型的建立

WEB 文档都是半结构化或无结构化,没有关系数据库中数据的结构化特性或者是只有有限的结构特性。本文采用了向量空间模型来表示 WEB 文档[6]。该模型[7]将文档空间看作是由一组正交词条向量所组成的向量空间,每个文档表示为其中的一个特征向量。

4) 特征抽取(降维处理)

当使用向量空间模型表示文本时,往往维数偏大,制约了后续聚类算法的效率。目前在文本聚类中,有几种技术可以减少高维特征向量的维数。如 PCA(Principal Component Analysis)方法、LSI(Latent Semantic Indexing)方法、CI(Concept Indexing)方法、SOFM(Kohonen Self-Organizing Feature Map)方法、MDS(Multi-dimensional Scaling)方法。本文采用的是 PCA 方法。

2.4 舆情信息分析模块

该模块利用文本聚类对预处理后的舆情信息进行分析、挖掘;实现网络舆情信息的主题发现[8]。该模块的流程如图 4 所示,是整个系统的核心模块。

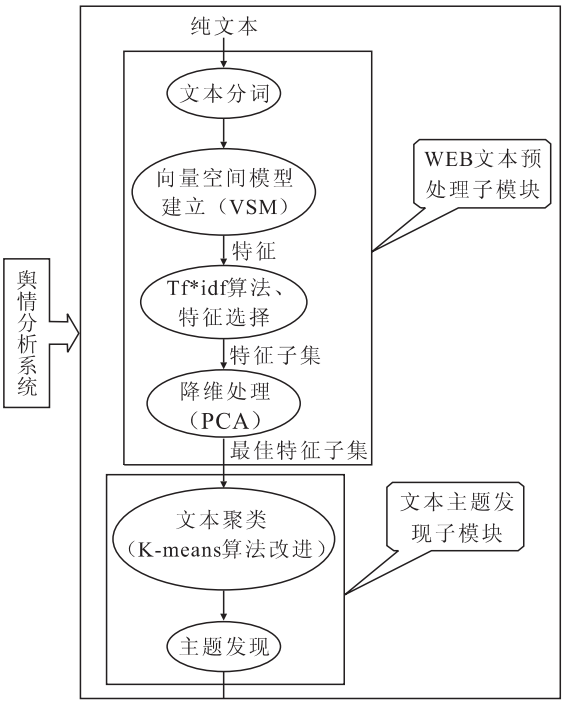

图 4 舆情分析系统

2.5 舆情预警处理

该模块根据舆情分析结果作出相应的处理,

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

并将结果以简报、报告、列表等形式反馈给决策者或舆情监督部门，为管理和决策提供支持。决策者或舆情监督部门获得舆情分析报告后往往会产生新的舆情需求，从而进入到下一轮循环之中，直到其满意为止。

3　关键算法分析

3.1　中文分词的核心代码

在 WEB 文本预处理子模块中文分词采用 ICTCLAS 分词系统，核心代码如下：

```
#include" Result\\result. h"
CResult m_ICTCLAS;
CFileDialog dlg(true,(LPCTSTR)(" txt"),(LPCTSTR)(" test"),OFN_HIDEREADONLY | OFN_OVERWRITEPROMPT," Text File(*. txt) | *. txt");
char sSourceFile[100],sResultFile[100];
if(dlg. DoModal()==IDOK)
{
UpdateData();
m_ICTCLAS. m_nOutputFormat=m_nOutputFormat;
m_ICTCLAS. m_nOperateType=m_nOperateType;
clock_t start, finish;
strcpy(sSourceFile,(LPCTSTR)dlg. GetPathName());//Get file name and path
strcpy(sResultFile,sSourceFile);//Set the result file name and path
unsigned int nLen=strlen(sSourceFile);
strncpy(sResultFile + nLen - 4," _cla. txt",10);//Change the extension
sResultFile[nLen+4]=0;
start=clock();
if(!m_ICTCLAS. FileProcessing(sSourceFile,sResultFile))　　m_sResult. Format(" 错误:程序初始化异常!");
else
{
finish=clock();
m_nTime=1000*(finish-start)/CLOCKS_PER_SEC;
m_sResult. Format(" 处理结果已经存在文件%s 中!",sResultFile);
}
UpdateData(FALSE);
}
```

3.2　PCA 技术降维处理

在 WEB 文本预处理子模块中，本文利用 PCA 方法进行特征抽取[9]的步骤如下：

1）统计建立词语特征-文档矩阵 $\boldsymbol{A}$；

2）求协方差矩阵 $\boldsymbol{A}$ 的特征值以及相应的特征向量；

3）计算各个主成分的累积贡献度；

4）计算协方差矩阵的特征值大于阈值的个数，来确定恰当的主成分个数 g；

5）提取主成分；

6）对 g 个提取的主成分做回归分析，得到新的 g 维降维特征空间，进而得到降维特征向量。

3.3　K-means 改进算法

在文本主题发现子模块的文本聚类过程中，针对 K-means 聚类算法的不足（如要求输入数字 k 确定结果簇的个数，对于不同初始值的选取可能导致不同的结果[10]；虽对类球形且大小差别不大的类簇有很好的表现，但不能发现形状任意和大小差别很大的类簇[11]；聚类结果易受噪声数据（孤立点）影响），提出了一种 K-means 改进算法，对 K-means 算法中的关键环节（聚类初始值的选择和孤立点的剔除）进行了改进。

改进算法的总体思路是要求用户输入簇的初始个数 k 和最大值 $k_{\max}$，由改进算法在计算过程中自动计算出聚类的结果数 k。改进算法中，有 2 个参数，一是类的初始个数 k（也就是 k-均值算法的 k 值），二是类的最大个数 $k_{\max}$，引入这个参数的优势是当出现文档对象与现有簇心的相似度等于 0 时，以这个文档对象为簇心新增一个类（但不会超过设置的类的最大个数 $k_{\max}$）。当类的个数等于设置的类的最大个数 $k_{\max}$，又出现一个文档对象与所有簇心的相似度都等于 0 时，就以这个文档对象作为孤立点剔除出聚类过程。

4　结论及未来工作

本文结合中文信息处理技术，设计了一个基于聚类分析的网络舆情监控系统，并详细介绍系统各个模块用到的关键技术；针对网络舆情挖掘研究中存在的问题，提出了一种 K-means 改进算法，对 K-means 算法中的关键环节（聚类初始值的选择和孤立点的剔除）进行了改进。具体算法实施及将这些关键技术整合实现成一套自动化的网络舆情信息采集、分析、监测与预警系统，是网络舆情挖掘研究工作的下一步重点。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

参考文献:

[1] 丁杰,徐俊刚. IPSMS:一个网络舆情监控系统的设计与实现[J]. 计算机应用与软件,2010(4):188-190.

[2] 陆蓓,程肖,谌志群. 互联网舆情挖掘研究述略[J]. 情报资料工作,2010(2):41-45.

[3] 王娟. 网络舆情监控分析系统构建[J]. 长春理工大学学报:高教版,2007,2(4):201-203,214.

[4] 张焕明. 网络舆情分析系统的研究与设计[J]. 微计算机信息,2010,26(18):119-121.

[5] 胡珀,何婷婷. 基于自适应聚类的文本潜在主题的自动发现[J]. 郑州大学学报:理学版,2007,39(2):92-95.

[6] 何佳,周长胜,石显锋. 网络舆情监控系统的实现方法[J]. 郑州大学学报:理学版,2010,42(1):82-85.

[7] 李若鹏,李翔,林祥,等. 基于 DK 算法的互联网热点主动发现研究与实现[J]. 计算机技术与发展,2008,18(9):1-4.

[8] 司夏萌,刘云,程辉,等. 基于态势评估的网络舆论监控与引导系统的研究[J]. 网络安全技术与应用,2009(12):59-61.

[9] 刘茂福,李文捷,姬东鸿. 基于事件项语义图聚类的多文档摘要方法[J]. 中文信息学报,2010,24(5):77-84.

[10] 陈利虎,张尔扬,沈荣骏. 基于优化初始聚类中心 K-Means 算法的跳频信号分选[J]. 国防科技大学学报,2009,31(2):70-75.

[11] 张忠平,王爱杰,陈丽萍. 一种基于广度优先搜索的 K-means 初始化算法[J]. 计算机工程与应用,2008,44(27):159-161.

(编校:李宗红)

英首次将石墨烯变成绝缘体

石墨烯"巨无霸汉堡"有望替代硅芯片

据美国物理学家组织网 2011 年 10 月 10 日(北京时间)报道,英国曼彻斯特大学的科学家们在《自然·物理学》上撰文,描述了他们用两块硝酸硼和两块石墨烯组装成一个"巨无霸汉堡",这是科学家们首次将石墨烯变成绝缘体,这个"巨无霸汉堡"有望取代计算机内的硅芯片。

石墨烯是从石墨材料中剥离出来、由碳原子组成的二维晶体,只有一层碳原子的厚度,是迄今最薄也最坚硬的材料,其导电、导热性能超强,远远超过硅和其他传统的半导体材料。随着对石墨烯的研究越来越深入,科学家们认为,石墨烯有望彻底变革材料科学领域,未来或能取代硅成为电子元件材料,广泛应用于超级计算机、触摸屏和光子传感器等多个领域。

在这项最新研究中,科学家将两层石墨烯和另外两层硝酸硼结合在一起,组装成一个四层结构的三明治式样的物质,并将其命名为"巨无霸汉堡"。两层硝酸硼不仅用于隔离两层石墨烯,而且能将石墨烯完全被其他物质包围时的反应展示于人前,从而使科学家们首次能观察到石墨烯不受环境影响时的所作所为。

该研究的主要作者、曼彻斯特大学的列昂尼德·波诺玛伦科表示:"制造出这种多层结构使我们能摒除周围环境带来的负面影响并控制石墨烯的电性,以前根本无法做到这一点。"

他说:"迄今为止,人们从来没有将石墨烯当作绝缘体,除非将其正确地破坏,但现在,科学家们首次将高质量的石墨烯变成绝缘体。"

因在石墨烯研究领域的突出贡献而荣膺 2010 年诺贝尔奖的英国曼彻斯特大学教授安德烈·盖姆指出:"我们一直在寻找新方法改进石墨烯的性能。最新用硝酸硼包裹的石墨烯能为未来的石墨烯电子设备提供最好、最先进的平台,从技术上来讲,这一点非常重要。它解决了科学家们此前一直担心的石墨烯的稳定性和质量问题,这两个问题一直是盘旋在用石墨烯制造各种电子设备这一灿烂美妙前景上的乌云。"

盖姆也解释到,现在,他们只是在较小的层面上做到了这一点,但结果表明,与石墨烯有关的一切都能被扩大。

(摘自科技网:http://www.stdaily.com/kjrb/content/2011-10/11/content_355057.htm)

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net